

AWS Academy Cloud Foundations (PT)

Module 10 Student Guide

Version 2.0.16

100-ACCLFO-20-PT-SG

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Este trabalho não pode ser reproduzido ou redistribuído, no todo ou em parte, sem a permissão prévia por escrito da Amazon Web Services, Inc. É proibido copiar, emprestar ou vender para fins comerciais.

Para correções ou comentários sobre o curso, entre em contato conosco em https://support.aws.amazon.com/#/contacts/aws-training.

Todas as marcas comerciais pertencem a seus proprietários.

Contents

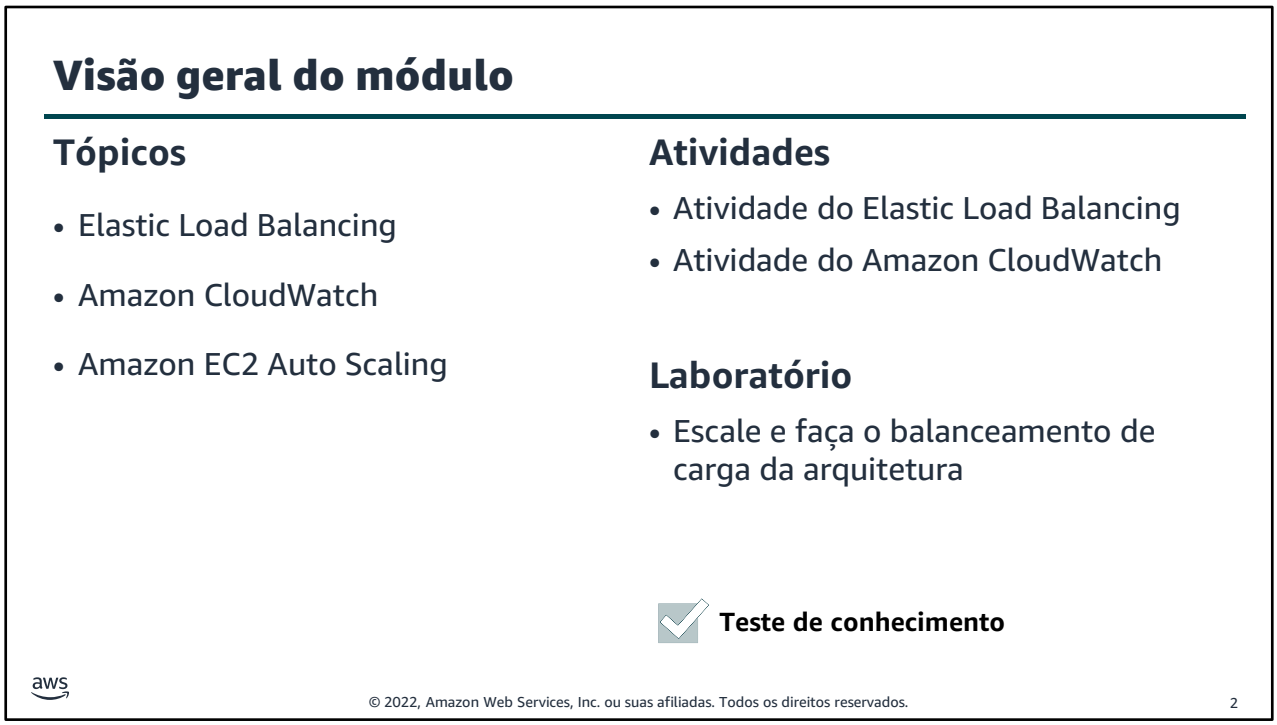
Módulo 10: Auto Scaling e monitoramento 4

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Bem-vindo ao Módulo 10: Auto Scaling e monitoramento

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



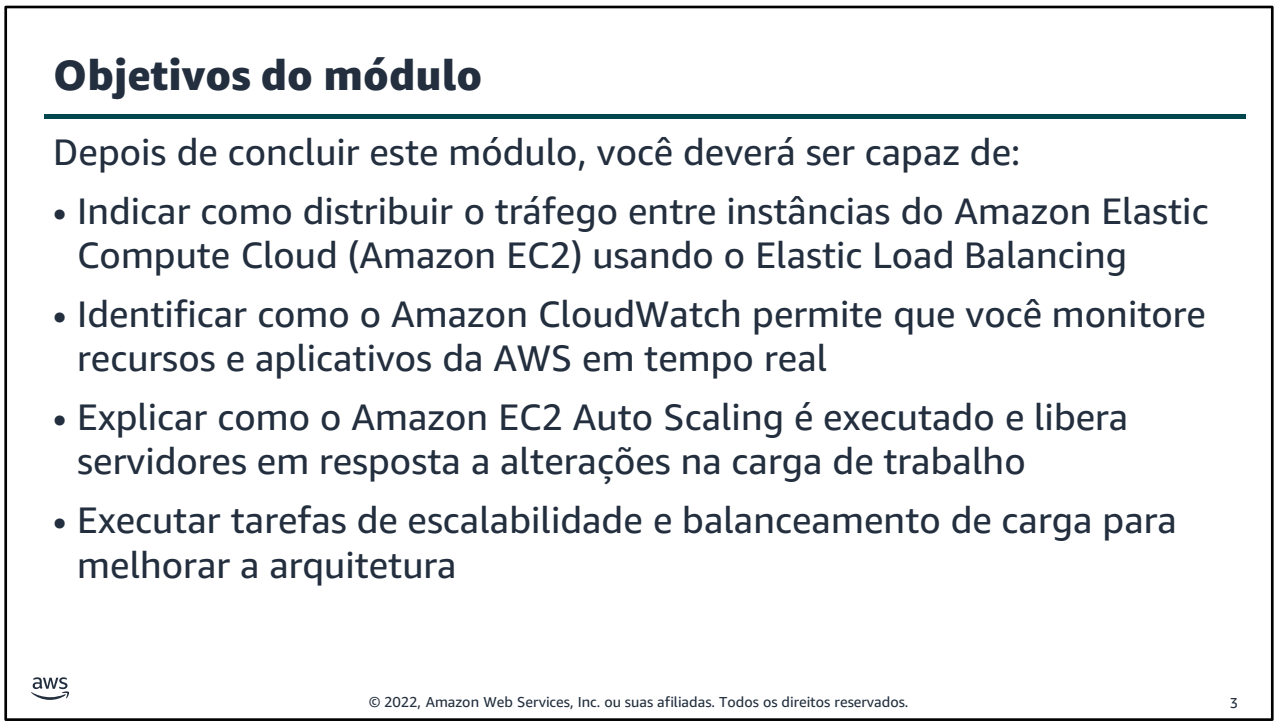
Este módulo abordará os seguintes tópicos:
- Elastic Load Balancing
- Amazon CloudWatch
- Amazon EC2 Auto Scaling

O módulo também inclui duas atividades. Uma atividade desafiará você a indicar casos de uso do Elastic Load Balancing. A outra atividade desafiará você a identificar exemplos do Amazon CloudWatch.

O módulo também inclui um laboratório prático onde você usará o Amazon EC2 Auto Scaling, o Elastic Load Balancing e o Amazon CloudWatch juntos para criar uma arquitetura dinamicamente escalável.

Por fim, você deverá concluir um teste de conhecimento que será usado para avaliar sua compreensão dos principais conceitos abordados neste módulo.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Depois de concluir este módulo, você deverá ser capaz de:
- Indicar como distribuir o tráfego entre instâncias do Amazon Elastic Compute Cloud (Amazon EC2) usando o Elastic Load Balancing
- Identificar como o Amazon CloudWatch permite que você monitore recursos e aplicativos da AWS em tempo real
- Explicar como o Amazon EC2 Auto Scaling é executado e libera servidores em resposta a alterações na carga de trabalho
- Executar tarefas de escalabilidade e balanceamento de carga para melhorar a arquitetura

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

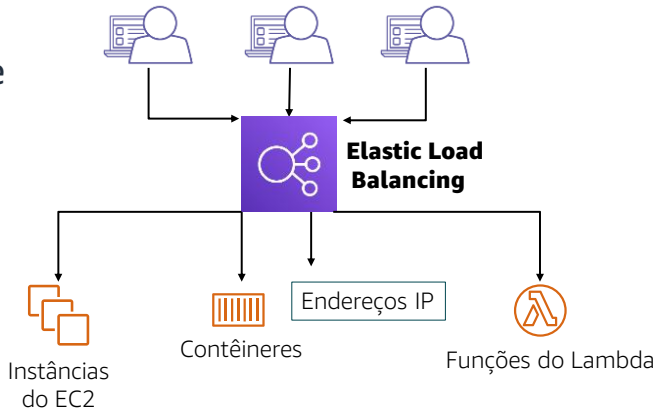


Seção 1: Elastic Load Balancing

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Elastic Load Balancing

- Distribui o tráfego de entrada do aplicativo ou da rede entre vários destinos em uma única zona de disponibilidade ou em várias zonas de disponibilidade.
- Escala seu load balancer à medida que o tráfego para seu aplicativo muda com o tempo.

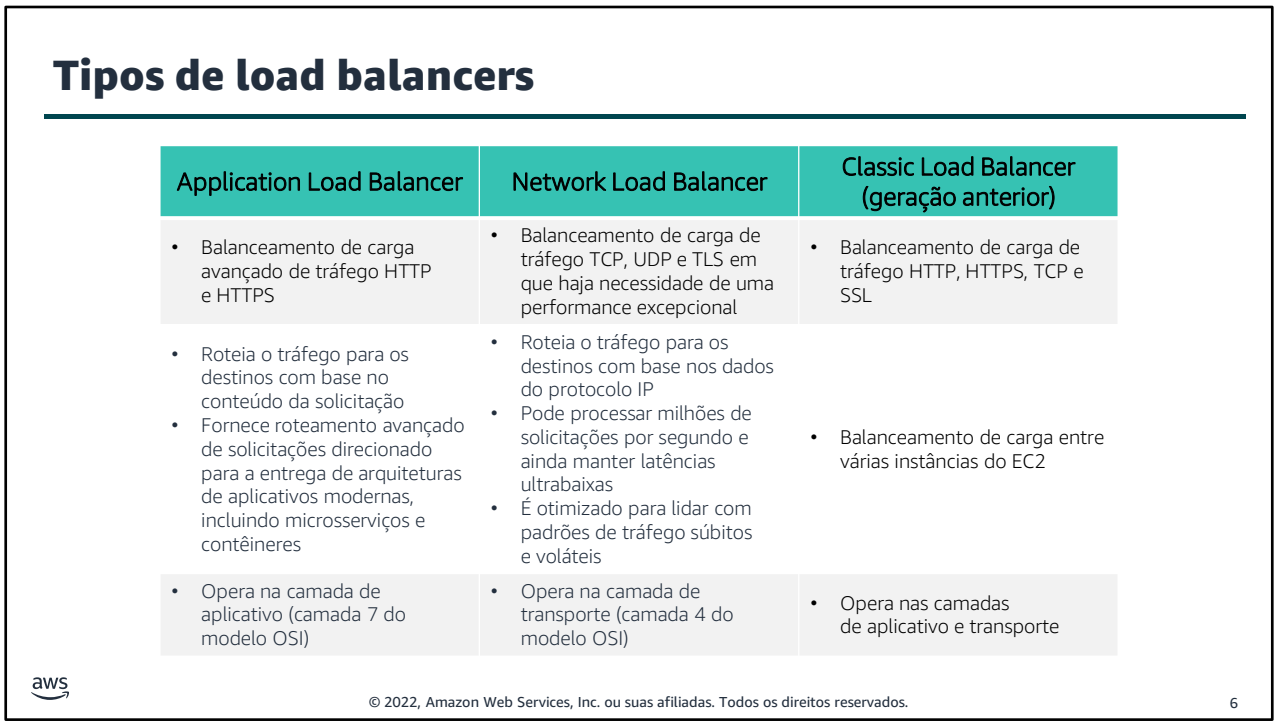


© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 5

Os sites modernos de alto tráfego devem atender a centenas de milhares, se não milhões, de solicitações simultâneas de usuários ou clientes, e retornar os dados corretos de texto, imagens, vídeo ou aplicativos de maneira rápida e confiável. Servidores adicionais geralmente são necessários para atender a esses altos volumes.

O Elastic Load Balancing é um serviço da AWS que distribui o tráfego de entrada de aplicativos ou rede entre vários destinos, como instâncias do Amazon Elastic Compute Cloud (Amazon EC2), contêineres, endereços de protocolo de Internet (IP) e funções Lambda, em uma única zona de disponibilidade ou em várias zonas de disponibilidade. O Elastic Load Balancing escala o load balancer à medida que o tráfego para o aplicativo muda ao longo do tempo. Ele pode escalar automaticamente para a maioria das cargas de trabalho.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



O Elastic Load Balancing está disponível em três tipos:

- Um *Application Load Balancer* opera no nível do aplicativo (Open Systems Interconnection, ou OSI, camada de modelo 7). Ele roteia o tráfego para destinos - instâncias do Amazon Elastic Compute Cloud (Amazon EC2), contêineres, endereços IP (Internet Protocol) e funções Lambda - com base no conteúdo da solicitação. Ele é ideal para balanceamento avançado de carga de tráfego Hypertext Transfer Protocol (HTTP) e Secure HTTP (HTTPS). Um Application Load Balancer oferece roteamento avançado de solicitações direcionado à distribuição de arquiteturas modernas de aplicativos, incluindo microsserviços e aplicativos baseados em contêiner. Um Application Load Balancer simplifica e melhora a segurança do seu aplicativo garantindo que as criptografias e os protocolos Secure Sockets Layer/Transport Layer Security (SSL/TLS) mais recentes sejam usados em todos os momentos.

- Um *Network Load Balancer* opera no nível de transporte de rede (camada 4 do modelo OSI), roteando conexões para destinos (instâncias do EC2, microsserviços e contêineres) com base em dados do protocolo IP. Ele funciona bem para o balanceamento de carga do tráfego Transmission Control Protocol (TCP) e do User Datagram Protocol (UDP). Um Network Load Balancer é capaz de lidar com milhões de solicitações por segundo, mantendo latências ultrabaixas. Um Network Load Balancer é otimizado para lidar com padrões de tráfego de rede súbitos e voláteis.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

- Um *Classic Load Balancer* fornece balanceamento de carga básico em várias instâncias do EC2 e opera tanto no nível do aplicativo quanto no nível do transporte de rede. Um Classic Load Balancer oferece suporte ao balanceamento de carga de aplicativos que usam HTTP, HTTPS, TCP e SSL. O Classic Load Balancer é uma implementação mais antiga. Quando possível, a AWS recomenda que você use um Application Load Balancer ou um Network Load Balancer dedicado.

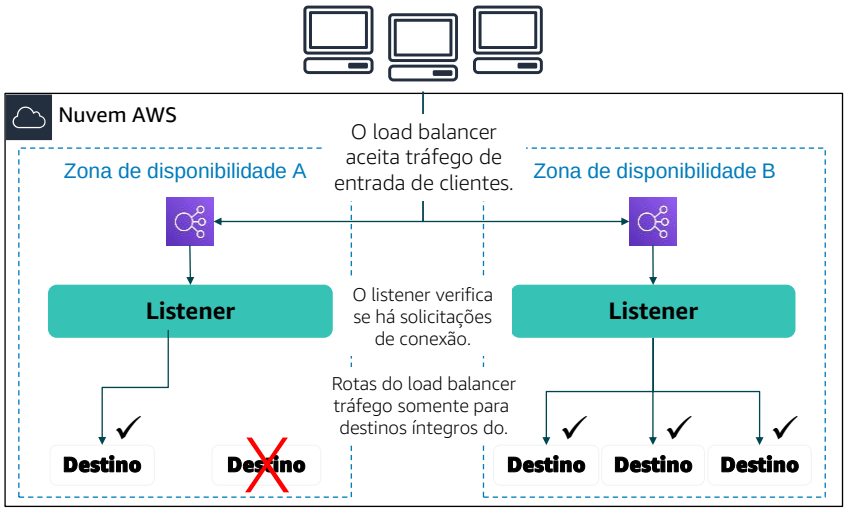
Para saber mais sobre as diferenças entre os três tipos de load balancers, consulte *Comparações de produtos* na página Recursos do Elastic Load Balancing.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Como o Elastic Load Balancing funciona

- Com Application Load Balancers e Network Load Balancers, você **registra destinos em grupos de destino**, e roteia o tráfego para os grupos de destino.
- Com Classic Load Balancers, você **registra instâncias com o load balancer.**

O load balancer executa verificações de integridade para monitorar a integridade dos destinos registrados.



© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 7

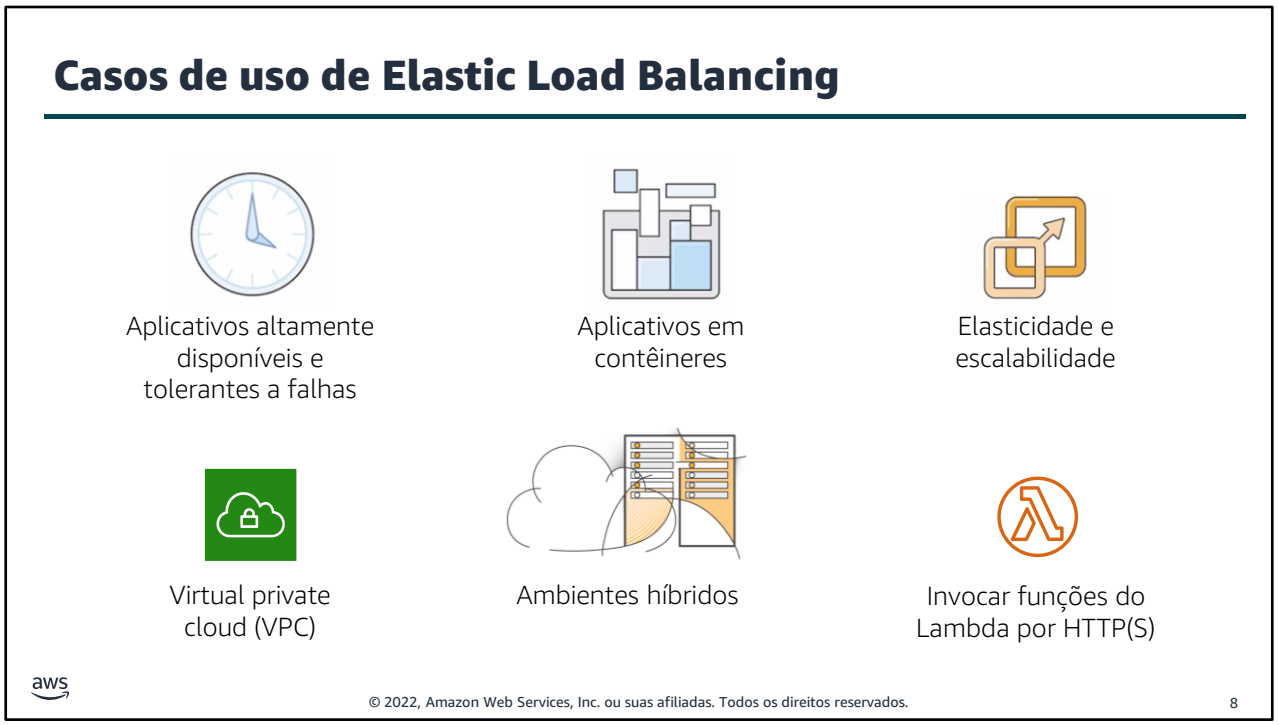
Um load balancer aceita o tráfego de entrada de clientes e roteia solicitações para seus destinos registrados (como instâncias do EC2) em uma ou mais zonas de disponibilidade.

Você configura o load balancer para aceitar tráfego de entrada especificando um ou mais *listeners*. Um listener é um processo que verifica se há solicitações de conexão. Ele é configurado com um protocolo e um número de porta para as conexões de clientes com o load balancer. Da mesma forma, ele é configurado com um protocolo e um número de porta para conexões do load balancer com os destinos.

Você também pode configurar o load balancer para executar *verificações de integridade*, que são usadas para monitorar a integridade dos destinos registrados para que o load balancer envie solicitações somente para as instâncias íntegras. Quando o load balancer detecta um destino não íntegro, ele interrompe o roteamento do tráfego para esse destino. Depois, ele retoma o roteamento do tráfego para esse destino quando detecta que o destino está íntegro novamente.

Há uma diferença fundamental em como os tipos de load balancer são configurados. Com Application Load Balancers e Network Load Balancers, você registra destinos em *grupos de destino*, e roteia o tráfego para os grupos de destino. Com Classic Load Balancers, você registra instâncias com o load balancer.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Há vários motivos para usar um load balancer:

- *Obtenha alta disponibilidade e melhor tolerância a falhas para seus aplicativos* -o Elastic Load Balancing equilibra o tráfego entre destinos íntegros em várias zonas de disponibilidade. Se um ou mais dos seus destinos em uma única zona de disponibilidade não estiverem íntegros, o Elastic Load Balancing roteará o tráfego para destinos íntegros em outras zonas de disponibilidade. Depois que os destinos retornarem para um estado íntegro, o balanceamento de carga retomará automaticamente o tráfego para eles.

- *Balanceamento de carga automático de aplicativos conteinerizados* - Com o suporte aprimorado de contêineres para o Elastic Load Balancing, agora você pode balancear a carga entre várias portas na mesma instância do EC2. Você também pode aproveitar a integração profunda com o Amazon Elastic Container Service (Amazon ECS), que disponibiliza uma oferta de contêineres totalmente gerenciada. Basta registrar um serviço com um load balancer e o Amazon ECS gerencia de maneira transparente o registro e o cancelamento do registro de contêineres do Docker. O load balancer detecta automaticamente a porta e se reconfigura dinamicamente.

- *Escale automaticamente seus aplicativos* - o Elastic Load Balancing funciona com o Amazon CloudWatch e o Amazon EC2 Auto Scaling para ajudar você a escalar seus

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

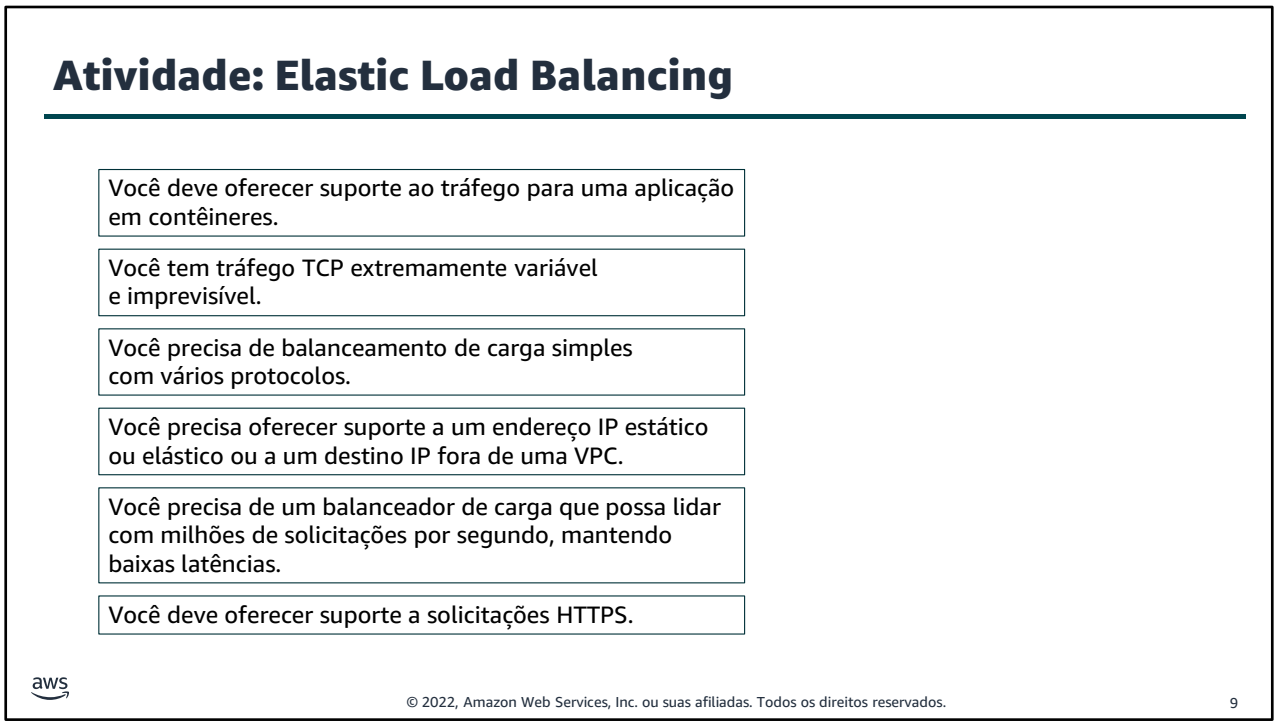
aplicativos de acordo com as demandas dos seus clientes. Os alarmes do Amazon CloudWatch podem acionar o Auto Scaling para sua frota de instâncias do EC2 quando a latência de qualquer uma de suas instâncias do EC2 exceder um limite pré-configurado. Em seguida, o Amazon EC2 Auto Scaling provisiona novas instâncias e seus aplicativos estarão prontos para atender à próxima solicitação do cliente. O load balancer registrará a instância do EC2 e direcionará o tráfego para ela, conforme necessário.

- *Usar o Elastic Load Balancing em sua nuvem privada virtual (VPC)* - Você pode usar o Elastic Load Balancing para criar um ponto de entrada pública em sua VPC ou para rotear o tráfego de solicitações entre níveis de seu aplicativo dentro de sua VPC. Você pode atribuir grupos de segurança ao seu load balancer para controlar quais portas estão abertas para uma lista de fontes permitidas. Como o Elastic Load Balancing funciona com a VPC, todas as listas de controle de acesso à rede (ACLs de rede) e tabelas de roteamento existentes continuam a fornecer controles de rede adicionais. Ao criar um load balancer em sua VPC, você pode especificar se ele é público (padrão) ou interno. Se você selecionar interno, não será preciso ter um gateway da Internet para acessar o load balancer, e os endereços IP privados dele serão usados para registrá-lo no DNS.

- *Enable hybrid load balancing* - O Elastic Load Balancing permite balancear a carga entre recursos locais e da AWS usando o mesmo load balancer. Por exemplo, se você precisar distribuir o tráfego de aplicativos entre recursos locais e da AWS, poderá registrar todos os recursos no mesmo grupo de destino e associá-lo a um load balancer. Como alternativa, é possível usar o balanceamento de carga ponderado baseado em DNS entre os recursos no local e da AWS usando dois load balancers, um para os recursos locais e o outro para os recursos da AWS. Também é possível usar balanceamento de carga híbrido para beneficiar aplicativos separados, quando um está em uma VPC e o outro está no local. Coloque os destinos da VPC em um grupo de destino, os destinos locais em outro grupo de destino e use o roteamento baseado em conteúdo para rotear o tráfego para cada grupo de destino.

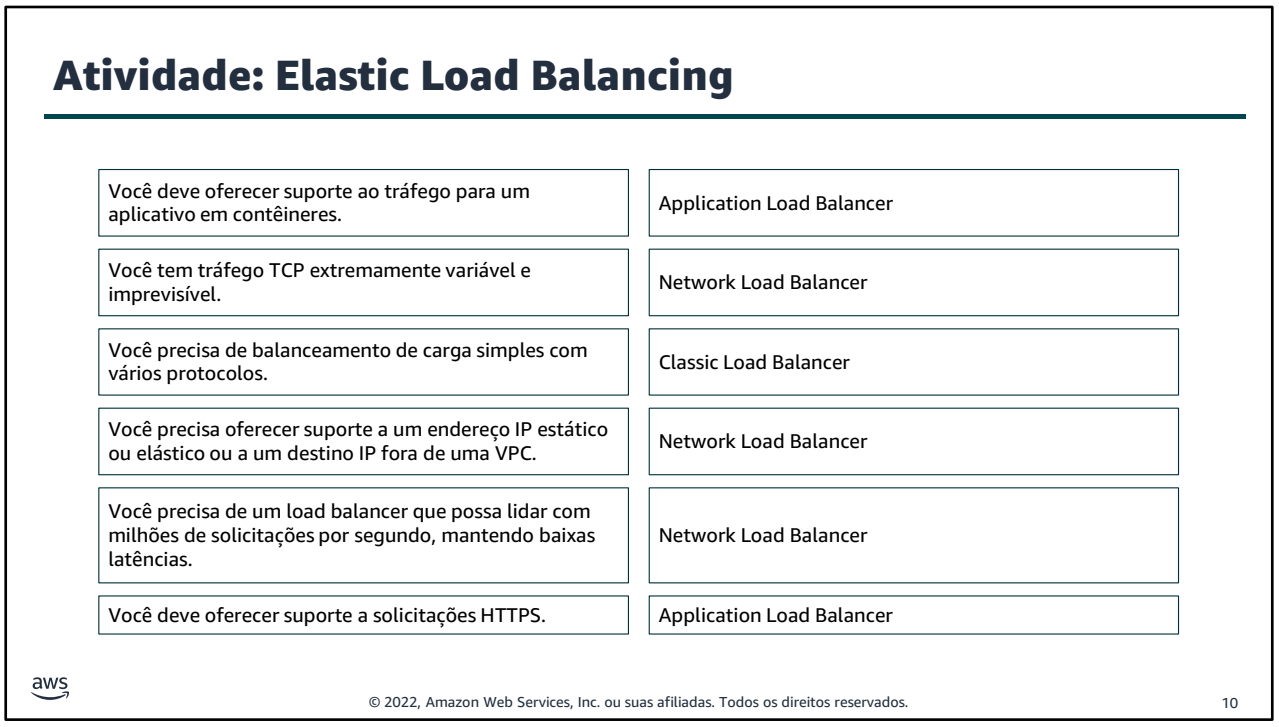
- *Invocar funções do Lambda via HTTP (S)* - o Elastic Load Balancing oferece suporte à invocação de funções do Lambda para atender a solicitações HTTP (S). Isso permite que os usuários acessem aplicativos sem servidor de qualquer cliente HTTP, incluindo navegadores da Web. Você pode registrar funções do Lambda como destinos e utilizar o suporte a regras de roteamento baseado em conteúdo nos Application Load Balancers para rotear solicitações para funções do Lambda diferentes. Você pode usar um Application Load Balancer como um endpoint HTTP comum para aplicativos que usam servidores e computação sem servidor. Você pode criar um site inteiro usando funções do Lambda ou combinar instâncias do EC2, contêineres, servidores locais e funções Lambda para criar aplicativos.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Para essa atividade, nomeie o balanceador de carga que você usaria para o cenário indicado.

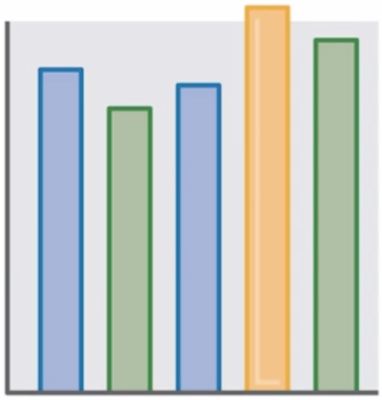
© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Para essa atividade, nomeie o load balancer que você usaria para o cenário indicado.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Monitoramento do load balancer



- **Métricas do Amazon CloudWatch** - usadas para verificar se o sistema está funcionando conforme o esperado e cria um alarme para iniciar uma ação se uma métrica sair de um intervalo aceitável.
- **Logs de acesso** - capture informações detalhadas sobre solicitações enviadas ao load balancer.
- **Logs do AWS CloudTrail** - Capture quem, o que, quando e onde das interações de API nos serviços da AWS.

aws

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 11

Você pode usar os seguintes recursos para monitorar seus load balancers, analisar os padrões de tráfego e solucionar problemas com seu load balancers e destinos:

- *Métricas do Amazon CloudWatch* - O Elastic Load Balancing publica pontos de dados no Amazon CloudWatch para seus load balancers e seus destinos. O CloudWatch permite recuperar estatísticas sobre esses pontos de dados como um conjunto ordenado de dados de séries temporais, conhecidos como métricas. Você pode usar métricas para verificar se o sistema está tendo a performance esperada. Por exemplo, você pode criar um alarme do CloudWatch para monitorar uma métrica específica e iniciar uma ação (como enviar uma notificação para um endereço de e-mail) se a métrica sair do que você considera um intervalo aceitável.

- *Logs de acesso* - Você pode usar logs de acesso para capturar informações detalhadas sobre as solicitações que foram feitas ao seu load balancer e armazená-las como arquivos de log no Amazon Simple Storage Service (Amazon S3). Você pode usar esses logs de acesso para analisar padrões de tráfego e solucionar problemas com seus destinos ou aplicativos de back-end.

- *Logs do AWS CloudTrail* - Você pode usar o AWS CloudTrail para capturar informações detalhadas sobre as chamadas que foram feitas para a interface de programação de aplicativos (API) do Elastic Load Balancing e armazená-las como

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

arquivos de log no Amazon S3. Você pode usar esses logs do CloudTrail para determinar quem fez a chamada, quais chamadas foram feitas, quando a chamada foi feita, o endereço IP de origem de onde a chamada veio e assim por diante.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Principais lições da Seção 1



- O Elastic Load Balancing distribui o tráfego de entrada de aplicativos ou rede entre vários destinos em uma ou mais zonas de disponibilidade.
- O Elastic Load Balancing oferece suporte a três tipos de load balancers:
  - Application Load Balancer
  - Network Load Balancer
  - Classic Load Balancer
- O ELB oferece verificações de integridade, segurança e monitoramento de instâncias.

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 12

Algumas das principais lições desta seção do módulo são:

- O Elastic Load Balancing distribui o tráfego de entrada de aplicativos ou rede entre vários destinos (como instâncias do Amazon EC2, contêineres, endereços IP e funções Lambda) em uma ou mais zonas de disponibilidade.
- O Elastic Load Balancing oferece suporte a três tipos de load balancers:
  - Application Load Balancer
  - Network Load Balancer
  - Classic Load Balancer
- O Elastic Load Balancing oferece várias ferramentas de monitoramento para monitoramento contínuo e registro em log para auditoria e análise.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Seção 2: Amazon CloudWatch

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Monitoramento de recursos da AWS

Para usar a AWS com eficiência, você precisa de informações sobre seus recursos da AWS:

- Como você sabe quando deve **executar mais instâncias do Amazon EC2**?
- A **performance ou a disponibilidade do seu aplicativo** estão sendo afetadas por falta de capacidade suficiente?
- Quanto da infraestrutura está realmente **sendo usada**?

aws

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

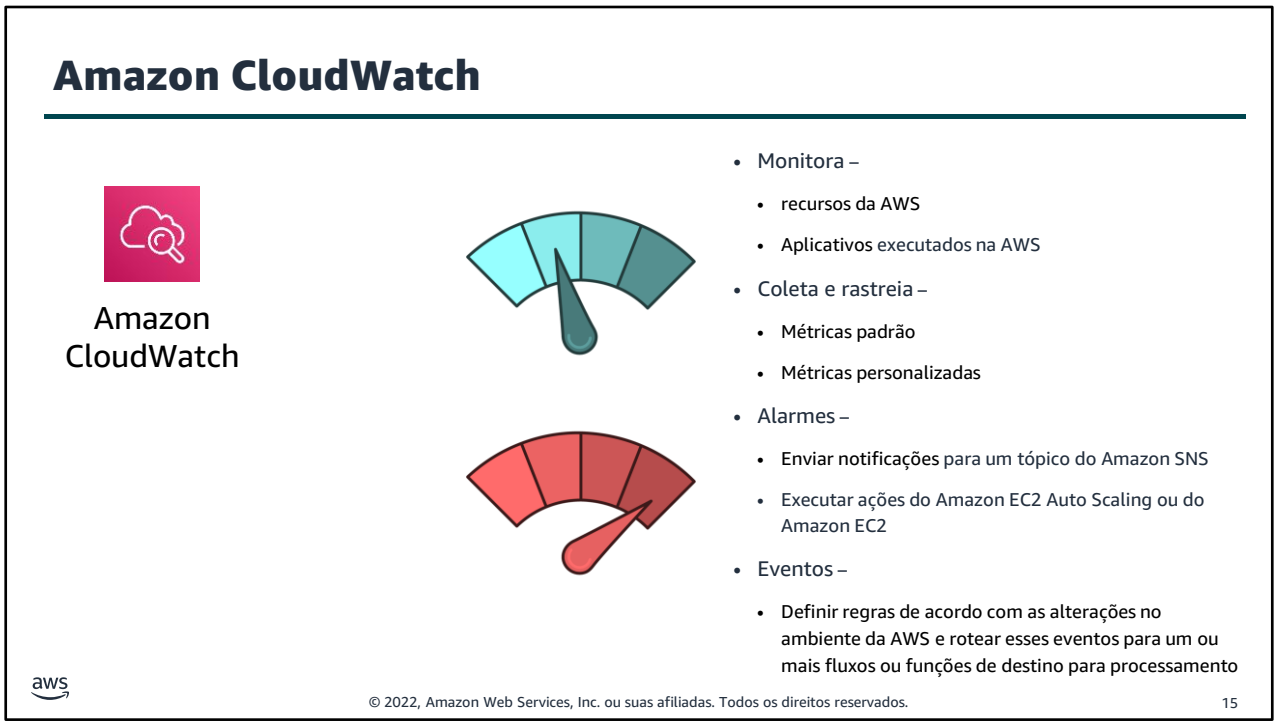
14

Para usar a AWS com eficiência, você precisa de informações sobre seus recursos da AWS.

Por exemplo, talvez você queira saber:
- Quando você deve executar mais instâncias do Amazon EC2?
- A performance ou a disponibilidade do seu aplicativo estão sendo afetadas pela falta de capacidade suficiente?
- Quanto da infraestrutura está realmente sendo usada?

Como você obtém essas informações?

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Você pode capturar essas informações com o Amazon CloudWatch.

O Amazon CloudWatch é um serviço de monitoramento e observabilidade criado para engenheiros de DevOps, desenvolvedores, Site Reliability Engineers (SREs – Engenheiros de confiabilidade de sites) e gerentes de TI. O CloudWatch monitora os recursos e as aplicações da AWS executados em tempo real na AWS. Você pode usar o CloudWatch para coletar e monitorar métricas, que são variáveis mensuráveis de seus recursos e aplicativos.

Você pode criar um alarme para monitorar qualquer métrica do Amazon CloudWatch em sua conta e usar o alarme para enviar automaticamente uma notificação para um tópico do Amazon Simple Notification Service (Amazon SNS) ou executar uma ação do Amazon EC2 Auto Scaling ou do Amazon EC2. Por exemplo, você pode criar alarmes sobre a utilização de CPU de uma instância do EC2, a latência de solicitação do Elastic Load Balancing, a taxa de transferência de tabelas do Amazon DynamoDB, o comprimento da fila do Amazon Simple Queue Service (Amazon SQS) ou até mesmo as cobranças da sua fatura da AWS. Também é possível criar um alarme para métricas personalizadas específicas de aplicativos ou infraestrutura personalizados.

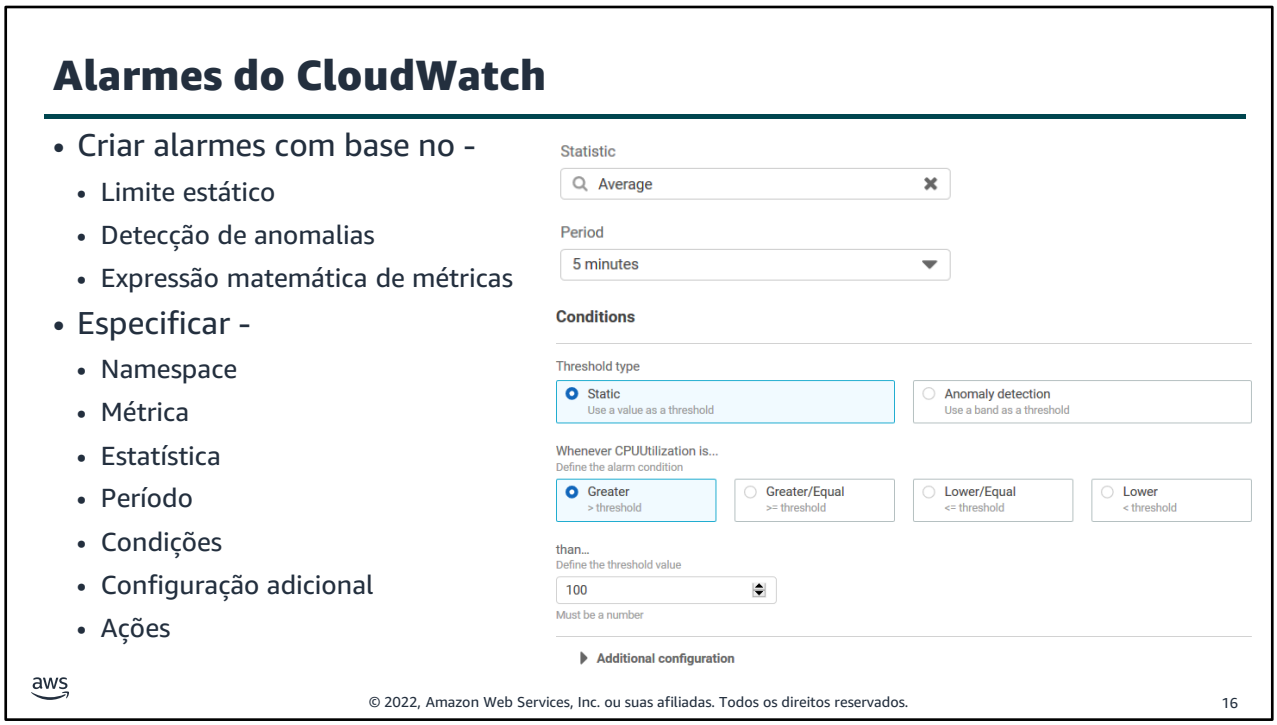
Você também pode usar o Amazon CloudWatch Events para definir regras que correspondam a eventos de entrada (ou alterações no seu ambiente da AWS) e roteá-

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

los para destinos para processamento. Os destinos podem incluir instâncias do Amazon EC2, funções do AWS Lambda, streams do Kinesis, tarefas do Amazon ECS, máquinas de estado do Step Functions, tópicos do Amazon SNS, filas do Amazon SQS e destinos integrados. O CloudWatch Events torna-se ciente das alterações operacionais à medida que ocorrem. O CloudWatch Events responde a essas alterações operacionais e realiza ações corretivas conforme necessário, enviando mensagens para responder ao ambiente, ativando funções, fazendo alterações e capturando informações de estado.

Com o CloudWatch, você ganha visibilidade integral do sistema da utilização de recursos, da performance de aplicativos e da integridade operacional. Não há compromissos antecipados nem taxas mínimas. Você simplesmentepaga pelo que usa. Ao final de cada mês, você será cobrado por seu uso.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Você pode criar um alarme do CloudWatch que observa uma única métrica do CloudWatch ou o resultado de uma expressão matemática com base nas métricas do CloudWatch. Você pode criar um alarme do CloudWatch com base em um limite estático, detecção de anomalias ou uma expressão matemática de métricas.

Ao criar um alarme com base em um limite estático, você escolhe uma métrica do CloudWatch para o alarme observar e o limite dessa métrica. O alarme passa para o estado ALARME quando a métrica atinge o limite de um número especificado de períodos de avaliação.

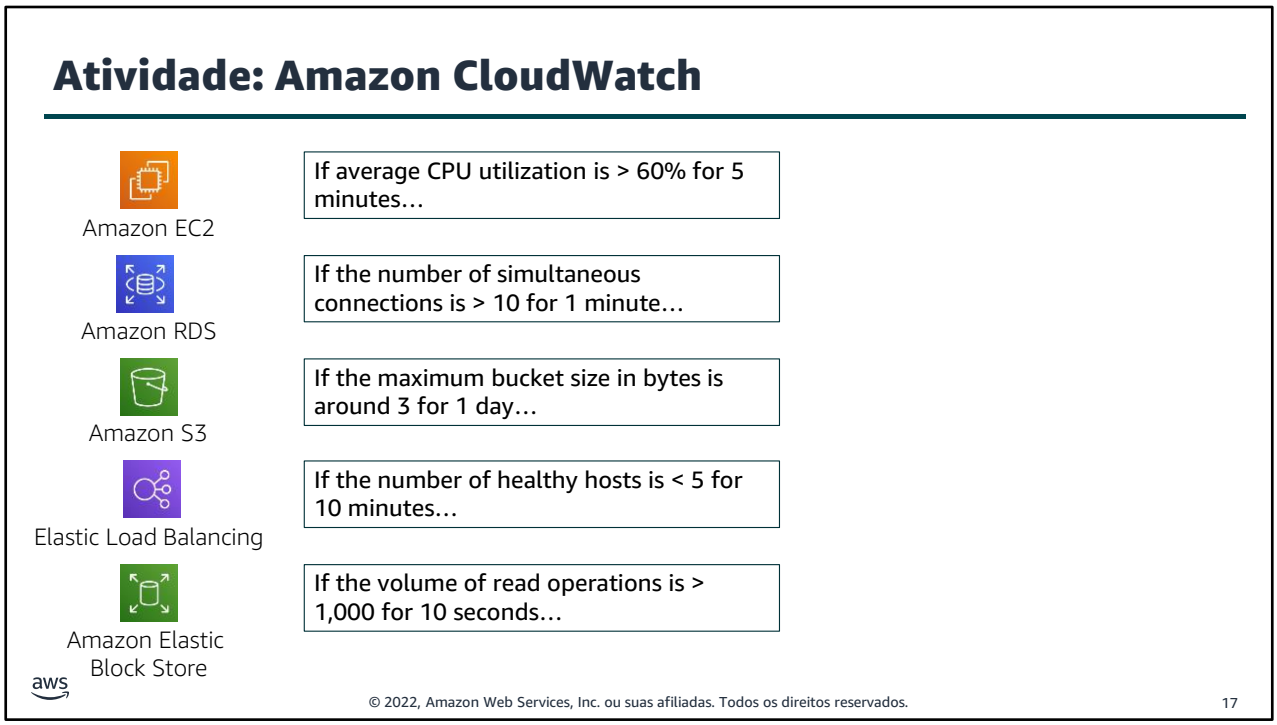
Para um alarme com base em um limite estático, você deve especificar o:
- *Namespace* - Um namespace contém a métrica do CloudWatch que você deseja, por exemplo, *AWS/EC2*.
- *Metric* - Uma métrica é a variável que você deseja medir, por exemplo, *utilização de CPU*.
- *Estatística* - Uma estatística pode ser uma média, soma, mínimo, máximo, contagem de amostras, um percentil predefinido ou um percentil personalizado.
- *Period* - Um período é o período de avaliação do alarme. Quando o alarme é avaliado, cada período é agregado em um ponto de dados.
- *Condições* - Ao especificar as condições para um limite estático, você especifica

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

sempre que a métrica for *Greater*, *Greater ou Equal*, *Lower ou Equal*, ou *Lower* que o valor limite, e você também especifica o valor limite.
- *Informações adicionais de configuração* - Isso inclui o número de pontos de dados dentro do período de avaliação que devem ser violados para acionar o alarme e como o CloudWatch deve tratar dados ausentes ao avaliar o alarme.
- *Ações* - Você pode optar por enviar uma notificação para um tópico do Amazon SNS ou executar uma ação do Amazon EC2 Auto Scaling ou do Amazon EC2.

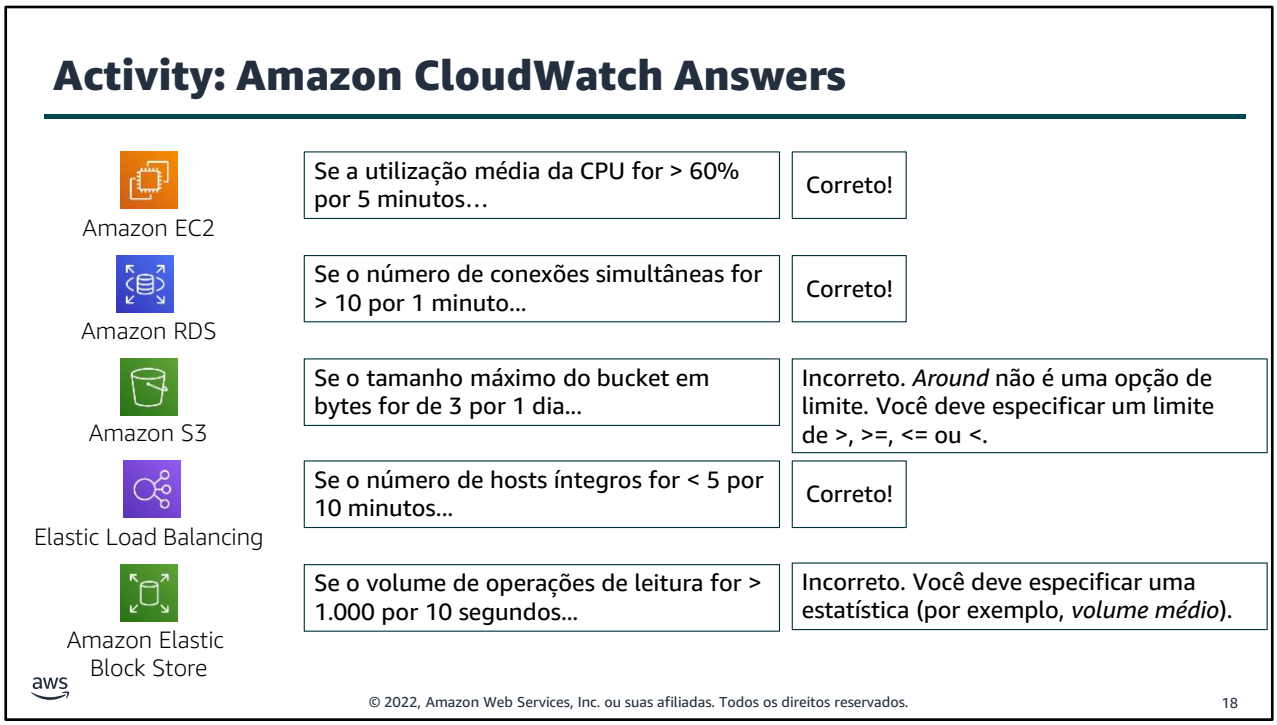
Para obter mais informações sobre como criar alarmes do CloudWatch, consulte os tópicos em Como usar alarmes na documentação da AWS.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Para essa atividade, veja se você consegue identificar quais são os alarmes corretos do CloudWatch. Para as que estão incorretas, consulte se você consegue identificar o erro.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Para essa atividade, veja se você consegue identificar quais são os alarmes corretos do CloudWatch. Para as que estão incorretas, consulte se você consegue identificar o erro.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Principais lições da Seção 2



- O Amazon CloudWatch ajuda você a monitorar em tempo real seus recursos da AWS e os aplicativos que você executa na AWS.
- O CloudWatch permite que você:
  - Colete e rastreie métricas padrão e personalizadas.
  - Defina alarmes para enviar notificações automaticamente para tópicos do SNS ou executar ações do Amazon EC2 Auto Scaling ou do Amazon EC2.
  - Defina regras que correspondam a alterações em seu ambiente da AWS e roteie esses eventos para destinos de processamento.

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 19

Algumas das principais lições desta seção do módulo são:

- O Amazon CloudWatch ajuda você a monitorar em tempo real seus recursos da AWS e os aplicativos que você executa na AWS.
- O CloudWatch permite que você:
  - Colete e rastreie métricas padrão e personalizadas.
  - Defina alarmes para enviar notificações automaticamente para tópicos do SNS ou executar ações do Amazon EC2 Auto Scaling ou do Amazon EC2 com base no valor da métrica ou expressão em relação a um limite ao longo de vários períodos.
  - Defina regras que correspondam a alterações em seu ambiente da AWS e roteie esses eventos para destinos de processamento.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

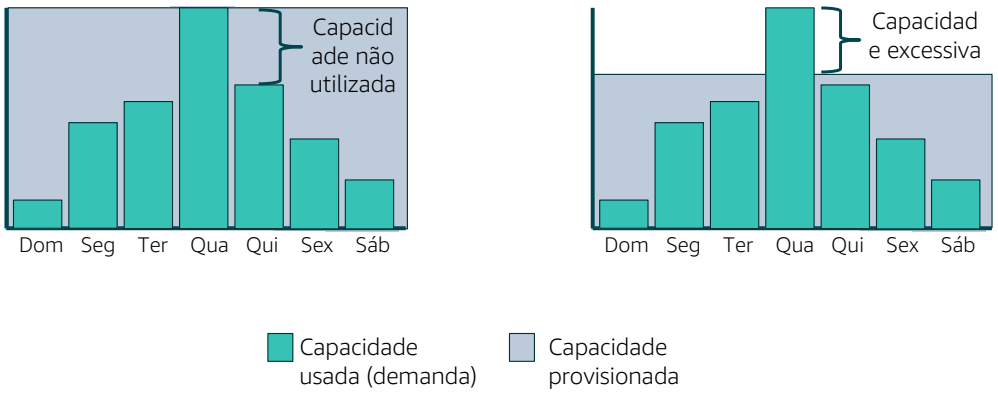


Seção 3: Amazon EC2 Auto Scaling

Ao executar seus aplicativos na AWS, você deseja garantir que sua arquitetura possa escalar para lidar com alterações na demanda. Nesta seção, você aprenderá a escalar automaticamente suas instâncias do EC2 com o Amazon EC2 Auto Scaling.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Por que a escalabilidade é importante?



© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

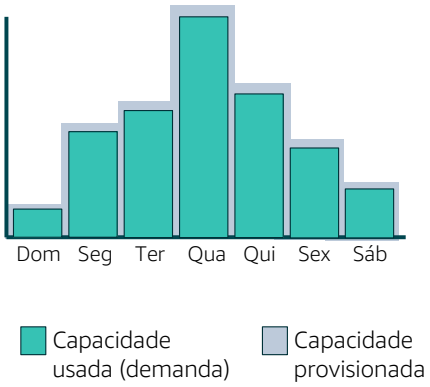
Escalabilidade é a capacidade de aumentar ou diminuir a capacidade de computação do seu aplicativo. Para entender por que a escalabilidade é importante, considere este exemplo de uma carga de trabalho que tem requisitos de recursos variáveis. Neste exemplo, a maior capacidade de recursos é necessária na quarta-feira, e a menor capacidade de recursos é necessária no domingo.

Uma opção é alocar capacidade mais do que suficiente para que você sempre possa atender à sua maior demanda - neste caso, quarta-feira. No entanto, isso significa que você está executando recursos que serão subutilizados na maioria dos dias da semana. Com essa opção, seus custos não são otimizados.

Outra opção é alocar menos capacidade para reduzir custos. Essa situação significa que você está abaixo da capacidade em determinados dias. Se você não resolver seu problema de capacidade, seu aplicativo pode apresentar performance insuficiente ou potencialmente ficar indisponível para os usuários.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Amazon EC2 Auto Scaling



- Ajuda a manter a disponibilidade do aplicativo
- Permite adicionar ou remover automaticamente instâncias do EC2 de acordo com as condições que você define
- Detecta instâncias do EC2 danificadas e aplicativos não íntegros e substitui as instâncias sem sua intervenção
- Fornece várias opções de escalabilidade - manual, programada, dinâmica ou sob demanda e preditiva

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 22

Na nuvem, como a capacidade computacional é um recurso programático, você pode adotar uma abordagem flexível de escalabilidade. O Amazon EC2 Auto Scaling é um serviço da AWS ajuda a manter a disponibilidade de aplicativos e permite aumentar ou reduzir instâncias do EC2 de maneira automática, de acordo com condições definidas por você. Você pode usar os recursos de gerenciamento de frota do EC2 Auto Scaling para manter a integridade e a disponibilidade da sua frota.

O Amazon EC2 Auto Scaling oferece várias maneiras de ajustar a escalabilidade para melhor atender às necessidades dos seus aplicativos. Você pode adicionar ou remover instâncias do EC2 manualmente, em uma programação, em resposta a mudanças na demanda ou em combinação com o AWS Auto Scaling para escalabilidade preditiva. Escalabilidade dinâmica e escalabilidade preditiva podem ser usadas juntas para escalar mais rapidamente.

Para saber mais sobre o Amazon EC2 Auto Scaling, consulte a página do produto Amazon EC2 Auto Scaling.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



A escalabilidade automática é útil para cargas de trabalho previsíveis - por exemplo, o tráfego semanal na empresa de varejo Amazon.com.

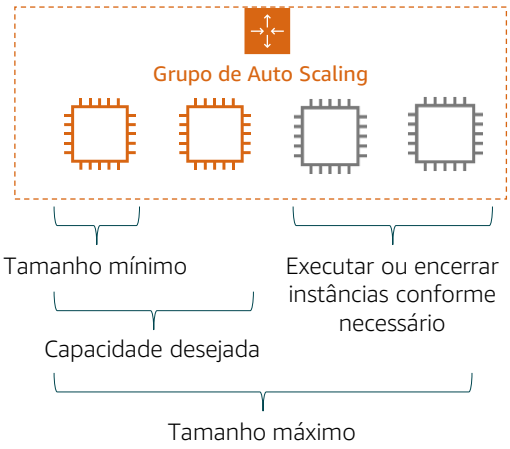
© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



A escalabilidade automática também é útil para escalabilidade dinâmica sob demanda. A Amazon.com enfrenta um pico sazonal no tráfego em novembro (na Black Friday e na Cyber Monday, que são dias no final de novembro, quando os varejistas dos EUA realizam grandes vendas). Se a Amazon provisiona uma capacidade fixa para acomodar o uso mais alto, 76% dos recursos ficam ociosos durante a maior parte do ano. A escalabilidade de capacidade é necessária para oferecer suporte às demandas flutuantes do serviço. Sem escalabilidade, os servidores poderiam falhar devido à saturação, e a empresa perderia a confiança do cliente.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Grupos de Auto Scaling



Um **grupo de Auto Scaling** é um conjunto de instâncias do EC2 que são tratadas como um agrupamento lógico para fins de escalabilidade automática e gerenciamento.

aws

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 25

Um grupo de Auto Scaling é um conjunto de instâncias do Amazon EC2 que são tratadas como um agrupamento lógico para fins de escalabilidade e gerenciamento automáticos. O tamanho de um grupo de Auto Scaling depende do número de instâncias definidas como a *capacidade desejada*. Você pode ajustar seu tamanho para atender à demanda manualmente ou usando a escalabilidade automática.

Você pode especificar o número mínimo de instâncias em cada grupo de Auto Scaling, e o Amazon EC2 Auto Scaling foi projetado para evitar que seu grupo fique abaixo desse tamanho. Você pode especificar o número máximo de instâncias em cada grupo de Auto Scaling, e o Amazon EC2 Auto Scaling foi projetado para evitar que seu grupo fique acima desse tamanho. Se você especificar a capacidade desejada, seja ao criar o grupo ou a qualquer momento posteriormente, o Amazon EC2 Auto Scaling será projetado para ajustar o tamanho do grupo para que ele tenha o número especificado de instâncias. Se você especificar políticas de escalabilidade, o Amazon EC2 Auto Scaling poderá iniciar ou encerrar instâncias à medida que a demanda o aplicativo aumenta ou diminui.

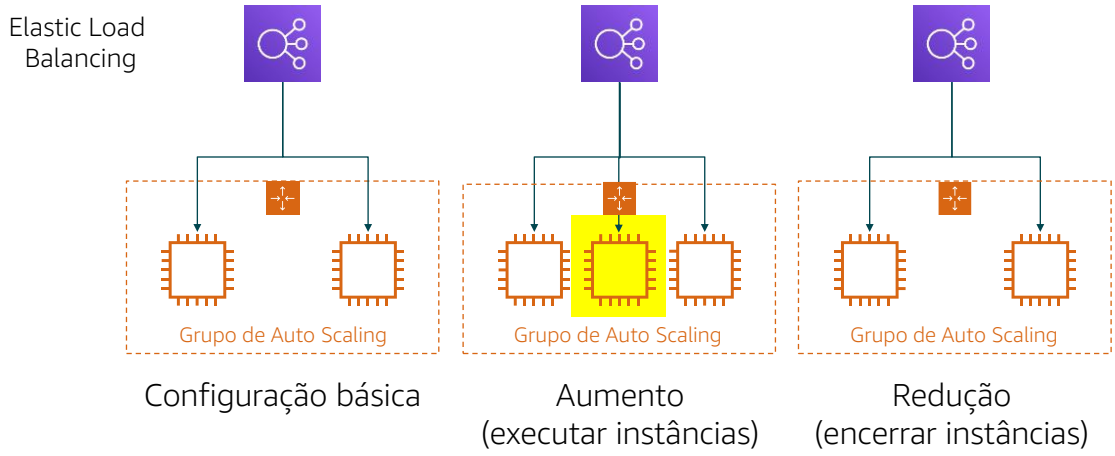
Por exemplo, esse grupo de Auto Scaling tem um tamanho mínimo de uma instância, uma capacidade desejada de duas instâncias e um tamanho máximo de quatro instâncias. As políticas de escalabilidade que você define ajustam o número de instâncias, em seu número mínimo e máximo de instâncias, com base nos critérios que

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

você especifica.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

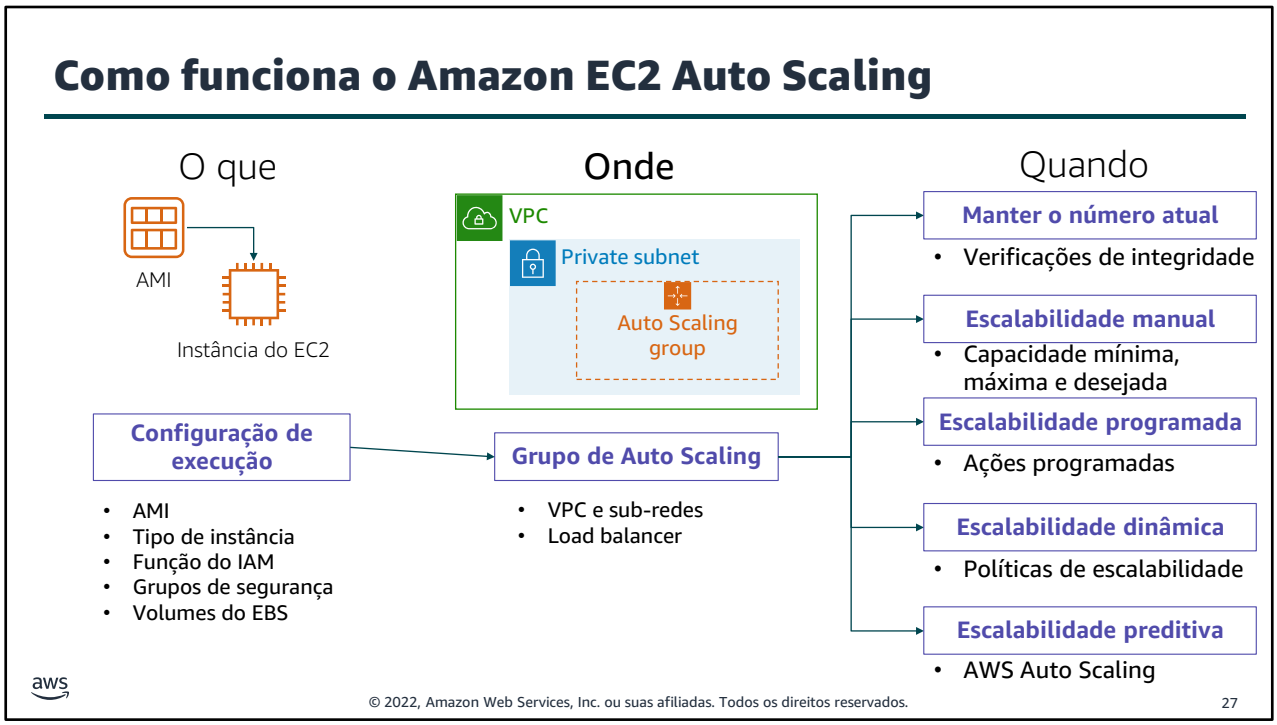
Expansão versus redução



© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Com o Amazon EC2 Auto Scaling, a execução de instâncias é chamada de *aumento* e o encerramento de instâncias é chamado de *redução*.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Para executar instâncias do EC2, um grupo de Auto Scaling usa uma configuração de execução, que é um modelo de configuração de instância. Você pode pensar em uma configuração de execução como *o que* você está escalando. Ao criar uma configuração de execução, você especifica informações para as instâncias. As informações especificadas incluem o ID da Imagem de máquina da Amazon (AMI), o tipo de instância, a função do AWS Identity and Access Management (IAM), armazenamento adicional, um ou mais security groups e qualquer volume do Amazon Elastic Block Store (Amazon EBS).

Você define o número mínimo e máximo de instâncias e a capacidade desejada de seu grupo de Auto Scaling. Em seguida, você o executa em uma sub-rede dentro de uma VPC (você pode pensar nisso como *onde* você está escalando). O Amazon EC2 Auto Scaling integra-se ao Elastic Load Balancing para que seja possível associar um ou mais load balancers a um grupo de Auto Scaling existente. Depois de associar o load balancer, ele registrará automaticamente as instâncias no grupo e distribuirá o tráfego

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

de entrada entre as instâncias.

Por fim, você especifica *quando* deseja que o evento de escalabilidade ocorra. Você tem muitas opções de escalabilidade:

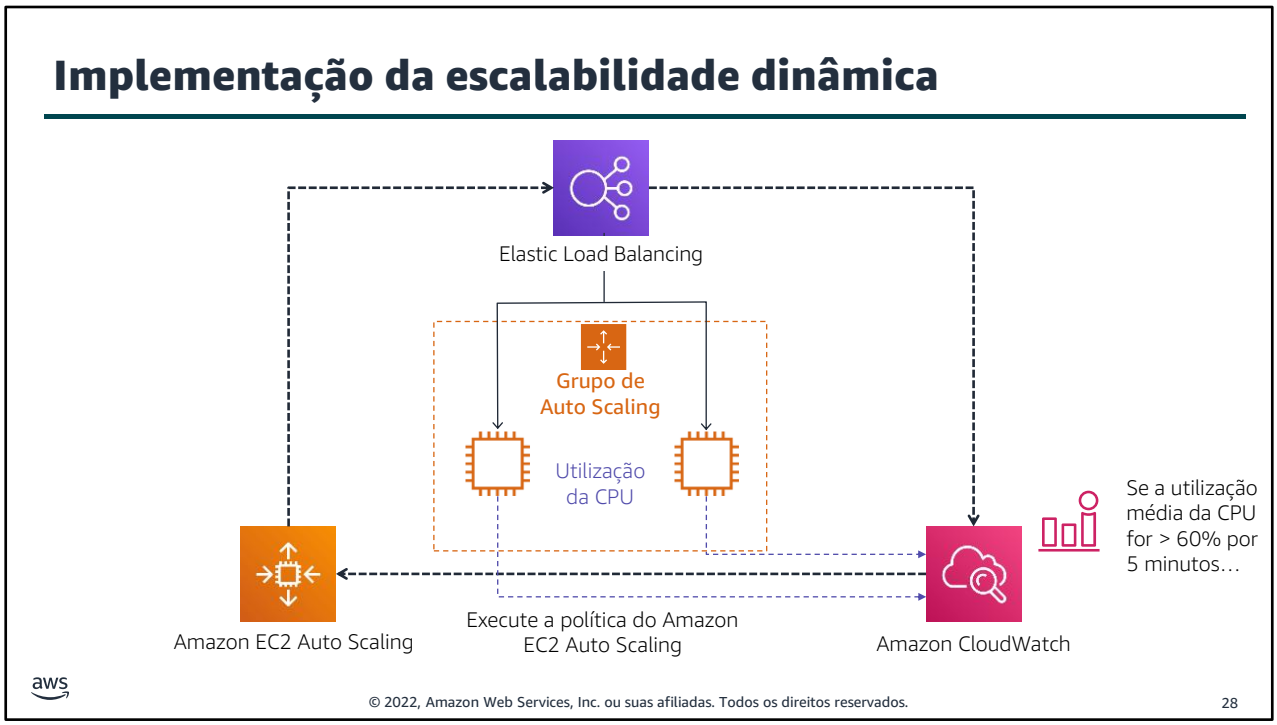
- *Manter os níveis de instância atuais em todos os momentos* - Você pode configurar seu grupo de Auto Scaling para manter um número especificado de instâncias em execução em todos os momentos. Para manter os níveis de instância atuais, o Amazon EC2 Auto Scaling executa uma verificação de integridade periódica nas instâncias em execução em um grupo de Auto Scaling. Quando o Amazon EC2 Auto Scaling encontra uma instância não íntegra, ele encerra essa instância e executa uma nova.
- Escalabilidade manual - Comescalabilidade anual, você especifica apenas a alteração na capacidade máxima, mínima ou desejada de seu grupo de Auto Scaling.
- Escalabilidade programada - Com a escalabilidade programada, as ações de escalabilidade são executadas automaticamente como uma função de data e hora. Isso é útil para cargas de trabalho previsíveis quando você sabe exatamente quando aumentar ou diminuir o número de instâncias em seu grupo do. Por exemplo, digamos que toda semana o tráfego para seu aplicativo Web começa a aumentar na quarta-feira, permanece alto na quinta-feira e começa a diminuir na sexta-feira. Você pode planejar as ações de escalabilidade com base nos padrões de tráfego previsível de seu aplicativo Web. Para implementar a escalabilidade programada, crie uma ação programada.

Escalabilidade dinâmica sob demanda - Uma maneira mais avançada de escalar seus recursos permite definir parâmetros que controlam o processo de escalabilidade. Por exemplo, você tem um aplicativo web que atualmente é executado em duas instâncias e deseja que a utilização de CPU do grupo de Auto Scaling permaneça próxima de 50% quando a carga no aplicativo mudar. Essa opção é útil para escalabilidade em resposta a alterações de condições, quando você não sabe quando essas condições mudarão. A escalabilidade dinâmica oferece capacidade extra para lidar com picos de tráfego sem manter uma quantidade excessiva de recursos ociosos. Você pode configurar seu grupo de Auto Scaling para escalar automaticamente a fim de atender a essa necessidade. O tipo de política de escalabilidade determina como a ação de escalabilidade é executada. Você pode usar o Amazon EC2 Auto Scaling com o Amazon CloudWatch para acionar a política de escalabilidade em resposta a um alarme.

- Escalabilidade preditiva - Você pode usar o Amazon EC2 Auto Scaling com o AWS Auto Scaling para implementar escalabilidade preditiva, onde sua capacidade é dimensionada de acordo com a demanda prevista. A escalabilidade preditiva usa dados coletados do uso real do EC2, e os dados são mais informados por bilhões de pontos de dados extraídos de nossas próprias observações. Em seguida, a AWS usa modelos de Machine Learning bem treinados para prever o tráfego esperado (e o uso do EC2), incluindo padrões diários e semanais. O modelo precisa de pelo menos 1 dia de dados históricos para começar a fazer previsões. Ele é reavaliado a cada 24 horas para criar uma previsão para as próximas 48 horas. O processo de previsão produz um plano de escalabilidade que pode comandar um ou mais grupos de instâncias do EC2 escaladas automaticamente.

Para saber mais sobre essas opções, consulte Scaling the Size of Your Auto Scaling Group na documentação da AWS.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Uma configuração comum para implementar a escalabilidade dinâmica é criar um alarme do CloudWatch baseado nas informações de performance das instâncias do EC2 ou do load balancer. Quando um limite de performance é violado, um alarme do CloudWatch aciona um evento de escalabilidade automática que pode ser expandido ou escalado em instâncias do EC2 no grupo de Auto Scaling.

Para entender como isso funciona, considere este exemplo:

- Você cria um alarme do Amazon CloudWatch para monitorar a utilização da CPU em toda a frota de instâncias do EC2 e executar políticas de escalabilidade automática se a utilização média da CPU em toda a frota ficar acima de 60% por 5 minutos.
- O Amazon EC2 Auto Scaling instancia uma nova instância do EC2 em seu grupo de Auto Scaling com base na configuração de execução que você cria.
- Depois que a nova instância é adicionada, o Amazon EC2 Auto Scaling faz uma chamada para o Elastic Load Balancing para registrar a nova instância do EC2 nesse grupo de Auto Scaling.
- Em seguida, o Elastic Load Balancing executa as verificações de integridade necessárias e começa a distribuir o tráfego para essa instância. O Elastic Load Balancing roteia o tráfego entre instâncias do EC2 e alimenta métricas para o Amazon CloudWatch.

O Amazon CloudWatch, o Amazon EC2 Auto Scaling e o Elastic Load Balancing

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

funcionam bem individualmente. Juntas, no entanto, elas se tornam mais poderosas e aumentam o controle e a flexibilidade sobre como seu aplicativo lida com a demanda do cliente.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

AWS Auto Scaling



AWS Auto Scaling

- Monitora os aplicativos e ajusta automaticamente a capacidade para manter uma performance constante e previsível pelo menor custo possível
- Fornece uma interface de usuário simples e eficiente que permite criar planos de escalabilidade para recursos do, incluindo -
  - Instâncias do Amazon EC2 e frotas spot
  - Tarefas do Amazon Elastic Container Service (Amazon ECS)
  - Índices e tabelas do Amazon DynamoDB
  - Réplicas do Amazon Aurora

aws

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 29

Até agora, você aprendeu sobre a escalabilidade de instâncias do EC2 com o Amazon EC2 Auto Scaling. Você também aprendeu que pode usar o Amazon EC2 Auto Scaling com o AWS Auto Scaling para executar escalabilidade preditiva.

O AWS Auto Scaling é um serviço separado que monitora seus aplicativos. Ele ajusta automaticamente a capacidade para manter uma performance estável e previsível pelo menor custo possível. O serviço fornece uma interface de usuário simples e eficiente que permite criar planos de escalabilidade para recursos do, incluindo:

- Instâncias do Amazon EC2 e frotas spot
- Tarefas do Amazon Elastic Container Service (Amazon ECS)
- Índices e tabelas do Amazon DynamoDB
- Réplicas do Amazon Aurora

Se você já usa o Amazon EC2 Auto Scaling para escalar dinamicamente suas instâncias do EC2, agora pode usá-lo com o AWS Auto Scaling para escalar recursos adicionais a outros serviços da AWS.

Para saber mais informações sobre o AWS Auto Scaling, consulte AWS Auto Scaling.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Principais lições da Seção 3



- A escalabilidade permite que você responda rapidamente a alterações nas necessidades de recursos.
- O Amazon EC2 Auto Scaling mantém a disponibilidade do aplicativo adicionando ou removendo automaticamente instâncias do EC2.
- Um grupo de Auto Scaling é um conjunto de instâncias do EC2.
- Uma configuração de execução é um modelo de configuração de instância.
- A escalabilidade dinâmica usa o Amazon EC2 Auto Scaling, o CloudWatch e o Elastic Load Balancing.
- O AWS Auto Scaling é um serviço separado do Amazon EC2 Auto Scaling.

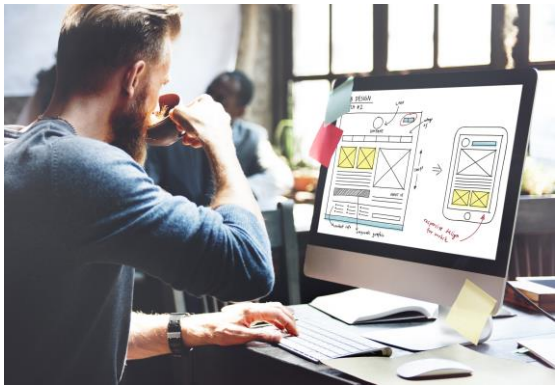
© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 30

Algumas das principais lições desta seção do módulo são:
- A escalabilidade permite que você responda rapidamente a alterações nas necessidades de recursos.
- O Amazon EC2 Auto Scaling ajuda você a manter a disponibilidade dos aplicativos e permite que você adicione ou remova automaticamente instâncias do EC2 de acordo com suas cargas de trabalho.
- Um grupo de Auto Scaling é um conjunto de instâncias do EC2.
- Uma configuração de execução é um modelo de configuração de instância.
- Você pode implementar a escalabilidade dinâmica com o Amazon EC2 Auto Scaling, o Amazon CloudWatch e o Elastic Load Balancing.

O AWS Auto Scaling é um serviço separado que monitora seus aplicativos e ajusta automaticamente a capacidade para os seguintes recursos:
- Instâncias do Amazon EC2 e frotas spot
- Tarefas do Amazon ECS
- Índices e tabelas do Amazon DynamoDB
- Réplicas do Amazon Aurora

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Laboratório 6: Escale e faça o balanceamento de carga da arquitetura

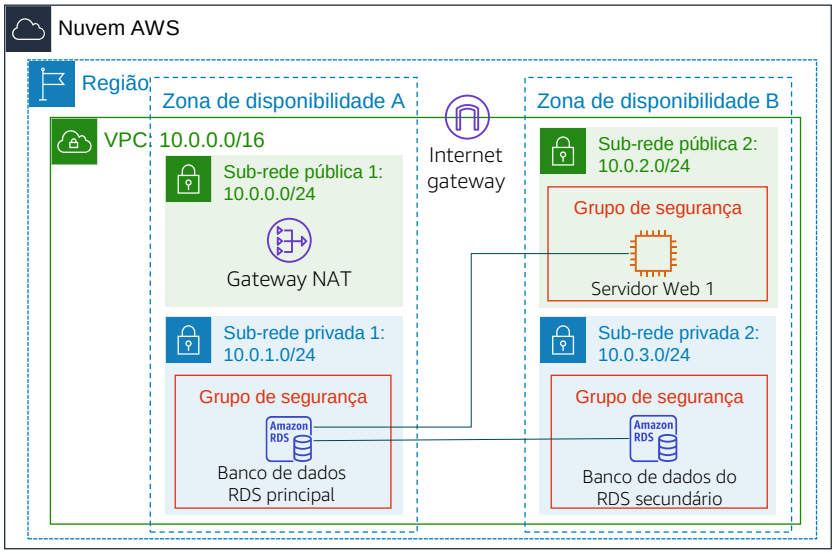


© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 31

Agora, você concluirá o laboratório 6: escalar e balancear sua arquitetura.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Laboratório 6: Cenário



Neste laboratório, você usará o Elastic Load Balancing e o Amazon EC2 Auto Scaling para balancear a carga e escalar sua infraestrutura. Você começará com a infraestrutura fornecida.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Laboratório 6: Tarefas

- Criar uma nova Imagem de máquina da Amazon (AMI) por meio de instância em execução.
- Criar um Application Load Balancer.
- Criar uma configuração de execução e um grupo de Auto Scaling.
- Escalar automaticamente novas instâncias em uma sub-rede privada.
- Criar alarmes do Amazon CloudWatch e monitorar a performance da sua infraestrutura.

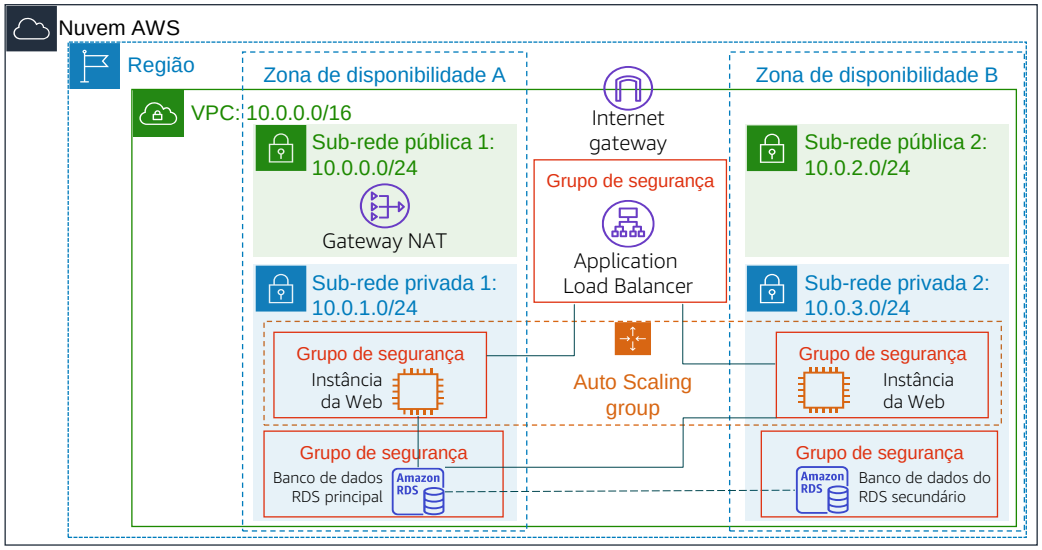
aws

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 33

Neste laboratório, você concluirá as seguintes tarefas:
- Criar uma nova Imagem de máquina da Amazon (AMI) por meio de instância em execução.
- Criar um Application Load Balancer.
- Criar uma configuração de execução e um grupo de Auto Scaling.
- Escalar automaticamente novas instâncias em uma sub-rede privada.
- Criar alarmes do Amazon CloudWatch e monitorar a performance da sua infraestrutura.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

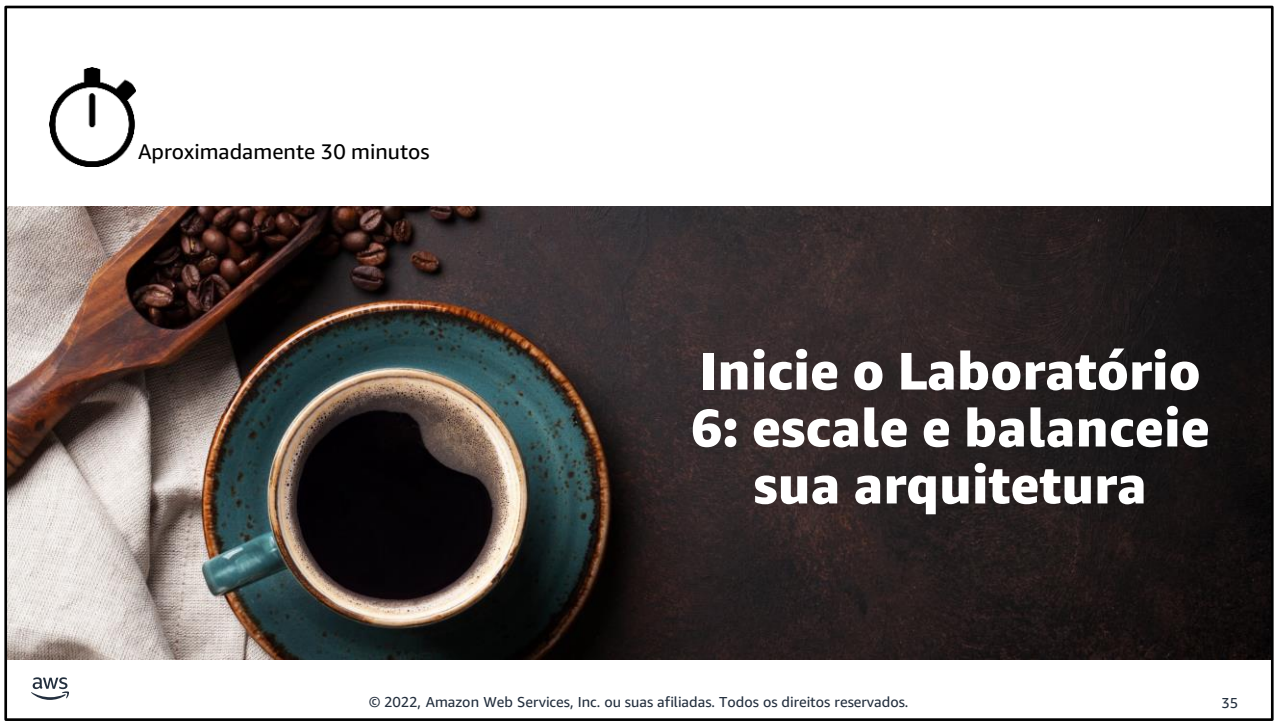
Laboratório 6: Produto final



© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

34

O diagrama resume o que você terá criado depois de concluir o laboratório.



Agora é hora de iniciar o laboratório. Você deve levar aproximadamente 30 minutos para concluí-lo.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Resumo do laboratório: Principais lições



© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 36

Neste laboratório, você:

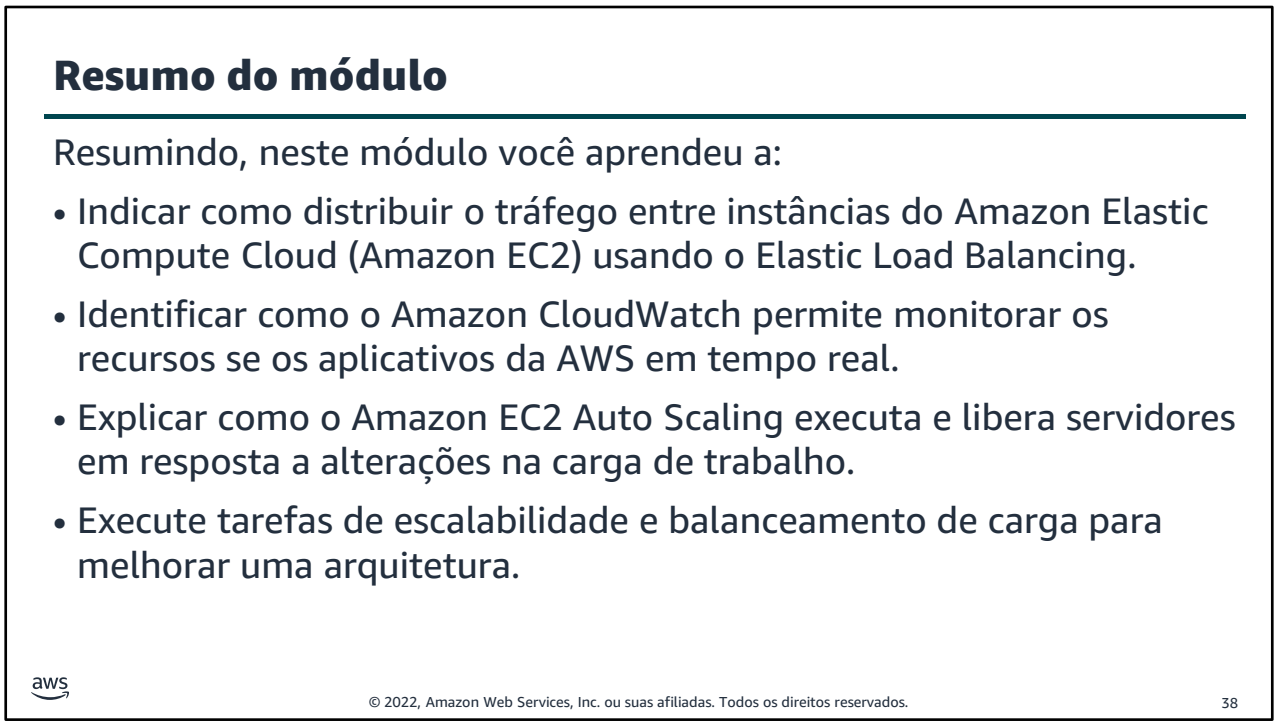
- Criou uma nova Imagem de máquina da Amazon (AMI) por meio de instância em execução.
- Criação de um load balancer.
- Criou uma configuração de execução e um grupo de Auto Scaling.
- Escalou automaticamente novas instâncias em uma sub-rede privada.
- Criou alarmes do Amazon CloudWatch e monitorou a performance da sua infraestrutura.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Agora é hora de revisar o módulo e encerrar com um teste de conhecimento e discussão sobre uma pergunta simulada do teste de certificação.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Resumindo, neste módulo você aprendeu a:
- Indicar como distribuir o tráfego entre instâncias do Amazon Elastic Compute Cloud (Amazon EC2) usando o Elastic Load Balancing.
- Identificar como o Amazon CloudWatch permite que você monitore recursos e aplicativos da AWS em tempo real
- Explicar como o Amazon EC2 Auto Scaling executa e libera servidores em resposta a alterações na carga de trabalho.
- Execute tarefas de escalabilidade e balanceamento de carga para melhorar uma arquitetura.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Conclua o teste de conhecimento



© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

Conclua o teste de conhecimento deste módulo.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

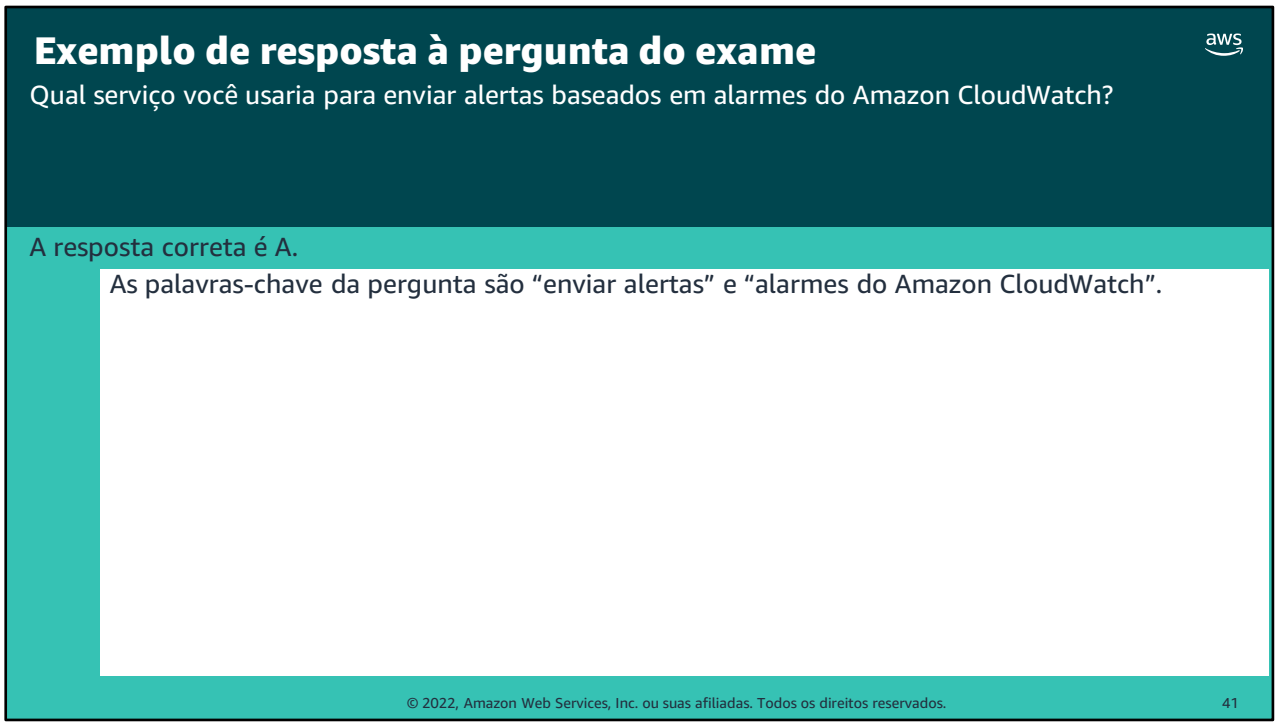
Exemplo de pergunta do exame

Qual serviço você usaria para enviar alertas baseados em alarmes do Amazon CloudWatch?

Opção	Resposta
A	Amazon Simple Notification Service
B	AWS CloudTrail
C	AWS Trusted Advisor
D	Amazon Route 53

© 2022, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados. 40

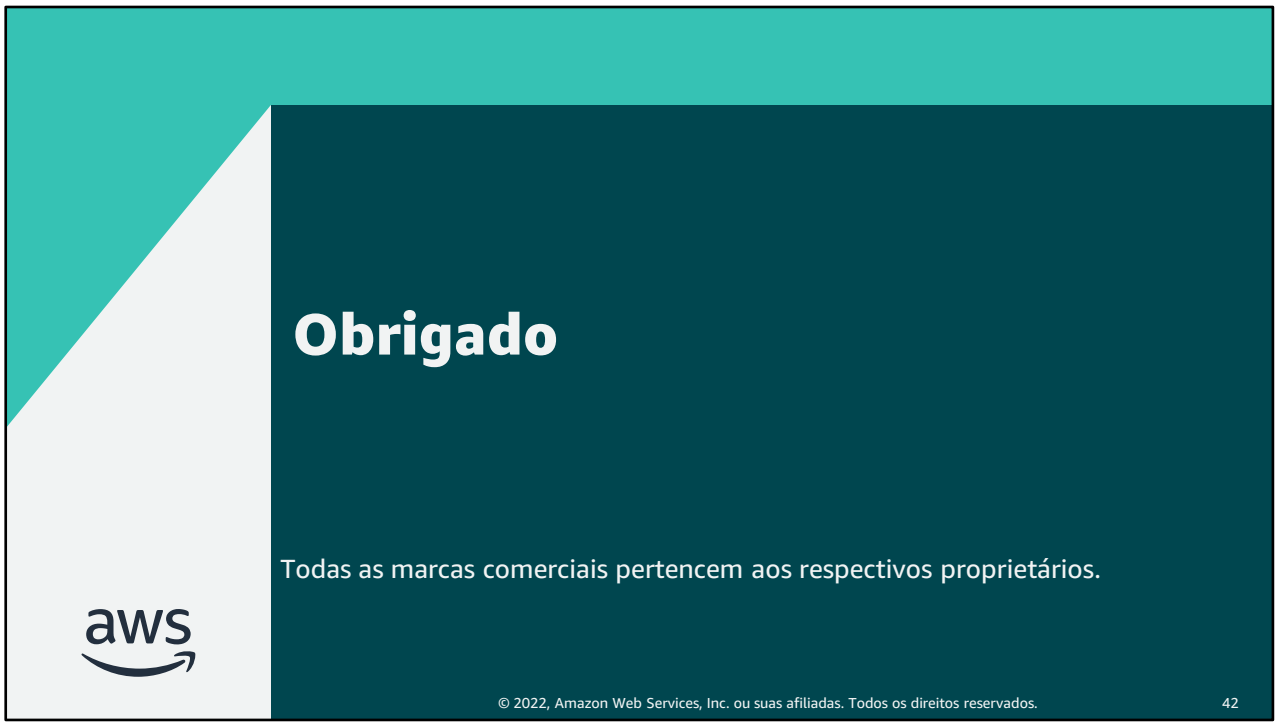
Examine as opções de respostas e descarte-as com base nas palavras-chave.



Estas são as palavras-chave a serem reconhecidas: **“enviar alertas” e “alarmes do Amazon CloudWatch”.**

A resposta correta é A.

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.



Agradecemos a sua participação!

© 2024, Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.