

Notas de Aula – Redes de Computadores

2026

Estas notas organizam o conteúdo por encontro e combinam o planejamento da disciplina com os registros do quadro. O objetivo é oferecer um roteiro de revisão; os slides e o livro-texto continuam sendo as referências principais.

Aula	Data	Tema	Cobertura
1	12/08	Curso e Internet	Organização, avaliação, Internet e protocolos
2	14/08	Borda e acesso	Hosts, AP/BS, redes de acesso e comutação
3	19/08	Núcleo e medição	Atrasos, núcleo da rede e <i>packet pair</i>
4	21/08	Bloqueio	Multiplexação estatística, binomial e Poisson
5	26/08	Bloqueio e filas	Caravanas de carros e início de filas
6	28/08	Filas	M/M/1
7	2/09	Revisão	Teste ao final da aula
8	4/09	Atrasos e medições	Divisão em camadas, segurança
9	9/09	HTTP	Camada de aplicação

AULA 1 | 12/08/2026 – quarta-feira**Apresentação do curso e uma primeira visão da Internet**

Cobertura: introdução ao curso e início do Capítulo 1.

1.1 Organização da disciplina

- Professor: Daniel Sadoc Menasché; contato registrado no quadro: `sadoc@ic.ufrj.br`.
- Classroom: avisos, materiais e atividades.
- Planilha da turma: presenças, agenda e trabalhos em grupo.
- A avaliação combina provas, exercícios/minitests, trabalho em grupo e eventuais bônus.

Se MP é a média das duas maiores notas entre $P1$, $P2$ e $P3$, MEX é a nota dos exercícios/minitests e NT é a nota do trabalho em grupo, então

$$MF = 0,70 MP + 0,15 MEX + 0,15 NT + \text{bônus}.$$

1.2 Roteiro do Capítulo 1

- 1.1 – O que é a Internet?
- 1.2 – A borda da rede (*network edge*).
- 1.3 – O núcleo da rede (*network core*).
- 1.4 – Desempenho: atraso, perda e vazão.
- 1.5 – Pilha de protocolos e modelos de serviço.

1.3 O que é a Internet?**1.3.1 Visão física**

A Internet é uma rede de redes que interliga bilhões de dispositivos. Os dispositivos nas extremidades são chamados **hosts** ou **sistemas finais**; eles se comunicam por enlaces e por equipamentos de comutação, como roteadores e switches.

1.3.2 Visão lógica ou de serviço

A Internet também é uma infraestrutura que oferece serviços de comunicação a aplicações distribuídas. As aplicações usam interfaces de programação (APIs) e protocolos para trocar dados sem precisar conhecer todos os detalhes internos da rede.

Ideia-chave. A visão física responde “quais elementos compõem a rede?”; a visão de serviço responde “o que a rede oferece às aplicações?”.

1.4 Protocolos

Um protocolo é um conjunto de regras que governa a comunicação entre entidades. Ele estabelece:

- a **sintaxe**: formato e ordem dos campos de uma mensagem;
- a **semântica**: significado dos campos e das mensagens, que caracteriza as ações, ou seja, o que fazer ao transmitir ou receber cada mensagem.

1.5 Primeira ponte com estatística

Um parâmetro, como a média populacional μ , é desconhecido. A partir de observações $D_1, D_2, \dots, D_n$, calculamos uma estatística para estimá-lo. A média amostral é

$$\hat{\mu} = \frac{D_1 + D_2 + \dots + D_n}{n}.$$

Essa linguagem reaparece ao estimar atraso médio, vazão disponível, perda e capacidade de um caminho.

Para revisar

1. Dê um exemplo da Internet sob a visão física e outro sob a visão de serviço.
2. Explique a diferença entre sintaxe, semântica e ação em um protocolo.
3. Por que uma média obtida de poucas medições é um estimador, e não necessariamente o valor real do parâmetro?

AULA 2 | 14/08/2026 – sexta-feira**Borda da rede, redes de acesso e compartilhamento de recursos**

Cobertura: slides até o 21 (inclusive), com ênfase em redes de acesso e comutação.

2.1 Borda da rede

Na borda estão os hosts ou sistemas finais: computadores, telefones, servidores, sensores e outros dispositivos que executam aplicações. A **rede de acesso** conecta um sistema final ao primeiro roteador da rede do provedor.

2.2 Acesso sem fio: AP e estação-base

- No Wi-Fi, o host se associa a um ponto de acesso (AP), tipicamente seguindo a família IEEE 802.11.
- Em uma rede celular, o host se comunica com uma estação-base (BS), por exemplo em uma rede 5G.
- Nos dois casos existe um trecho de rádio, mas a arquitetura, o alcance, a mobilidade e a gestão dos recursos são diferentes.

Um meio é **guiado** quando o sinal percorre cabo de cobre ou fibra, e **não guiado** quando se propaga pelo ar.

2.3 Tecnologias de acesso residencial

- **HFC:** combina fibra na rede do provedor com cabo coaxial no trecho de distribuição; No coaxial, usa-se FDM para dividir a frequência de *upstream* e *downstream* de dados; usuários vizinhos compartilham a mesma frequência de *upstream* por TDMA.
- **DSL:** usa o par de cobre da linha telefônica até a central; o acesso é dedicado nesse trecho físico.
- **Rede doméstica:** normalmente combina modem/ONT, roteador, Ethernet e Wi-Fi.

2.4 Comutação de circuitos e de pacotes

Na comutação de circuitos, recursos são reservados antes da transmissão. Na comutação de pacotes, os dados são divididos em pacotes que compartilham enlaces e buffers.

Aspecto	Circuitos	Pacotes
Recursos	Reservados para a conexão	Compartilhados sob demanda
Uso	Previsível após admissão	Estatístico e variável
Ociosidade	Recursos podem ficar ociosos	Capacidade aproveitada por outros fluxos
Sobrecarga	Nova conexão pode ser bloqueada	Podem surgir fila, atraso e perda

Recursos reservados podem ser separados por frequência (FDM), tempo (TDM) ou códigos (CDMA).

2.5 FDM, TDM vs FDMA e TDMA

FDM e TDM são técnicas de **multiplexação**: dividem os recursos de um enlace por tempo ou frequência. FDMA e TDMA são técnicas de **acesso múltiplo**: definem como diferentes usuários ou transmissores compartilham um meio comum.

- **FDM (Frequency Division Multiplexing)**: divide a largura de banda do meio em diferentes faixas de frequência. Cada sinal utiliza uma faixa distinta e as transmissões podem ocorrer simultaneamente.
- **TDM (Time Division Multiplexing)**: divide o acesso ao meio em intervalos de tempo. Cada fluxo utiliza o enlace durante determinados intervalos, compartilhando o mesmo recurso ao longo do tempo.
- **FDMA (Frequency Division Multiple Access)**: aplica a divisão por frequência ao compartilhamento de um meio entre múltiplos usuários. Cada usuário recebe uma faixa de frequência para transmitir.
- **TDMA (Time Division Multiple Access)**: aplica a divisão por tempo ao compartilhamento de um meio entre múltiplos usuários. Cada usuário recebe determinados intervalos de tempo para transmitir.

Assim, a principal diferença está tanto no **recurso dividido** quanto no **objetivo da técnica**: FDM e TDM descrevem como um enlace pode ser multiplexado, enquanto FDMA e TDMA descrevem como múltiplos usuários podem acessá-lo.

Técnica	Recurso dividido	Aplicação principal
FDM	Frequência	Multiplexação de sinais
TDM	Tempo	Multiplexação de fluxos
FDMA	Frequência	Acesso de múltiplos usuários
TDMA	Tempo	Acesso de múltiplos usuários

No caso de uma rede **HFC**, essas técnicas podem aparecer em conjunto. O espectro disponível no cabo coaxial é dividido por **FDM**, reservando faixas de frequência distintas para *upstream* e *downstream*. Dentro da faixa de *upstream*, que é compartilhada por vários modems, o acesso pode ser organizado por **TDMA**, de modo que diferentes usuários transmitam em intervalos de tempo distintos. Dessa forma, FDM realiza a separação por frequência, enquanto TDMA organiza o compartilhamento temporal da faixa de *upstream*.

Para revisar

1. Identifique o AP e o roteador de borda em uma rede doméstica.
2. Em que sentido a capacidade de uma rede HFC pode ser compartilhada?
3. Compare a chegada de um novo usuário a um circuito sem capacidade e a um enlace de pacotes congestionado.

AULA 3 | 19/08/2026 – quarta-feira**Atrasos, núcleo da rede e técnica de *packet pair***

Cobertura planejada: slides até o 35 (exclusive) e técnica de *packet pair*.

3.1 Componentes do atraso

Para um pacote de L bits transmitido por um enlace de taxa R bits/s, o atraso de transmissão é

$$d_{\text{trans}} = \frac{L}{R}.$$

Para um enlace de comprimento d e velocidade de propagação s , o atraso de propagação é

$$d_{\text{prop}} = \frac{d}{s}.$$

O primeiro depende do tamanho do pacote e da taxa do enlace; o segundo depende da distância e do meio físico.

3.2 Núcleo da rede

- **Encaminhamento:** mover um pacote da interface de entrada para a interface de saída apropriada.
- **Roteamento:** calcular ou aprender os caminhos usados nas decisões de encaminhamento.
- Em *store-and-forward*, o roteador recebe o pacote antes de transmiti-lo no enlace seguinte.
- Se os pacotes chegam mais depressa do que podem sair, surgem fila, atraso de enfileiramento e, com buffer finito, perda.

3.3 Técnica de *packet pair*

Dois pacotes de mesmo tamanho L são enviados muito próximos. O gargalo de taxa R_b tende a impor uma dispersão Δ entre eles:

$$\Delta \approx \frac{L}{R_b} \quad \implies \quad \hat{R}_b \approx \frac{L}{\Delta}.$$

Tráfego concorrente, filas, escalonamento e resolução do relógio introduzem erro. A técnica estima principalmente a capacidade do gargalo; capacidade e largura de banda disponível não são sinônimos.

3.3.1 Comparação entre *store-and-forward* e *cut-through*

Considere N pacotes de tamanho L atravessando H enlaces idênticos, cada um com taxa R . Ignorando filas e processamento, na comutação *store-and-forward* temos

$$T_{\text{SF}} = (N + H - 1) \frac{L}{R} + \sum_{i=1}^H d_{\text{prop},i}.$$

O termo $H - 1$ aparece porque o primeiro pacote deve ser completamente recebido em cada roteador antes de ser retransmitido.




Figure 1: Comutação *store-and-forward*. O roteador somente começa a transmitir um pacote depois de recebê-lo completamente.

3.3.1.1 Comutação *cut-through*

Na comutação *cut-through*, o roteador pode começar a encaminhar um pacote assim que recebe cabeçalho suficiente para determinar a interface de saída.

No caso ideal, com enlaces de mesma taxa e tempo de processamento desprezível,

$$T_{CT} = N \frac{L}{R} + \sum_{i=1}^H d_{prop,i}.$$

O tempo de transmissão L/R é multiplicado pelo número de pacotes N , mas não pelo número de enlaces H . Os roteadores encaminham os bits como um pipeline contínuo.




Figure 2: Comutação *cut-through*. No caso ideal, o atraso de transmissão é multiplicado pelo número de pacotes, mas não pelo número de enlaces.

3.3.2 Técnica de *packet pair*

Considere dois pacotes de tamanho L enviados consecutivamente por um caminho com dois enlaces. Sejam R_1 e R_2 as capacidades dos enlaces.

A dispersão entre os pacotes depois do primeiro enlace é

$$\Delta_{\text{in}} = \frac{L}{R_1}.$$

A relação entre R_1 e R_2 determina se o segundo pacote precisará esperar no roteador.

3.3.2.1 Primeiro enlace mais rápido: $R_1 > R_2$

Neste caso,

$$\frac{L}{R_1} < \frac{L}{R_2}.$$

O pacote 2 chega ao roteador antes que a transmissão do pacote 1 pelo segundo enlace tenha terminado. Portanto, o pacote 2 espera na fila do roteador.

O atraso de fila do segundo pacote é

$$W_{q,2} = \frac{L}{R_2} - \frac{L}{R_1}.$$

Na saída, a dispersão passa a ser

$$\Delta_{\text{out}} = \frac{L}{R_2}.$$




Figure 3: *Packet pair* quando a capacidade do primeiro enlace é maior. O enlace 2 aumenta a dispersão entre os pacotes.

3.3.2.2 Primeiro enlace mais lento: $R_1 < R_2$

Agora,

$$\frac{L}{R_1} > \frac{L}{R_2}.$$

O segundo enlace termina de transmitir o pacote 1 antes da chegada completa do pacote 2. Portanto, não há espera no roteador.

A dispersão observada na saída permanece

$$\Delta_{\text{out}} = \frac{L}{R_1}.$$

Se os dois pacotes ficam prontos simultaneamente na origem, o pacote 2 precisa esperar a transmissão do pacote 1 pelo primeiro enlace:

$$W_{q,2}^{(\text{origem})} = \frac{L}{R_1}.$$

Essa é uma espera na origem, e não uma fila produzida no roteador intermediário.




Figure 4: *Packet pair* quando a capacidade do primeiro enlace é menor. O segundo enlace fica temporariamente ocioso entre os pacotes.

3.3.2.3 Interpretação dos dois casos

Os dois exemplos podem ser resumidos por

$$\Delta_{\text{out}} = \max \left\{ \frac{L}{R_1}, \frac{L}{R_2} \right\} = \frac{L}{\min\{R_1, R_2\}}.$$

Portanto,

$$\hat{R}_{\text{gargalo}} = \frac{L}{\Delta_{\text{out}}}.$$

No caso ideal, a dispersão observada entre os dois pacotes revela a capacidade do enlace mais lento. Na prática, tráfego concorrente pode introduzir atrasos adicionais de fila e alterar a dispersão observada.

Para revisar

1. Diferencie atraso de transmissão e atraso de propagação.
2. Por que o gargalo aumenta a separação entre pacotes consecutivos?
3. Por que é prudente repetir a medição e usar estatísticas robustas?

Atrasos, *packet pair* e tamanho ótimo de pacote

Notas adicionais – aula de 19 de agosto de 2026

3.4 Atraso de transmissão e atraso de propagação

Considere um pacote com L bits e um enlace com taxa R bits/s. O **atraso de transmissão** (ou de serialização) é o tempo necessário para colocar todos os bits do pacote no enlace:

$$d_{\text{trans}} = \frac{L}{R}.$$

Se o enlace possui distância d e o sinal se propaga no meio com velocidade s , o **atraso de propagação** é

$$d_{\text{prop}} = \frac{d}{s}.$$

Diferença essencial. L/R depende do tamanho do pacote e da taxa do enlace. d/s depende da distância e do meio físico. Um enlace pode ter alta taxa e grande atraso de propagação, como ocorre em enlaces via satélite.

Para um caminho com H enlaces, o atraso fim a fim de um pacote pode ser representado por

$$d_{\text{fim-a-fim}} = \sum_{i=1}^H \left(d_{\text{proc},i} + d_{\text{fila},i} + \frac{L}{R_i} + \frac{d_i}{s_i} \right).$$

Neste texto, H é o número de **enlaces** percorridos. Se “ H hops” for usado para contar apenas os roteadores intermediários, o caminho terá $H + 1$ enlaces e as fórmulas devem ser ajustadas.




Figure 5: As quatro fontes do atraso nodal, na ordem em que o pacote as encontra. A CPU do roteador verifica o cabeçalho e determina a porta de saída. O pacote é então colocado no *buffer* correspondente. Quando chega à frente da fila, o módulo de transmissão da placa de rede serializa seus L bits à taxa R , produzindo o atraso de transmissão L/R . Finalmente, os bits se propagam pelo meio físico, produzindo o atraso de propagação d/s .

3.5 Técnicas de *packet pair*

A técnica de *packet pair* envia dois pacotes de sondagem de mesmo tamanho L muito próximos. Em um gargalo de taxa R_b , os pacotes precisam ser serializados. Na situação ideal, a dispersão observada na saída do gargalo é

$$\Delta_{\text{out}} \approx \frac{L}{R_b},$$

de modo que

$$\hat{R}_b \approx \frac{L}{\Delta_{\text{out}}}.$$

O atraso de propagação comum aos dois pacotes muda o instante absoluto de chegada, mas tende a se cancelar quando se considera apenas a diferença entre os instantes de chegada. Por isso a dispersão pode revelar a taxa de serialização do gargalo.

Na prática, há várias fontes de erro:

- tráfego concorrente pode entrar entre os pacotes e aumentar a dispersão;
- filas e políticas de escalonamento podem comprimir ou expandir o par;
- caminhos diferentes, offloading e resolução limitada do relógio afetam a medição;
- um único par é frágil, razão pela qual se usam repetições, filtros e trens de pacotes.

Capacidade versus largura de banda disponível. O *packet pair* clássico procura principalmente a capacidade do gargalo. A capacidade livre depende do tráfego concorrente e exige hipóteses ou técnicas adicionais.

3.6 Fragmentação de uma mensagem em pacotes

Considere uma mensagem com L' bytes úteis que atravessa H enlaces idênticos. Nesta seção, para manter as fórmulas em bytes, R representa a taxa em **bytes/s**. Se a taxa do enlace for dada em bits/s, basta usar $R/8$ como taxa em bytes/s, ou multiplicar os numeradores por 8. A mensagem é dividida em N pacotes. Cada pacote contém ℓ bytes úteis e um cabeçalho de h bytes. Inicialmente, suponha que L' é múltiplo de ℓ , de modo que

$$N = \frac{L'}{\ell}.$$

As hipóteses do modelo são:

- comutação *store-and-forward*;
- todos os enlaces têm a mesma taxa R ;
- não há perdas, retransmissões, filas nem atraso de processamento;
- os pacotes são transmitidos em pipeline;
- o atraso de propagação será acrescentado separadamente.

O primeiro pacote leva

$$H \frac{\ell + h}{R}$$

para ser serializado nos H enlaces. Depois que o pipeline é preenchido, cada um dos $N - 1$ pacotes restantes chega separado pelo intervalo $(\ell + h)/R$. Logo,

$$T_{\text{tx}}(\ell) = (H + (N - 1)) \frac{\ell + h}{R} \quad (1)$$

$$= \frac{(H + N - 1)(\ell + h)}{R}. \quad (2)$$

Substituindo $N = L'/\ell$,

$$T_{\text{tx}}(\ell) = \frac{1}{R} \left(H - 1 + \frac{L'}{\ell} \right) (\ell + h) \quad (3)$$

$$= \frac{1}{R} \left(L' + (H - 1)\ell + \frac{L'h}{\ell} + (H - 1)h \right). \quad (4)$$

Se cada enlace também possui atraso de propagação d/s , o atraso total, sob as mesmas hipóteses, torna-se

$$T_{\text{total}}(\ell) = T_{\text{tx}}(\ell) + H \frac{d}{s}.$$

O termo de propagação não altera o tamanho ótimo de pacote neste modelo, pois não depende de ℓ .

3.7 Tamanho útil ótimo do pacote

Os termos constantes de (4) não afetam a minimização. Assim, devemos minimizar

$$f(\ell) = (H - 1)\ell + \frac{L'h}{\ell}.$$

Derivando,

$$f'(\ell) = (H - 1) - \frac{L'h}{\ell^2}.$$

Igualando a zero,

$$(H - 1) = \frac{L'h}{\ell^2},$$

e, portanto,

$$\ell^* = \sqrt{\frac{L'h}{H - 1}}.$$

A segunda derivada é

$$f''(\ell) = \frac{2L'h}{\ell^3} > 0,$$

logo o ponto estacionário é um mínimo para $H > 1$, $h > 0$ e $L' > 0$.

O número contínuo de pacotes correspondente é

$$N^* = \frac{L'}{\ell^*} = \sqrt{\frac{L'(H - 1)}{h}}.$$

Na prática, N deve ser inteiro, o último pacote pode ser menor, e ℓ é limitado pela MTU. Devem-se comparar os inteiros próximos de N^* e respeitar os limites do sistema.

3.8 A mesma derivação em função de N

Como $\ell = L'/N$, a Equação (2) também pode ser escrita como

$$T_{\text{tx}}(N) = \frac{(H + N - 1)(L'/N + h)}{R} \quad (5)$$

$$= \frac{1}{R} \left(L' + (H - 1)h + Nh + \frac{(H - 1)L'}{N} \right). \quad (6)$$

Derivando a parte não constante,

$$\frac{d}{dN} \left(Nh + \frac{(H - 1)L'}{N} \right) = h - \frac{(H - 1)L'}{N^2}.$$

Igualando a zero, obtemos novamente

$$N^* = \sqrt{\frac{(H - 1)L'}{h}}.$$

3.9 Quando a fórmula degenera para $L(N + H - 1)/R$?

Se desprezarmos o cabeçalho, isto é, se $h = 0$, e chamarmos de L o tamanho de cada pacote, então $\ell = L$ e a mensagem total satisfaz

$$L' = NL.$$

Substituindo essas três condições na Equação (4),

$$T_{\text{tx}} = \frac{L' + L(H - 1)}{R} \quad (7)$$

$$= \frac{LN + L(H - 1)}{R} \quad (8)$$

$$= \boxed{\frac{L(N + H - 1)}{R}}. \quad (9)$$

Portanto, a identificação está correta sob as seguintes condições:

$$h = 0, \quad \ell = L, \quad L' = NL,$$

além das hipóteses de enlaces iguais, *store-and-forward*, ausência de filas e pipeline perfeito.

Quando $h = 0$, o modelo ideal favorece pacotes cada vez menores: reduzir ℓ melhora o pipeline sem custo adicional. O cabeçalho, o processamento por pacote, a MTU e outros custos reais impedem esse limite irreal e produzem um compromisso entre fragmentação e overhead.

3.10 Resumo das expressões

Grandeza	Expressão
Atraso de transmissão de um pacote	L/R
Atraso de propagação de um enlace	d/s
Dispersão ideal de <i>packet pair</i>	$\Delta \approx L/R_b$
Estimativa do gargalo	$\hat{R}_b \approx L/\Delta$
Mensagem fragmentada	$(H + N - 1)(\ell + h)/R$
Tamanho útil ótimo	$\ell^* = \sqrt{L'h/(H - 1)}$
Número contínuo ótimo de pacotes	$N^* = \sqrt{L'(H - 1)/h}$
Caso sem cabeçalho	$L(N + H - 1)/R$

AULA 4 | 21/08/2026 – sexta-feira

Multiplexação estatística e probabilidade de bloqueio

Cobertura: slide 35 e desenvolvimento, no quadro, do modelo probabilístico de usuários ativos.

4.1 Problema de dimensionamento

Considere m usuários que compartilham um recurso capaz de atender simultaneamente r usuários. Cada usuário está ativo com probabilidade p . Se A é o número de usuários ativos, então, sob independência e probabilidades iguais,

$$A \sim \text{Binomial}(m, p), \quad \Pr(A = a) = \binom{m}{a} p^a (1-p)^{m-a}.$$

Além disso,

$$\mathbb{E}[A] = mp.$$

A média é a carga esperada, não um limite máximo para A .

4.2 Probabilidade de sobrecarga

Há demanda acima da capacidade quando $A > r$:

$$\Pr(A > r) = \sum_{a=r+1}^m \Pr(A = a) = 1 - \sum_{a=0}^r \Pr(A = a).$$

Um projeto probabilístico escolhe r de modo que

$$\Pr(A > r) \leq \varepsilon,$$

onde ε é a tolerância de bloqueio, perda ou sobrecarga.

Cuidado. Escolher apenas $r = mp$ geralmente não produz uma probabilidade pequena de sobrecarga. É preciso considerar a variabilidade e a cauda da distribuição.

4.3 Aproximação de Poisson

Quando m é grande, p é pequeno e $\lambda = mp$ permanece moderado,

$$\Pr(A = a) \approx e^{-\lambda} \frac{\lambda^a}{a!}.$$

4.4 Fila e garantias

Na comutação de pacotes, o uso pode ser imediato e a garantia costuma ser probabilística. Na comutação de circuitos, a reserva permite garantia ao usuário aceito, mas uma nova chamada pode ser recusada se todos os circuitos estiverem ocupados.

Síntese. A multiplexação estatística aumenta a eficiência porque nem todos os usuários ficam ativos ao mesmo tempo; o preço é um risco controlado de fila, perda ou bloqueio.

Exercício guiado

Uma rede possui $m = 100$ usuários, cada um ativo com probabilidade $p = 0,10$. Assim, $\mathbb{E}[A] = 10$. Para uma capacidade r :

1. calcule $\Pr(A > r)$ usando a cauda binomial;
2. compare com a aproximação de Poisson de parâmetro $\lambda = 10$;
3. encontre o menor r que atende a uma meta ε ;
4. explique por que $r = 10$ não equivale a uma garantia de baixa sobrecarga.

Da binomial ao tempo de descongestionamento

Complemento da aula de 21 de agosto de 2026

4.5 A mesma binomial em dois sistemas diferentes

Considere m usuários. Em uma escala de tempo adequada, defina

$$I_i = \begin{cases} 1, & \text{se o usuário } i \text{ está ativo;} \\ 0, & \text{caso contrário.} \end{cases}$$

Se os usuários são independentes e $\Pr(I_i = 1) = p$, então

$$A = \sum_{i=1}^m I_i \sim \text{Binomial}(m, p).$$

A distribuição matemática é a mesma em comutação de pacotes e de circuitos. O que muda é a definição de “ativo”, a escala de observação e a pergunta feita ao modelo.

	Comutação de pacotes	Comutação de circuitos
Escala de tempo	Slot curto, intervalo de escalonamento ou instante de medição da carga.	Duração de uma chamada/conexão ou instante de admissão de uma nova chamada.
Evento $I_i = 1$	O usuário transmite pacotes ou demanda taxa no slot observado.	O usuário mantém uma chamada/conexão que ocupa um circuito.
Variável A	Número de fontes simultaneamente ativas.	Número de chamadas oferecidas ou circuitos potencialmente ocupados.
Pergunta típica	Qual é $\Pr(A > r)$, isto é, a chance de a demanda superar a capacidade e produzir fila ou perda?	Qual é a chance de uma nova chamada não encontrar circuito disponível? Ou, antes do controle de admissão, qual é $\Pr(A > r)$ para a demanda oferecida?
Interpretação da garantia	Probabilística: busca-se manter fila, atraso ou perda abaixo de uma meta.	Determinística para chamadas aceitas; probabilística para o bloqueio na admissão.

Pergunta e modelo devem combinar. Com admissão rígida e apenas r circuitos, o número de circuitos efetivamente ocupados nunca excede r . Nesse caso, $\Pr(A > r)$ deve referir-se à *demanda oferecida*, antes da recusa, ou ser substituída diretamente pela probabilidade de bloqueio vista por uma chegada. A binomial é apropriada quando há uma população finita de fontes independentes; o modelo clássico de Erlang usa hipóteses temporais diferentes.

4.6 Da binomial à Poisson: derivação heurística

Considere

$$A_m \sim \text{Binomial}(m, p_m), \quad p_m = \frac{\lambda}{m}.$$

Assim, o número médio de usuários ativos permanece fixo:

$$\mathbb{E}[A_m] = mp_m = \lambda.$$

Para um valor fixo a ,

$$\Pr(A_m = a) = \binom{m}{a} \left(\frac{\lambda}{m}\right)^a \left(1 - \frac{\lambda}{m}\right)^{m-a} \quad (10)$$

$$= \frac{m(m-1) \cdots (m-a+1)}{a!} \frac{\lambda^a}{m^a} \left(1 - \frac{\lambda}{m}\right)^m \left(1 - \frac{\lambda}{m}\right)^{-a} \quad (11)$$

$$= \frac{\lambda^a}{a!} \underbrace{\prod_{j=0}^{a-1} \left(1 - \frac{j}{m}\right)}_{\rightarrow 1} \underbrace{\left(1 - \frac{\lambda}{m}\right)^m}_{\rightarrow e^{-\lambda}} \underbrace{\left(1 - \frac{\lambda}{m}\right)^{-a}}_{\rightarrow 1}. \quad (12)$$

Quando $m \rightarrow \infty$, $p_m \rightarrow 0$ e $mp_m = \lambda$, obtemos

$$\Pr(A_m = a) \rightarrow e^{-\lambda} \frac{\lambda^a}{a!}$$

e escrevemos, aproximadamente,

$$A_m \approx \text{Poisson}(\lambda).$$

Interpretação. A aproximação de Poisson é natural quando existem muitas fontes, cada fonte fica ativa com probabilidade pequena, e a carga média total $\lambda = mp$ permanece moderada.

4.7 Do estado da rede ao tempo de recuperação

Até aqui, A descreve uma fotografia da rede em um slot. Agora queremos uma variável aleatória temporal: quantos slots serão necessários para que o sistema volte a ficar des congestionado?

Para cada slot futuro $t = 1, 2, \dots$, seja A_t o número de usuários ativos. Defina

$$q = \Pr(A_t \leq r), \quad 1 - q = \Pr(A_t > r).$$

No modelo binomial,

$$q = \sum_{a=0}^r \binom{m}{a} p^a (1-p)^{m-a}.$$

Defina a nova variável aleatória

$$S = \min\{s \geq 1 : A_s \leq r\},$$

isto é, S é o número de slots futuros até observarmos o primeiro slot descongestionado.

Se os slots são independentes e têm a mesma probabilidade q de sucesso,

$$S \sim \text{Geom}(q),$$

com suporte $\{1, 2, 3, \dots\}$. Sua PMF é

$$\Pr(S = s) = (1 - q)^{s-1}q, \quad s = 1, 2, \dots,$$


e sua função de distribuição acumulada (CDF) é

$$F_S(s) = \Pr(S \leq s) = 1 - (1 - q)^s, \quad s = 1, 2, \dots$$

Hipótese forte. Se usuários permanecem ativos por vários slots, os valores A_t são correlacionados e S não é necessariamente geométrica. A geométrica é o modelo básico obtido sob independência entre slots.

4.8 Duas CDFs para o tempo de descongestionamento

O gráfico compara dois sistemas. No Sistema A, um slot está descongestionado com probabilidade $q_A = 0,50$; no Sistema B, essa probabilidade é apenas $q_B = 0,20$.



Pergunta aos alunos. Qual sistema você preferiria? Para um mesmo valor de s , qual curva oferece maior probabilidade de já ter saído do congestionamento?

Leitura do gráfico. O Sistema A é preferível: sua CDF sobe mais cedo. A curva do Sistema B está mais à direita e é pior, pois atribui maior probabilidade a tempos longos de recuperação. Em termos de ordem estocástica, S_A é estocasticamente menor que S_B (o que pode confundir com o fato de a CDF do sistema S_A estar acima da CDF do sistema S_B).

4.9 Como caracterizar uma variável aleatória

Uma variável aleatória pode ser descrita de várias maneiras equivalentes ou complementares:

- pela **CDF**, $F_S(s) = \Pr(S \leq s)$, que sempre caracteriza a distribuição;
- pela **PMF**, $p_S(s) = \Pr(S = s)$, quando a variável é discreta;
- por uma **transformada**, como a função geradora de probabilidades ou a função geradora de momentos;
- por **todos os momentos**, quando a distribuição é determinada por seus momentos.

Para a geométrica com suporte começando em 1, a função geradora de probabilidades é

$$G_S(z) = \mathbb{E}[z^S] = \sum_{s=1}^{\infty} z^s (1-q)^{s-1} q = \frac{qz}{1 - (1-q)z}.$$

4.10 Média da geométrica pela falta de memória

A geométrica possui a propriedade de falta de memória:

$$\Pr(S > m + n \mid S > m) = \Pr(S > n).$$

Depois de um slot congestionado, a situação probabilística para os slots futuros é igual à situação inicial.

Seja

$$\mu = \mathbb{E}[S].$$

No primeiro slot, ocorrem duas possibilidades:

- com probabilidade q , o sistema descongestiona imediatamente e $S = 1$;
- com probabilidade $1 - q$, gastamos um slot congestionado e, pela falta de memória, o tempo médio restante volta a ser μ .

Portanto,

$$\mu = q \cdot 1 + (1 - q)(1 + \mu) \tag{13}$$

$$= 1 + (1 - q)\mu. \tag{14}$$

Reorganizando,

$$q\mu = 1,$$

e concluímos que

$$\boxed{\mathbb{E}[S] = \frac{1}{q}}.$$

Nos dois sistemas do gráfico,

$$\mathbb{E}[S_A] = \frac{1}{0,50} = 2 \text{ slots}, \quad \mathbb{E}[S_B] = \frac{1}{0,20} = 5 \text{ slots}.$$

Isso confirma numericamente a leitura visual: a curva mais à direita é a pior.

Fechamento da aula. A binomial descreve quantos usuários estão ativos em uma fotografia da rede; a Poisson oferece uma aproximação para muitas fontes raramente ativas; e a geométrica descreve, sob independência temporal, quanto tempo esperamos até o sistema voltar a ficar descongestionado.

Referências de acompanhamento

- J. F. Kurose e K. W. Ross, *Computer Networking: A Top-Down Approach*, Capítulo 1.
- Slides oficiais dos autores: https://gaia.cs.umass.edu/kurose_ross/ppt.php.
- Agenda e materiais da disciplina disponíveis nos canais informados em aula.

AULA 5 | 26/08/2026 – quarta-feira

Do pipeline à teoria de filas

Cobertura: slides 36 até slide 52 sobre teoria de filas.

Roteiro da aula. Primeiro retomamos o envio de vários pacotes por um caminho com múltiplos enlaces. Depois comparamos *store-and-forward* e *cut-through*. Finalmente, introduzimos um modelo de fila para relacionar taxa de chegada, capacidade, utilização, número de pacotes e atraso.

5.1 Retomada: pacotes em pipeline

Considere N pacotes de mesmo tamanho L bits atravessando H enlaces. Todos os enlaces têm taxa R bits/s e os nós usam *store-and-forward*. Por enquanto, ignore filas, perdas, processamento e propagação.

O tempo de transmissão de um pacote em um enlace é

$$\tau = \frac{L}{R}.$$

O primeiro pacote precisa ser completamente transmitido nos H enlaces e chega após $H\tau$. A partir daí, graças ao pipeline, chega um novo pacote a cada intervalo τ . Portanto,

$$T_{N,H} = (H + N - 1) \frac{L}{R}.$$

O termo $N + H - 1$ pode ser visualizado como H intervalos para o primeiro pacote e $N - 1$ intervalos para esvaziar o restante do pipeline.

Se cada enlace também possui atraso de propagação d_i/s_i , ele é somado uma vez por enlace:

$$T_{N,H} = (H + N - 1) \frac{L}{R} + \sum_{i=1}^H \frac{d_i}{s_i}.$$

Observe que a propagação não é multiplicada por N : os pacotes também se propagam em pipeline.

Verificação. Se $N = 1$, obtemos HL/R . Se $H = 1$, obtemos NL/R . Por que esses dois casos-limite fazem sentido?

5.2 Comutação e o momento de encaminhar

O nó intermediário pode decidir quando começar a transmitir o pacote pelo próximo enlace.

	<i>Store-and-forward</i>	<i>Cut-through</i>
Quando encaminha?	Depois de receber o pacote completo.	Assim que recebe cabeçalho suficiente para determinar a saída.
Memória no nó	Armazena o pacote inteiro.	Pode usar um buffer menor, embora ainda possa haver filas.
Erro no final do pacote	Pode ser detectado antes do encaminhamento.	O nó pode já ter propagado parte de um quadro corrompido.
Atraso ideal	Cada enlace acrescenta aproximadamente L/R .	A serialização pode se sobrepor entre enlaces; após o início, o pacote pode atravessar os nós quase como um fluxo de bits.

Não confundir conceitos. *Packet switching* versus *circuit switching* descreve como os recursos são compartilhados. *Store-and-forward* versus *cut-through* descreve quando um nó começa a encaminhar os bits. São duas classificações diferentes.

Em uma rede de pacotes, o encaminhamento é feito pacote a pacote com uma tabela de encaminhamento. Em uma rede de circuitos, há antes uma fase de estabelecimento do circuito e os recursos podem ser reservados durante a conexão. A análise probabilística continua útil nos dois casos, mas em escalas distintas: slots ou rajadas para pacotes; duração de chamadas para circuitos.

5.3 A analogia da caravana

A “caravana”, traduzida na edição nacional de Kurose & Ross como “comboio de carros”, ilustra de forma intuitiva a diferença física e matemática entre o **atraso de transmissão** e o **atraso de propagação**.

Nesta versão da analogia, consideramos um único pacote suficientemente longo para mostrar claramente a diferença entre os regimes *store-and-forward* e *cut-through*.

5.3.1 Os elementos da analogia

Imagine uma rodovia com três cabines de pedágio, separadas por trechos de 100 km:

- **Carros individuais** → os **bits**;
- **O comboio de 15 carros** → um **pacote** de dados;
- **As cabines de pedágio** → os **roteadores ou comutadores**;
- **O tempo de atendimento de um carro** → o tempo necessário para transmitir um bit;
- **Os trechos de rodovia** → os **enlaces** de comunicação;
- **A velocidade dos carros** → a velocidade de propagação do sinal no meio físico.

Adotaremos os seguintes parâmetros:

- distância entre dois pedágios: 100 km;
- velocidade dos carros: 1.000 km/h;
- tempo de atendimento: 1 minuto por carro;
- tamanho do comboio: 15 carros.

5.3.2 Um mesmo pacote nos dois regimes


A Figura 6 representa o sistema no instante $t = 14$ minutos.

No regime *store-and-forward*, o pedágio 2 ainda não recebeu o comboio completo e, portanto, não pode liberar nenhum carro para o trecho seguinte.

No regime *cut-through*, cada pedágio libera os carros à medida que eles chegam. Nesse mesmo instante, o carro 15 está no pedágio 1, o carro 8 está no pedágio 2 e o carro 1 está no pedágio 3.

(a) Store-and-forward no instante $t = 14$ min


um único pacote: o último carro ainda está no pedágio 1, o pedágio 2 aguarda enquanto os demais propagam ou aguardam no pedágio 2 o pacote completo



No instante $t = 14$, o carro 15 está no pedágio 1, os carros 9–14 ainda propagam e os carros 1–8 já estão armazenados no pedágio 2. O trecho posterior permanece vazio.

(b) Cut-through no instante $t = 14$ min

um único pacote ocupa simultaneamente os três pedágios e os dois trechos entre eles



No mesmo instante, o carro 15 está no pedágio 1, o carro 8 está no pedágio 2 e o carro 1 está no pedágio 3. Todos pertencem ao mesmo pacote.




Figure 6: Um único pacote de 15 carros observado no instante $t = 14$ minutos. Em (a), no regime *store-and-forward*, o carro 15 está sendo atendido pelo pedágio 1, os carros 9–14 ainda estão em propagação e os carros 1–8 já chegaram ao pedágio 2, onde permanecem armazenados verticalmente. O pedágio 2 não pode liberar nenhum carro antes de receber o pacote completo e, por isso, o trecho posterior permanece vazio. Em (b), no regime *cut-through*, os carros 15, 8 e 1 estão sendo atendidos simultaneamente pelos pedágios 1, 2 e 3, respectivamente, enquanto os demais carros propagam pelos enlaces.

5.3.3 Cálculo dos atrasos básicos

Atraso de transmissão. Cada pedágio atende um carro por minuto. Portanto, sua taxa de serviço é

$$R_{\text{pedágio}} = 1 \text{ carro/min.}$$

Como o pacote contém 15 carros, o tempo necessário para transmitir o pacote completo é

$$d_{\text{trans}} = \frac{15 \text{ carros}}{1 \text{ carro/min}} = 15 \text{ minutos.} \quad (15)$$

Na analogia com redes, os 15 carros representam os bits do pacote e a taxa de um carro por minuto representa a taxa de transmissão do enlace.

Atraso de propagação. Os carros deslocam-se a 1.000 km/h e os pedágios estão separados por 100 km. Logo,

$$d_{\text{prop}} = \frac{100 \text{ km}}{1.000 \text{ km/h}} \quad (16)$$

$$= 0,1 \text{ h} \quad (17)$$

$$= 6 \text{ minutos.} \quad (18)$$

Observe que o atraso de propagação depende da distância e da velocidade, mas não depende do número de carros.

Tempo para o pacote chegar completamente ao pedágio seguinte. No regime *store-and-forward*, o último carro deixa o primeiro pedágio após 15 minutos e ainda precisa percorrer 100 km.

Consequentemente, o instante em que o pacote está completamente disponível no pedágio seguinte é

$$d_{\text{trans}} + d_{\text{prop}} = 15 + 6 = 21 \text{ minutos.} \quad (19)$$

5.3.4 Funcionamento no regime *store-and-forward*

No regime *store-and-forward*, cada pedágio precisa receber o pacote completo antes de começar a encaminhá-lo:

1. O pedágio 1 atende os 15 carros, um de cada vez.
2. O último carro deixa o pedágio 1 em $t = 15$ minutos.
3. Depois de percorrer 100 km, o último carro chega ao pedágio 2 em

$$t = 15 + 6 = 21 \text{ minutos.}$$

4. Somente em $t = 21$ minutos o pedágio 2 pode começar a atender o primeiro carro.
5. O mesmo procedimento se repete no pedágio 3.

Ideia central: o pedágio seguinte pode receber alguns carros antes dos demais, mas não pode encaminhar nenhum deles antes de receber o comboio completo. Isso corresponde a um roteador *store-and-forward*, que somente inicia a transmissão depois de receber o pacote inteiro.

5.3.5 O instante $t = 14$ minutos

O instante $t = 14$ minutos permite visualizar claramente a diferença entre os dois regimes.

No pedágio 1, cada carro i termina seu atendimento no instante

$$t = i \text{ minutos.}$$

Como o tempo de propagação é de seis minutos, o carro i chega ao pedágio 2 no instante

$$t = i + 6.$$

Assim, no instante $t = 14$:

- o carro 15 está sendo atendido pelo pedágio 1;
- o carro 8, que deixou o pedágio 1 em $t = 8$, chega ao pedágio 2;
- o carro 1 já chegou ao pedágio 2 desde $t = 7$.

No regime *store-and-forward*, o pedágio 2 precisa esperar até $t = 21$ minutos, quando chega o carro 15. Portanto, em $t = 14$ nenhum carro foi encaminhado para além do pedágio 2.

5.3.6 Funcionamento no regime *cut-through*

No regime *cut-through*, o pedágio não espera pela chegada do pacote completo. Cada carro é atendido assim que chega.

O carro 1 segue a seguinte trajetória:

1. é atendido pelo pedágio 1 entre $t = 0$ e $t = 1$;
2. percorre o primeiro trecho entre $t = 1$ e $t = 7$;
3. é atendido pelo pedágio 2 entre $t = 7$ e $t = 8$;
4. percorre o segundo trecho entre $t = 8$ e $t = 14$;
5. chega ao pedágio 3 em $t = 14$.

O carro 8 deixa o pedágio 1 em $t = 8$ e chega ao pedágio 2 em $t = 14$.

O carro 15 começa a ser atendido pelo pedágio 1 em $t = 14$.

Portanto, no instante $t = 14$ minutos,

pedágio 1:	carro 15,
pedágio 2:	carro 8,
pedágio 3:	carro 1.

Os três pedágios estão simultaneamente ocupados por carros pertencentes ao mesmo pacote.

Pipeline: o *cut-through* permite que diferentes partes do mesmo pacote sejam processadas simultaneamente em diferentes estágios. O pacote não precisa estar completamente armazenado em um roteador para que sua parte inicial avance.

5.3.7 Atraso fim a fim nos dois regimes

Considere um caminho com $H = 3$ pedágios, seguido por três trechos de propagação. Cada trecho apresenta atraso de propagação de seis minutos.

5.3.7.1 *Store-and-forward*

Em cada estágio, é necessário:

- atender os 15 carros: 15 minutos;
- percorrer o trecho seguinte: 6 minutos.

Portanto,

$$T_{\text{SF}} = H (d_{\text{trans}} + d_{\text{prop}}) \quad (20)$$

$$= 3(15 + 6) \quad (21)$$

$$= \boxed{63 \text{ minutos}}. \quad (22)$$

5.3.7.2 *Cut-through*

No regime *cut-through*, os carros formam um pipeline através dos três pedágios.

Com $C = 15$ carros, $H = 3$ pedágios e tempo de serviço por carro $t_c = 1$ minuto, o tempo de serviço do pipeline é

$$(C + H - 1)t_c.$$

Somando os três atrasos de propagação,

$$T_{\text{CT}} = (C + H - 1)t_c + H d_{\text{prop}} \quad (23)$$

$$= (15 + 3 - 1)(1) + 3(6) \quad (24)$$

$$= 17 + 18 \quad (25)$$

$$= \boxed{35 \text{ minutos}}. \quad (26)$$

A diferença fundamental é que, no regime *store-and-forward*, o tempo de transmissão do pacote completo é pago em cada estágio:

$$3(15) = 45 \text{ minutos}.$$

No regime *cut-through*, o tempo dominante de transmissão é pago uma única vez:

$$15 \text{ minutos},$$

acrescido apenas do pequeno custo de preenchimento dos dois estágios adicionais:

$$(H - 1)t_c = 2 \text{ minutos.}$$

5.3.8 *Store-and-forward* versus *cut-through*

Os dois regimes diferem no momento em que o equipamento decide encaminhar o pacote:

- ***Store-and-forward***: o comutador recebe o pacote inteiro, verifica o campo de detecção de erros e somente então inicia a transmissão. Em um caminho com H enlaces idênticos, o atraso de transmissão do pacote é aproximadamente

$$H \frac{L}{R}.$$

- ***Cut-through***: o comutador começa a encaminhar assim que lê cabeçalho suficiente para identificar a porta de saída. No modelo ideal, o atraso associado ao tamanho completo do pacote é aproximadamente

$$\frac{L}{R},$$

e não HL/R . Existe apenas um pequeno custo adicional para o preenchimento do pipeline.

O preço do *cut-through*. Como o quadro é encaminhado antes de terminar de chegar, o comutador pode não conseguir verificar previamente todo o campo de detecção de erros. Quadros corrompidos ou truncados podem ser propagados adiante.

Além disso, o ganho diminui se a porta de saída estiver ocupada ou se sua taxa for menor do que a taxa de entrada. Nesses casos, o equipamento precisa armazenar parte ou todo o quadro. Por isso, o *cut-through* e sua variante *fragment-free*, que examina os primeiros 64 bytes, aparecem principalmente em *switches* Ethernet e em redes de datacenter sensíveis à latência. Os roteadores da Internet operam predominantemente em regime *store-and-forward*.

5.4 Da transmissão determinística à fila

Até agora supusemos que o pacote encontra cada enlace livre. Na prática, vários pacotes disputam uma mesma saída. Modele uma interface por um servidor com uma fila: Use a seguinte notação:




Figure 7: Modelo de fila para um enlace de comunicação. Os pacotes chegam à taxa média λ , esperam na fila quando o enlace está ocupado e são transmitidos pelo servidor à taxa média μ .

- λ : taxa média de chegada, em pacotes/s;
- L : tamanho médio dos pacotes, em bits;
- R : taxa do enlace, em bits/s;
- $1/\mu = L/R$: tempo médio de serviço de um pacote;
- $\mu = R/L$: taxa média de serviço, em pacotes/s.

A intensidade de tráfego ou carga oferecida é

$$\rho = \frac{\lambda}{\mu} = \frac{\lambda L}{R}.$$

Quando o sistema é estável e não há perda de trabalho, ρ também é a fração de tempo em que o enlace permanece ocupado.

Uma justificativa por conservação de taxa é simples. Se o enlace está ocupado durante a fração p_{ocup} do tempo, sua taxa média de saída é

$$0 \cdot (1 - p_{\text{ocup}}) + \mu p_{\text{ocup}}.$$


Em regime estacionário, a taxa média de saída deve igualar a taxa de entrada:

$$\lambda = \mu p_{\text{ocup}} \implies p_{\text{ocup}} = \frac{\lambda}{\mu} = \rho.$$

Condição de estabilidade. Em uma fila com buffer ilimitado, precisamos de $\rho < 1$, isto é, $\lambda < \mu$. Se $\rho > 1$ por tempo prolongado, chega trabalho mais rapidamente do que o enlace consegue atendê-lo e a fila cresce sem limite. Em um buffer finito, o efeito aparece como perdas.

5.5 Utilização alta não significa atraso pequeno

Uma utilização próxima de 100% parece eficiente, mas deixa pouca folga para absorver as flutuações aleatórias das chegadas e dos tamanhos dos pacotes.



O formato acima é qualitativo: o crescimento exato depende do modelo de chegadas, do tamanho dos pacotes, do escalonamento e do tamanho do buffer. A mensagem essencial é que o atraso cresce rapidamente quando ρ se aproxima de 1.

Caso particular $M/M/1$. Somente se as chegadas forem Poisson, os tempos de serviço forem exponenciais, houver um único servidor e buffer ilimitado, vale

$$\mathbb{E}[T] = \frac{1}{\mu - \lambda}, \quad \mathbb{E}[W_q] = \frac{\rho}{\mu - \lambda}.$$

Essas fórmulas não são consequências apenas de conhecer λ e μ .

5.6 Lei de Little

Considere todos os pacotes presentes no sistema: os que esperam na fila e o que está sendo transmitido. Defina

- $\bar{N}$: número médio de pacotes no sistema;
- $\bar{T}$: tempo médio de um pacote no sistema;
- λ : taxa média efetiva de entrada no sistema.

A Lei de Little estabelece que

$$\boxed{\bar{N} = \lambda \bar{T}}.$$

A intuição é uma contagem de “pacote-segundos”. Em um intervalo longo de duração t , a área sob a curva $N(u)$ é aproximadamente $t\bar{N}$. A mesma área é a soma dos tempos que aproximadamente λt pacotes passaram no sistema, isto é, $(\lambda t)\bar{T}$. Igualando as duas contagens,

$$t\bar{N} = (\lambda t)\bar{T} \implies \bar{N} = \lambda \bar{T}.$$

A lei também pode ser aplicada apenas à fila:

$$\bar{N}_q = \lambda \bar{W}_q,$$

onde $\bar{N}_q$ exclui o pacote em serviço e $\bar{W}_q$ conta apenas o tempo de espera. É importante combinar corretamente a região contada e o tempo correspondente.

Exemplo. Um enlace recebe em média 200 pacotes/s e cada pacote passa em média 15 ms no sistema. Quantos pacotes há, em média, na fila mais o servidor?

$$\bar{N} = 200 \times 0,015 = 3 \text{ pacotes.}$$

5.7 Síntese e questões de revisão

Ao final da aula, deve ser possível explicar:

1. por que N pacotes em H enlaces requerem $N + H - 1$ intervalos de transmissão no modelo ideal;
2. a diferença entre *store-and-forward* e *cut-through*;
3. por que $\mu = R/L$ e $\rho = \lambda L/R$;
4. por que o atraso pode crescer fortemente antes de a utilização atingir 100%;
5. como usar $\bar{N} = \lambda \bar{T}$ sem misturar sistema e fila.

Para pensar.

1. Um enlace de 10 Mbit/s recebe 800 pacotes/s de tamanho médio 1,000 bytes. Qual é ρ ? O sistema pode ser estável?
2. Se $\bar{N} = 12$ pacotes e $\lambda = 600$ pacotes/s, qual é o tempo médio no sistema?
3. Dois enlaces têm a mesma utilização média. Eles necessariamente têm o mesmo atraso médio? Que outras características podem ser relevantes?

AULA 6 | 28/08/2026 – sexta-feira**Teoria de filas****Cobertura:** Slide 52.**6.1 Lei de Little e intensidade de tráfego**

Nesta aula, introduzimos um modelo simples para estudar o desempenho de um enlace. O objetivo é relacionar:

- a taxa de chegada de pacotes;
- a capacidade de transmissão do enlace;
- a utilização do enlace;
- o número médio de pacotes;
- o tempo médio de espera;
- o tempo médio total no sistema.

Inicialmente, apresentaremos relações que valem para uma classe ampla de sistemas. Posteriormente, adotaremos as hipóteses específicas do modelo $M/M/1$ para obter fórmulas explícitas para o atraso.

6.1.1 Fila de espera, servidor e sistema

Em um instante t , definimos:

- $N_q(t)$: número de pacotes esperando na fila;
- $N_s(t)$: número de pacotes no servidor, isto é, sendo transmitidos;
- $N(t)$: número total de pacotes no sistema.


Consequentemente,

$$N(t) = N_q(t) + N_s(t).$$

Em um enlace com um único servidor, temos

$$N_s(t) \in \{0, 1\}.$$

O servidor contém um pacote quando o enlace está ocupado e nenhum pacote quando o enlace está ocioso.



É importante distinguir a fila de espera do sistema completo:

$$\boxed{\text{sistema} = \text{fila de espera} + \text{servidor}}.$$

Portanto, “fila de espera” e “sistema” não são sinônimos.

6.1.2 Valores instantâneos e valores médios

As variáveis $N_q(t)$, $N_s(t)$ e $N(t)$ descrevem o sistema em um instante. Ao observarmos o sistema durante um intervalo longo, obtemos os valores médios:

- $\bar{N}_q$: número médio de pacotes na fila de espera;
- $\bar{N}_s$: número médio de pacotes no servidor;
- $\bar{N}$: número médio de pacotes no sistema.

Como a igualdade

$$N(t) = N_q(t) + N_s(t)$$

vale em todos os instantes, também temos

$$\boxed{\bar{N} = \bar{N}_q + \bar{N}_s}.$$

Embora o número observado de pacotes seja sempre inteiro, seu valor médio pode ser fracionário. Por exemplo, $\bar{N}_s = 0,8$ significa que o servidor está ocupado durante 80% do tempo e vazio durante os outros 20%.

6.1.3 Tempos no sistema

Definimos:

- W : tempo médio que um pacote passa esperando na fila;
- S : tempo médio de serviço;
- T : tempo médio total que um pacote passa no sistema.

Consequentemente,

$$\boxed{T = W + S}.$$

Considere um enlace com taxa R bits/s e pacotes com tamanho médio L bits. O tempo médio de serviço é

$$S = \frac{L}{R}.$$

A taxa média de serviço, medida em pacotes por segundo, é

$$\boxed{\mu = \frac{1}{S} = \frac{R}{L}}.$$

Por exemplo, se

$$R = 10\,000\,000 \text{ bits/s}$$

e

$$L = 8\,000 \text{ bits},$$

então

$$\mu = \frac{10\,000\,000}{8\,000} = 1\,250 \text{ pacotes/s.}$$

6.1.4 Lei de Little

Seja a a taxa média efetiva de chegada de pacotes, medida em pacotes por segundo.

A Lei de Little afirma que

$$\boxed{\text{número médio} = \text{taxa média de chegada} \times \text{tempo médio}}.$$

Podemos aplicá-la separadamente à fila de espera, ao servidor e ao sistema completo:

$$\overline{N}_q = aW, \tag{27}$$

$$\overline{N}_s = aS, \tag{28}$$

$$\overline{N} = aT. \tag{29}$$

A região usada para contar os pacotes deve ser a mesma região usada para medir o tempo. Por exemplo:

- $\overline{N}_q$ é associado apenas ao tempo de espera W ;
- $\overline{N}_s$ é associado apenas ao tempo de serviço S ;
- $\overline{N}$ é associado ao tempo total $T = W + S$.

6.1.4.1 Intuição para a Lei de Little

Considere um intervalo longo de duração t . Nesse intervalo, chegam aproximadamente

$$at$$

pacotes.

Se cada pacote passa, em média, T segundos no sistema, esses pacotes acumulam aproximadamente

$$(at)T$$

pacote-segundos.

Por outro lado, se há, em média, $\overline{N}$ pacotes no sistema, a área sob a curva que representa o número de pacotes presentes é aproximadamente

$$\overline{N}t.$$

As duas expressões contam a mesma quantidade. Logo,

$$\overline{N}t = (at)T.$$

Cancelando t , obtemos

$$\overline{N} = aT.$$

6.1.4.2 Exemplo

Um enlace recebe, em média,

$$a = 200 \text{ pacotes/s.}$$

Cada pacote passa, em média,

$$T = 15 \text{ ms} = 0,015 \text{ s}$$

no sistema. Pela Lei de Little,

$$\overline{N} = aT = 200 \times 0,015 = 3.$$

Portanto, há, em média, três pacotes no sistema, contando os pacotes na fila e o pacote em transmissão.

6.1.5 Intensidade de tráfego

A intensidade de tráfego é definida por

$$I = \frac{aL}{R}.$$

Como

$$\mu = \frac{R}{L},$$

podemos escrever

$$I = \frac{a}{\mu}.$$

Em teoria de filas, é comum representar a intensidade de tráfego pela letra ρ . Assim,

$$\rho = \frac{a}{\mu} \quad \text{e, nestas notas,} \quad I = \rho.$$

A quantidade I não possui unidade:

$$I = \frac{\text{pacotes/s}}{\text{pacotes/s}}.$$

6.1.6 Intensidade de tráfego e utilização

Seja U a fração do tempo durante a qual o servidor está ocupado.

Quando o servidor está ocupado, ele transmite à taxa $\mu = R/L$ pacotes/s. Quando está vazio, sua taxa de saída é zero. Portanto, a taxa média de saída é

$$U \frac{R}{L} + (1 - U)0.$$

Em equilíbrio, a taxa média de saída deve ser igual à taxa média de entrada:

$$a = U \frac{R}{L}.$$

Isolando U , obtemos

$$U = \frac{aL}{R}.$$

Como $I = aL/R$,

$$\boxed{U = I = \rho}.$$

Assim, a intensidade de tráfego também representa a fração do tempo durante a qual o enlace está ocupado.

6.1.7 Número médio de pacotes no servidor

Como há apenas um servidor,

$$N_s(t) = \begin{cases} 1, & \text{se o servidor estiver ocupado,} \\ 0, & \text{se o servidor estiver vazio.} \end{cases}$$

Consequentemente,

$$\overline{N}_s = 1 \cdot U + 0 \cdot (1 - U) \tag{30}$$

$$= U. \tag{31}$$

Como $U = I$,

$$\boxed{\overline{N}_s = I}.$$

Podemos obter o mesmo resultado diretamente pela Lei de Little:

$$\overline{N}_s = aS = a \frac{L}{R} = I.$$

Por exemplo, se $I = 0,8$, então

$$\overline{N}_s = 0,8.$$

Isso significa que o servidor está ocupado durante 80% do tempo e vazio durante 20% do tempo. Não significa que exista uma fração de pacote no servidor.

6.1.8 Condição de estabilidade

Para que o sistema seja estável, a taxa média de chegada deve ser inferior à taxa média de serviço:

$$a < \mu.$$

Equivalentemente,

$$\boxed{I < 1}.$$

Se $I > 1$, chegam mais pacotes por segundo do que o enlace consegue transmitir.

- Com buffer ilimitado, a fila cresce sem limite.
- Com buffer finito, pacotes acabam sendo descartados.
- Mesmo quando $I < 1$, podem ocorrer filas devido às flutuações aleatórias das chegadas.

Uma utilização média inferior a 1 é necessária para a estabilidade, mas não garante que o atraso seja pequeno.

6.1.9 O que a Lei de Little não determina

A Lei de Little fornece as relações

$$\overline{N}_q = aW, \quad \overline{N}_s = aS, \quad \overline{N} = aT,$$

mas não determina, sozinha, os valores de W , T ou $\overline{N}$.

Para obter fórmulas explícitas para essas quantidades, precisamos especificar um modelo para:

- o processo de chegada;
- a distribuição dos tempos de serviço;
- o número de servidores;
- a política de atendimento;
- o tamanho do buffer.

A seguir, adotaremos o modelo $M/M/1$.

6.2 A fila $M/M/1$

O modelo $M/M/1$ possui as seguintes hipóteses:

- as chegadas formam um processo de Poisson com taxa a ;

- os tempos de serviço são exponenciais com média $1/\mu = L/R$;
- há um único servidor;
- o buffer é ilimitado;
- os pacotes são atendidos por ordem de chegada;
- $a < \mu$.

A hipótese exponencial implica a propriedade de falta de memória:

$$\Pr(S > x + y \mid S > x) = \Pr(S > y).$$

Portanto, quando um pacote chega e encontra outro pacote sendo transmitido, o tempo residual médio dessa transmissão continua sendo

$$\frac{1}{\mu}.$$

6.2.1 Tempo médio na fila

Um pacote que chega encontra, em média:

- $\overline{N}_q$ pacotes esperando;
- um pacote no servidor com probabilidade I .

Como as chegadas são Poisson, uma chegada observa as médias temporais do sistema. Essa propriedade é conhecida como PASTA: *Poisson Arrivals See Time Averages*.

Cada pacote à frente requer, em média, $1/\mu$ segundos de serviço. Assim,

$$W = (\overline{N}_q + I) \frac{1}{\mu}.$$

Pela Lei de Little,

$$\overline{N}_q = aW.$$

Substituindo,

$$W = (aW + I) \frac{1}{\mu}.$$

Multiplicando por μ ,

$$\mu W = aW + I.$$

Portanto,

$$(\mu - a)W = I$$

e

$$W = \frac{I}{\mu - a}.$$

Como

$$I = \frac{a}{\mu},$$

temos

$$\mu - a = \mu(1 - I).$$

Logo,

$$W = \frac{I}{\mu(1 - I)} = \frac{I L/R}{1 - I}.$$

6.2.2 Tempo médio total no sistema

O tempo total no sistema é

$$T = W + \frac{1}{\mu}.$$

Substituindo a expressão de W ,

$$T = \frac{I}{\mu(1 - I)} + \frac{1}{\mu} \tag{32}$$

$$= \frac{I}{\mu(1 - I)} + \frac{1 - I}{\mu(1 - I)} \tag{33}$$

$$= \frac{1}{\mu(1 - I)}. \tag{34}$$

Portanto,

$$T = \frac{1}{\mu(1 - I)} = \frac{1}{\mu - a}.$$

Usando $\mu = R/L$ e $I = aL/R$, também podemos escrever

$$T = \frac{L/R}{1 - aL/R}.$$

6.2.3 Número médio de pacotes

Pela Lei de Little,

$$\bar{N} = aT.$$

Substituindo $T = 1/(\mu - a)$,

$$\bar{N} = \frac{a}{\mu - a}.$$

Dividindo o numerador e o denominador por μ ,

$$\boxed{\bar{N} = \frac{I}{1 - I}}.$$

O número médio de pacotes na fila de espera é

$$\bar{N}_q = aW.$$

Portanto,

$$\bar{N}_q = a \frac{I}{\mu(1 - I)} \tag{35}$$

$$= \frac{I^2}{1 - I}. \tag{36}$$

Assim,

$$\boxed{\bar{N}_q = \frac{I^2}{1 - I}}.$$

Podemos verificar que

$$\bar{N}_q + \bar{N}_s = \frac{I^2}{1 - I} + I \tag{37}$$

$$= \frac{I^2 + I(1 - I)}{1 - I} \tag{38}$$

$$= \frac{I}{1 - I} \tag{39}$$


$$= \bar{N}. \tag{40}$$

6.2.4 Crescimento do número médio de pacotes

A expressão

$$\bar{N} = \frac{I}{1 - I}$$

mostra que o número médio de pacotes cresce rapidamente quando I se aproxima de 1.



Alguns valores ilustrativos são:

I	$\bar{N} = I/(1 - I)$
0,20	0,25
0,50	1
0,80	4
0,90	9
0,95	19

Aumentar a utilização de 80% para 90% mais do que duplica o número médio de pacotes:

$$4 \longrightarrow 9.$$

6.2.5 Exemplo numérico

Considere um enlace com

$$R = 10 \text{ Mbit/s}, \quad L = 1\,000 \text{ bytes}, \quad a = 800 \text{ pacotes/s}.$$

Convertendo o tamanho dos pacotes para bits,

$$L = 8\,000 \text{ bits}.$$

A taxa de serviço é

$$\mu = \frac{10\,000\,000}{8\,000} = 1\,250 \text{ pacotes/s}.$$

A intensidade de tráfego é

$$I = \frac{a}{\mu} = \frac{800}{1\,250} = 0,64.$$

Como $I < 1$, o sistema pode ser estável. No modelo $M/M/1$,

$$\bar{N} = \frac{0,64}{1 - 0,64} \approx 1,78 \text{ pacotes.}$$

O tempo médio total é

$$T = \frac{\bar{N}}{a} = \frac{1,78}{800} \approx 0,00222 \text{ s.}$$

Portanto,

$$\boxed{T \approx 2,22 \text{ ms}}.$$

O tempo médio de serviço é

$$S = \frac{L}{R} = 0,8 \text{ ms.}$$

Logo, o tempo médio na fila é

$$W = T - S \approx 2,22 - 0,8 = 1,42 \text{ ms.}$$

6.2.6 E se todos os pacotes tiverem o mesmo tamanho?

A fórmula

$$\bar{N} = \frac{I}{1 - I}$$

não vale para qualquer sistema com intensidade I . Ela foi obtida usando as hipóteses do modelo $M/M/1$, especialmente a hipótese de tempos de serviço exponenciais.

Se todos os pacotes tiverem exatamente L bits, o tempo de serviço será determinístico. Com chegadas Poisson, o modelo correspondente será $M/D/1$.

Na fila $M/M/1$,

$$W_{M/M/1} = \frac{I}{\mu(1 - I)}.$$

Na fila $M/D/1$,

$$W_{M/D/1} = \frac{I}{2\mu(1 - I)}.$$

Portanto,

$$W_{M/D/1} = \frac{1}{2} W_{M/M/1}.$$

A Lei de Little continua válida nos dois casos. O que muda é o atraso obtido a partir do modelo. A maior variabilidade dos tempos de serviço no modelo $M/M/1$ aumenta o tempo médio de espera.

6.3 Síntese

As principais relações desta aula são:

$$\mu = \frac{R}{L}$$

$$I = \frac{a}{\mu} = \frac{aL}{R}$$

$$\overline{N}_q = aW, \quad \overline{N}_s = aS, \quad \overline{N} = aT$$

$$\overline{N}_s = I$$

Para o modelo $M/M/1$,

$$W = \frac{I}{\mu(1-I)}$$

$$T = \frac{1}{\mu(1-I)} = \frac{1}{\mu - a}$$

$$\overline{N}_q = \frac{I^2}{1-I}, \quad \overline{N} = \frac{I}{1-I}.$$

6.4 Questões de revisão

1. Qual é a diferença entre fila de espera, servidor e sistema?
2. O que significa afirmar que $\overline{N}_s = 0,75$?
3. Por que a intensidade de tráfego também representa a utilização do servidor?
4. Por que $I < 1$ é uma condição necessária para a estabilidade?
5. A Lei de Little depende de chegadas Poisson ou de tempos de serviço exponenciais?
6. A fórmula

$$\overline{N} = \frac{I}{1-I}$$

vale para qualquer fila? Quais hipóteses foram usadas para obtê-la?

7. Dois sistemas com a mesma intensidade de tráfego necessariamente apresentam o mesmo atraso médio?
8. Um enlace de 20 Mbit/s recebe 1 000 pacotes/s, com tamanho médio de 1 500 bytes. Calcule μ e I .
9. Em um sistema, há em média oito pacotes e a taxa de chegada é 400 pacotes/s. Use a Lei de Little para determinar o tempo médio no sistema.
10. Em uma fila $M/M/1$, o que acontece com W , T e $\overline{N}$ quando I se aproxima de 1?

AULA 7 | 02/09/2026 – quarta-feira**Modelos probabilísticos, revisão de filas e camadas de protocolo****Cobertura:** Revisão do Slide 52**7.1 Observações sobre o teste**

A aula começou com comentários sobre o teste. Quatro pontos foram destacados.

7.1.1 Modelagem de situações de incerteza

O primeiro ponto é reconhecer qual distribuição descreve cada situação. Cada uma responde a uma pergunta diferente.

- $Z \sim \text{Ber}(p)$: situações de sucesso ou fracasso, isto é, um único experimento com dois resultados possíveis;
- $X \sim \text{Bin}(n, p)$: situações em que se deseja contar a quantidade de sucessos em n tentativas independentes;
- $Y \sim \text{Geo}(p)$: situações em que se deseja contar a quantidade de tentativas até o primeiro sucesso;
- $W \sim \text{Poi}(\lambda)$: situações em que se deseja contar o número de ocorrências em um dado intervalo de tempo.

A variável binomial é construída a partir de variáveis de Bernoulli:

$$X = \sum_{i=1}^n Z_i.$$

A variável geométrica também é construída a partir das mesmas variáveis, mas registrando a posição do primeiro sucesso:

$$Y = \arg \min_i \{Z_i : Z_i = 1\}.$$


Na variável de Poisson, o parâmetro é o produto da taxa pelo intervalo de interesse:

$$\boxed{\lambda = \tilde{\lambda} T},$$

em que $\tilde{\lambda}$ é a taxa de ocorrências por unidade de tempo e T é a duração do intervalo observado.

7.1.1.1 Relações entre as distribuições

As distribuições não são independentes umas das outras. Há uma conexão entre todas elas:



Dois limites foram destacados em aula:

- quando $n \rightarrow \infty$, a soma $X = \sum_i Z_i$ se aproxima de uma Gaussiana;
- quando $n \rightarrow \infty$ com $np = \lambda$ fixo, a binomial se aproxima de uma Poisson. Em sala, comentou-se que valores de n a partir de aproximadamente 10 já produzem uma aproximação razoável.

Uma diferença estrutural importante é o suporte de cada variável:

- o suporte da binomial é finito, $X \in \{0, 1, 2, \dots, n\}$;
- o suporte da geométrica é infinito, $Y \in \{1, 2, 3, \dots\}$;
- o suporte da Poisson é infinito, $W \in \{0, 1, 2, \dots\}$.

Por esse motivo, muitas vezes é mais conveniente trabalhar com a Poisson do que com a binomial: a expressão da Poisson depende de um único parâmetro.

Exemplo de escolha do parâmetro. Se escolhermos $\lambda = 7$ em uma janela de 5 minutos, isso significa que, na média, chegam 7 clientes a cada 5 minutos. O parâmetro da Poisson é sempre um número médio de ocorrências, não uma probabilidade.

7.1.2 PMF aplicada em um ponto

A função massa de probabilidade (PMF) quantifica a probabilidade de uma realização específica da variável aleatória.

Para a binomial,

$$\Pr(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k \in \{0, 1, \dots, n\}.$$

O coeficiente $\binom{n}{k}$ é a combinação de n elementos tomados k a k ; ele conta de quantas maneiras os k sucessos podem se distribuir entre as n tentativas.

Para a geométrica,

$$\Pr(Y = k) = (1 - p)^{k-1} p, \quad k \in \{1, 2, 3, \dots\}.$$

Observe que a geométrica começa em 1: é preciso ao menos uma tentativa para haver um primeiro sucesso.

Para a Poisson,

$$\Pr(W = w) = \frac{e^{-\lambda T} (\lambda T)^w}{w!}, \quad w \in \{0, 1, 2, \dots\}.$$

7.1.3 Notação da CDF

A função de distribuição acumulada (CDF) é definida por

$$F_X(k) = \Pr(X \leq k).$$

A CDF acumula a PMF até o ponto k , inclusive. A distinção entre $\leq$ e $<$ é essencial em variáveis discretas.

7.1.4 Cálculo de $\Pr(X \geq k)$

Seja $X \sim \text{Bin}(n, p)$. Há duas formas de calcular $\Pr(X \geq k)$.

(a) **Soma direta de PMFs.**

$$\Pr(X \geq k) = \sum_{i=k}^n \binom{n}{i} p^i (1-p)^{n-i}.$$

(b) **Complementar da CDF aplicada em um ponto.**

$$\Pr(X \geq k) = 1 - \Pr(X \leq k-1) = 1 - F_X(k-1).$$

A estratégia é acumular até um valor e depois complementar. O cuidado está no índice: o complementar de $X \geq k$ é $X \leq k-1$, e não $X \leq k$.

Exemplo discutido em sala. Arremessos de bola de basquete em uma cesta, com

$$n = 10 \text{ (jogou 10 vezes)}, \quad p = \text{probabilidade de acertar uma tentativa}.$$

Cada arremesso é uma variável de Bernoulli, e o total de acertos é binomial.

7.2 Revisão da aula passada

A segunda parte da aula retomou o modelo de filas visto na Aula 6.

7.2.1 Nota sobre notação


O quadro desta aula usa λ para a taxa média de chegada e barras sobre os tempos médios. A correspondência com a notação da Aula 6 é:

$$\lambda = a, \quad \overline{W} = W, \quad \overline{S} = S, \quad \overline{T} = T.$$

Nesta aula, adotamos a notação do quadro.

7.2.2 Os três elementos

O sistema estudado tem três elementos: a taxa de chegada, a fila e o servidor.



O tempo de serviço médio é

$$\bar{S} = \frac{1}{\mu} = \frac{\bar{L}}{R},$$


em que $\bar{L}$ é o tamanho médio do pacote e R é a taxa do enlace.

A intensidade de tráfego é a probabilidade de o servidor estar ocupado:

$$I = \Pr(\text{ocupado}) < 1.$$

7.2.3 Fluxo de Poisson, variável de Poisson e variável exponencial

Um ponto central da revisão é que “Poisson” aparece em dois papéis diferentes: como fluxo de chegadas e como variável aleatória discreta. Ligada a esse fluxo há ainda uma variável contínua, a exponencial.



A variável de Poisson responde à pergunta: qual a probabilidade de haver w chegadas em um intervalo T qualquer?

$$\Pr(W = w) = \frac{e^{-\lambda T} (\lambda T)^w}{w!}.$$

A variável exponencial responde à pergunta complementar. Definindo

$$V \triangleq \text{tempo até a próxima chegada},$$

o evento $V > T$ significa que nenhuma chegada ocorreu no intervalo T . Logo,

$$\Pr(V > T) = \Pr(W = 0) = e^{-\lambda T}.$$

Essa é a ponte entre as duas descrições: contar chegadas em um intervalo (discreto) e medir o tempo entre chegadas (contínuo) são duas leituras do mesmo fluxo.

7.2.4 Chegadas de Poisson e o estado do sistema

Como as chegadas são de Poisson, um pacote que chega enxerga o sistema no seu estado médio de longo prazo. Ele não chega em um instante privilegiado. Essa é a propriedade PASTA, *Poisson Arrivals See Time Averages*, apresentada na Aula 6.

7.2.5 A conta do tempo médio de espera

Um pacote que chega precisa esperar que todo o trabalho pendente à sua frente seja executado. Esse trabalho pendente é composto por:

- os $\bar{N}_q$ pacotes que estão na fila;
- o pacote que está no servidor, presente em média $\bar{N}_s = I$.

Cada um deles consome, em média, $\bar{S}$ segundos. Portanto,

$$\bar{W} = (\bar{N}_q + \bar{N}_s) \bar{S}.$$

Duas hipóteses sustentam essa expressão:

1. **PASTA:** a chegada observa as médias temporais do sistema;
2. **falta de memória do serviço:** o pacote que já está sendo transmitido ainda demanda, em média, $\bar{S}$ segundos, e não menos.

Aplicando a Lei de Little, $\bar{N}_q = \lambda \bar{W}$, e usando $\bar{N}_s = I$:

$$\bar{W} = \lambda \bar{W} \bar{S} + I \bar{S}. \quad (41)$$

Como $\lambda \bar{S} = \lambda / \mu = I$,

$$\bar{W} = I \bar{W} + I \bar{S}.$$

Isolando $\bar{W}$,

$$\bar{W}(1 - I) = I \bar{S}$$

e portanto

$$\bar{W} = \frac{I \bar{S}}{1 - I}.$$

7.2.6 Número médio de pacotes

Pela Lei de Little aplicada à fila de espera,

$$\bar{N}_q = \lambda \bar{W} = \lambda \frac{I \bar{S}}{1 - I} = \frac{I^2}{1 - I},$$

pois $\lambda \bar{S} = I$. Assim,

$$\overline{N}_q = \frac{I^2}{1 - I}.$$


Somando o pacote em serviço,

$$\overline{N} = \overline{N}_q + \overline{N}_s = \frac{I^2}{1 - I} + I = \frac{I}{1 - I}.$$

Portanto,

$$\overline{N} = \frac{I}{1 - I}.$$

O gráfico de $\overline{N}$ contra I , revisto em aula, cresce sem limite quando $I \rightarrow 1$:



7.2.7 Condição de equilíbrio

Foi retomada a observação do Kurose: o sistema só está em equilíbrio se a taxa de chegada for menor do que a capacidade de serviço. Essa é uma condição *necessária* para o sistema estar em equilíbrio, e corresponde a $I < 1$.


Além disso, se $\overline{S}$ aumenta, então $\overline{W}$ e $\overline{T}$ aumentam. Serviços mais lentos elevam a intensidade de tráfego e, com ela, o atraso.

7.3 Decomposição do atraso

O tempo total $\bar{T}$ percebido por um pacote se decompõe em parcelas distintas:

- $d_{\text{fila}} = \bar{W}$: espera na fila;
- $d_{\text{transm}} = \bar{S}$: tempo de transmissão, isto é, de serviço;
- d_{prop} : tempo de propagação no enlace.

O diagrama espaço-tempo torna a distinção visível. O eixo vertical representa o tempo, e as duas linhas verticais representam o transmissor e o receptor.




A altura do retângulo de cada pacote é o tempo de transmissão; a inclinação da reta é o tempo de propagação. A fila aparece como o intervalo entre a chegada do pacote e o início da sua transmissão.

7.4 Efeito da variabilidade: $M/D/1$ e $M/M/1$

Na fila $M/D/1$, o tempo de serviço é determinístico: todos os pacotes têm o mesmo tamanho, então todos os retângulos de transmissão têm a mesma altura e as retas de propagação são paralelas.

Na fila $M/M/1$, o tempo de serviço é exponencial: o tamanho do pacote é uma variável aleatória, então os retângulos têm alturas diferentes.



A comparação quantitativa foi vista na Aula 6:

$$\bar{W}_{M/D/1} = \frac{1}{2} \bar{W}_{M/M/1}.$$

A conclusão é que a variabilidade dos tempos de serviço, e não apenas a média, determina o atraso. Dois sistemas com a mesma intensidade de tráfego I podem ter atrasos médios diferentes.

7.5 Roteiro do Capítulo 1


- o que é a Internet;
- a borda da rede (*edge*);
- o núcleo da rede (*core*);
- atrasos e perdas;
- modelo em camadas;
- segurança;
- histórico.

O item de segurança veio acompanhado da referência ao livro *Fancy Bear Goes Phishing*, indicado como leitura complementar.

7.6 Camadas de protocolo

7.6.1 A analogia da companhia aérea

O Kurose apresenta a arquitetura em camadas por meio de uma analogia humana: o sistema de uma companhia aérea. Esse sistema envolve emissão de passagens, despacho de bagagem, portão de embarque, pilotos, aviões e controle de tráfego aéreo. Organizar essas funções em camadas permite descrever o sistema por partes.



Cada camada, combinada com as que estão abaixo dela, implementa um serviço:

- na camada da passagem e abaixo dela, realiza-se a transferência balcão-a-balcão do passageiro;
- na camada da bagagem e abaixo dela, realiza-se a transferência despacho-a-recuperação do passageiro e de suas malas;
- na camada do portão, realiza-se a transferência portão-a-portão;
- na camada de decolagem/aterriçagem, realiza-se a transferência pista-a-pista.

Cada camada provê seu serviço de duas maneiras: executando ações próprias e utilizando os serviços da camada imediatamente inferior.

Assim como as funções da companhia aérea estão distribuídas entre vários aeroportos, um protocolo de camada n está distribuído entre sistemas finais, comutadores de pacote e demais componentes da rede.

7.6.2 Vantagens e desvantagens

A principal vantagem é a modularidade: a divisão em camadas permite discutir uma parcela bem definida de um sistema grande e facilita a atualização de componentes.

- uma camada pode duplicar a funcionalidade de uma camada inferior. Por exemplo, várias pilhas oferecem recuperação de erros por enlace e também fim a fim, o que gera trabalho desnecessário;
- uma camada pode precisar de informação que só existe em outra camada, o que infringe o objetivo de separação entre elas.

O conjunto dos protocolos das várias camadas é denominado *pilha de protocolos*. A pilha da Internet tem cinco camadas: física, de enlace, de rede, de transporte e de aplicação. O livro é organizado nessa ordem, de cima para baixo, o que caracteriza a abordagem *top-down*.

7.7 Síntese

Distribuições e suas relações:

$$X = \sum_{i=1}^n Z_i, \quad Y = \arg \min_i \{Z_i : Z_i = 1\}, \quad \lambda = \tilde{\lambda} T$$

$$\Pr(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$\Pr(Y = k) = (1-p)^{k-1} p$$

$$\Pr(W = w) = \frac{e^{-\lambda T} (\lambda T)^w}{w!}$$

$$F_X(k) = \Pr(X \leq k), \quad \Pr(X \geq k) = 1 - F_X(k-1)$$

Fluxo de Poisson e tempo entre chegadas:

$$\Pr(V > T) = \Pr(W = 0) = e^{-\lambda T}$$

Filas:

$$\bar{S} = \frac{1}{\mu} = \frac{\bar{L}}{R}, \quad I = \Pr(\text{ocupado}) < 1$$

$$\bar{W} = (\bar{N}_q + \bar{N}_s) \bar{S} = \frac{I \bar{S}}{1 - I}$$

$$\overline{N}_q = \frac{I^2}{1-I}, \quad \overline{N} = \frac{I}{1-I}$$

Atraso:

$$\overline{T} = d_{\text{fila}} + d_{\text{transm}} + d_{\text{prop}}$$

7.8 Questões de revisão

1. Qual pergunta cada uma das distribuições responde: Bernoulli, binomial, geométrica e Poisson?
2. Por que a geométrica tem suporte $\{1, 2, 3, \dots\}$ e não $\{0, 1, 2, \dots\}$?
3. Sob quais condições a binomial se aproxima de uma Poisson? E de uma Gaussiana?
4. Em $\lambda = \tilde{\lambda}T$, o que representa cada fator? O que significa afirmar que $\lambda = 7$?
5. Escreva $\Pr(X \geq 3)$ para $X \sim \text{Bin}(10, p)$ das duas formas vistas em aula. Por que o complementar usa $\Pr(X \leq 2)$?
6. Qual é a diferença entre o fluxo de Poisson, a variável de Poisson e a variável exponencial?
7. Deduza $\Pr(V > T) = e^{-\lambda T}$ a partir da PMF de Poisson.
8. Quais são as duas hipóteses usadas para escrever $\overline{W} = (\overline{N}_q + \overline{N}_s)\overline{S}$?
9. Partindo dessa expressão e da Lei de Little, obtenha $\overline{W} = I\overline{S}/(1-I)$.
10. Quais parcelas compõem $\overline{T}$? Qual delas não depende da intensidade de tráfego?
11. Por que $M/D/1$ apresenta metade da espera de $M/M/1$, mesmo com a mesma intensidade de tráfego?
12. Na analogia da companhia aérea, qual serviço é prestado pela camada do portão e abaixo dela?
13. Quais são as cinco camadas da pilha de protocolos da Internet?

AULA 8 | 04/09/2026 – sexta-feira**Tempo residual de serviço, vazão e comunicação entre processos**

Cobertura: Fim do Capítulo 1 e início do Capítulo 2.

8.1 Estabilidade e ocupação do servidor

Há uma distinção que precisa ficar clara: um sistema pode estar com o servidor permanentemente ocupado sem que isso implique instabilidade.

Na fila $M/M/1$, a condição de estabilidade é

$$I < 1,$$

e o sistema é instável caso contrário. Isso decorre das flutuações aleatórias: com chegadas de Poisson e serviço exponencial, mesmo com I próximo de 1 ocorrem rajadas que fazem a fila crescer, e é preciso folga para que ela se esvazie.

8.1.1 Existe sistema estável com $I = 1$?

Sim. Considere a fila $D/D/1$:

- chegadas determinísticas;
- tempos de serviço determinísticos;
- um único servidor.

Se um pacote chega exatamente a cada $1/\lambda$ segundos e cada pacote leva exatamente $\bar{S} = 1/\mu$ segundos para ser transmitido, com $\lambda = \mu$, então cada pacote encontra o servidor livre no instante exato em que chega. O servidor fica ocupado 100% do tempo, ou seja, $I = 1$, e mesmo assim a fila nunca cresce: não há espera.

A conclusão é que a condição $I < 1$ é necessária apenas quando existe aleatoriedade. O que gera fila não é a utilização alta em si, mas a variabilidade em torno dela.

8.2 Tempo residual de serviço

Um pacote que chega e encontra o servidor ocupado não espera um tempo de serviço completo pelo pacote em transmissão: espera apenas o que falta dele. Essa quantidade é o tempo residual de serviço, denotado $\bar{S}_R$.

8.2.1 A expressão geral da espera

A espera se decompõe em duas parcelas:

$$\boxed{\bar{W} = \bar{N}_q \bar{S} + \bar{N}_s \bar{S}_R}.$$


O primeiro termo considera os pacotes que estão inteiramente na fila: cada um deles ainda será transmitido por completo, consumindo $\bar{S}$ segundos. O segundo termo trata do pacote que já está no servidor, e por isso usa o tempo residual e não o tempo completo.

O peso do segundo termo é a probabilidade de haver alguém em serviço:

$$\boxed{\bar{N}_s = I = U = \Pr(\text{ocupação})}.$$

8.2.2 Cálculo do tempo residual

Considere o eixo do tempo dividido pelas transmissões sucessivas, cada uma com duração L/R . Um pacote que chega cai em um ponto qualquer de um desses intervalos, e o que ele espera é a distância desse ponto até o fim do intervalo.



Como as chegadas não escolhem o instante em que ocorrem, intervalos longos têm mais chance de receber uma chegada do que intervalos curtos, e exatamente na proporção da sua duração. Isso faz o segundo momento aparecer:

$$\boxed{\bar{S}_R = \frac{\bar{S}^2}{2\bar{S}} = \frac{\mathbb{E}(S^2)}{2\mathbb{E}(S)}}.$$

O numerador é o segundo momento do tempo de serviço, isto é, a esperança de S^2 .

8.2.3 Os dois casos particulares

8.2.3.1 Serviço exponencial: $M/M/1$

Para o tempo de serviço exponencial de média $1/\mu$,

$$\mathbb{E}(S) = \frac{1}{\mu}, \quad \mathbb{E}(S^2) = \frac{2}{\mu^2}.$$

Logo,

$$\bar{S}_R = \frac{2/\mu^2}{2/\mu} = \frac{1}{\mu} = \bar{S}.$$

O tempo residual é igual ao tempo de serviço completo. Esse é o significado concreto da propriedade *memoryless*: saber que a transmissão já começou não adianta nada. A espera fica

$$\boxed{\bar{W}_{M/M/1} = \bar{N}_q \bar{S} + \bar{N}_s \bar{S}}.$$

8.2.3.2 Serviço determinístico: $M/D/1$

Para o tempo de serviço constante e igual a $\bar{S}$,

$$\mathbb{E}(S) = \bar{S}, \quad \mathbb{E}(S^2) = \bar{S}^2.$$

Logo,

$$\bar{S}_R = \frac{\bar{S}^2}{2\bar{S}} = \frac{\bar{S}}{2}.$$

Uma chegada em um instante qualquer encontra, em média, metade da transmissão já concluída. A espera fica

$$\boxed{\bar{W}_{M/D/1} = \bar{N}_q \bar{S} + \bar{N}_s \frac{\bar{S}}{2}}.$$

8.2.3.3 Resolvendo o caso determinístico

Aplicando a Lei de Little, $\bar{N}_q = \lambda \bar{W}$, e usando $\bar{N}_s = I$ com $\lambda \bar{S} = I$:

$$\bar{W} = \lambda \bar{W} \bar{S} + I \frac{\bar{S}}{2} \tag{42}$$

$$= I \bar{W} + \frac{I \bar{S}}{2}. \tag{43}$$

Isolando,

$$\bar{W}(1 - I) = \frac{I \bar{S}}{2}$$

e portanto

$$\boxed{\bar{W}_{M/D/1} = \frac{I \bar{S}}{2(1 - I)} = \frac{1}{2} \bar{W}_{M/M/1}}.$$


8.2.4 O papel da variabilidade

A expressão de $\bar{S}_R$ depende do segundo momento, e não apenas da média. Duas filas podem ter o mesmo $\bar{S}$, a mesma taxa de chegada e a mesma intensidade de tráfego, e ainda assim apresentar esperas diferentes. Quanto maior a variabilidade dos tempos de serviço, maior o tempo residual e pior o desempenho.

Vale notar que várias aplicações geram pacotes com tamanho determinístico: a aplicação usa sempre o mesmo tamanho, o que aproxima o comportamento do caso $M/D/1$ e reduz a espera pela metade em relação ao caso exponencial.

8.3 Distribuição do número de pacotes

O sistema pode ser descrito pelos estados $0, 1, 2, 3, \dots$, em que o estado n significa haver n pacotes no sistema. As transições ocorrem para o estado seguinte à taxa λ , quando chega um pacote, e para o estado anterior à taxa μ , quando um pacote termina de ser servido.



A probabilidade de o sistema estar vazio é o complementar da probabilidade de estar ocupado:

$$\pi_0 = 1 - \text{Pr}(\text{ocupado}) = 1 - \rho = 1 - U = 1 - I.$$

8.4 Vazão

8.4.1 Vazão instantânea e vazão média

A vazão instantânea é a taxa com que os bits estão sendo entregues em um dado momento. Enquanto o servidor transmite, ela vale

$$\frac{R}{L} = \mu,$$

e enquanto o servidor está ocioso, ela vale zero.

A vazão média é obtida condicionando nos dois estados possíveis:

$$\text{vazão média} = (\text{vazão} \mid \text{ocupado}) \text{Pr}(\text{ocupado}) + (\text{vazão} \mid \text{ocioso}) \text{Pr}(\text{ocioso}).$$

Substituindo cada termo,


$$\lambda = \mu I + 0 \cdot (1 - I).$$

Essa identidade confirma que $I = \lambda/\mu$: em equilíbrio, o que entra é igual ao que sai, e a única forma de o servidor entregar λ pacotes por segundo transmitindo à taxa μ é ficar ocupado durante a fração I do tempo.

8.4.2 Vazão fim a fim e gargalo

Em um caminho fim a fim, a vazão é limitada pelo enlace mais restritivo. Considere um servidor com taxa de acesso R_s , um cliente com taxa de acesso R_c e um enlace intermediário de taxa R compartilhado por 10 conexões simultâneas. A vazão de cada conexão é

$$\min\left(R_c, R_s, \frac{R}{10}\right).$$



Um cache instalado próximo ao cliente altera essa conta. Uma fração p_{hit} das requisições é atendida localmente, sem atravessar o gargalo; apenas a fração p_{miss} percorre o caminho completo. O tráfego que efetivamente disputa o enlace compartilhado é reduzido pelo fator p_{miss} , o que diminui a intensidade de tráfego naquele enlace e, com ela, o atraso de fila. O cache do navegador é um exemplo desse mecanismo.

8.5 Medição do atraso

8.5.1 TTL

Todo pacote carrega um campo TTL, *time to live*, que é decrementado a cada roteador atravessado. Quando o campo chega a zero, o roteador descarta o pacote e devolve uma mensagem de erro à origem. O objetivo do campo é impedir que pacotes circulem indefinidamente em caso de laço de roteamento.

8.5.2 Traceroute

O traceroute explora esse mecanismo: envia pacotes com valores crescentes de TTL, de modo que cada roteador do caminho seja obrigado a responder na sua vez. Para cada salto são enviados três *probes*, e os três tempos são reportados.

Um valor medido, como 121 ms, é um tempo total: ele engloba o atraso de fila acumulado no caminho, além dos atrasos de transmissão, propagação e processamento. Por isso os três valores de um mesmo salto costumam diferir entre si.


Vale lembrar que $\bar{W}$ é uma média fixa, determinada pelos parâmetros do sistema, enquanto as amostras individuais de espera variam de pacote para pacote.

8.6 Custo da divisão em camadas

A modularidade das camadas tem um preço, e ele aparece em dois lugares.

Primeiro, cada camada mantém sua própria fila, o que significa uma fila por camada ao longo do percurso.

Segundo, cada camada atravessada acrescenta um cabeçalho ao pacote. O cabeçalho mais interno é o que só será examinado pelo destino final; os cabeçalhos externos são lidos e removidos pelos elementos intermediários.



8.7 Segurança

Três propriedades organizam a discussão de segurança, resumidas pela sigla AIC.

Availability (disponibilidade)	Integrity (integridade)	Confidentiality (confidencialidade)
DoS ataque ativo <i>firewall</i>	<i>spoofing</i> ataque ativo assinaturas, <i>hashes</i>	<i>sniffing</i> ataque passivo criptografia

A distinção entre ataque ativo e passivo é relevante: no ataque ativo há modificação ou injeção de tráfego, o que o torna detectável em princípio; no ataque passivo há apenas observação, e por isso a defesa é impedir a leitura, não a interceptação.

Como leitura complementar sobre o tema, foi indicado o livro *Fancy Bear Goes Phishing*.

8.8 Capítulo 2: comunicação entre processos

8.8.1 Formas de comunicação

Uma aplicação de rede não é um programa executando em uma máquina isolada: são processos em máquinas diferentes que trocam informação. Antes de tratar da rede, convém situar as formas gerais de comunicação entre processos (IPC):


- *pipes*;
- sinais;
- mensagens (*sockets*);
- memória compartilhada.

Dessas quatro, a comunicação por mensagens é a que interessa às redes, pois é a única que funciona entre máquinas distintas. A memória compartilhada pertence ao domínio da computação concorrente, dentro de uma mesma máquina.

Vale a distinção: *threads* já compartilham memória por padrão; processos não.

8.8.2 Sockets


O socket é o elemento entre a aplicação e a camada de transporte. Ele é implementado pelo sistema operacional, e é, concretamente, uma região de memória do sistema operacional.



As operações disponíveis sobre um socket são criar, ler e destruir. A aplicação escreve no socket e lê do socket; tudo o que acontece abaixo dele é responsabilidade do sistema operacional e da rede.

8.8.3 Portas

O endereço IP identifica a máquina; a porta identifica qual processo dentro dela deve receber os dados. Um mesmo servidor pode atender simultaneamente à porta 80, para HTTP, e à porta 25, para correio eletrônico.



8.8.4 Transporte: TCP e UDP

Há duas opções de transporte disponíveis para a aplicação:

- TCP: oferece muitos serviços à aplicação, e por isso é *heavyweight*;
- UDP: oferece quase nada, é minimalista e *lightweight*.

A escolha entre eles é uma decisão de projeto da aplicação: quanto do trabalho ela quer delegar ao transporte e quanto quer implementar por conta própria.

O HTTP tradicionalmente usa TCP, mas também pode operar sobre QUIC, que por sua vez roda sobre UDP.

O capítulo se encerra com a programação de uma aplicação usando sockets.

8.9 Síntese

Espera com tempo residual:

$$\bar{W} = \bar{N}_q \bar{S} + \bar{N}_s \bar{S}_R, \quad \bar{N}_s = I = U = \text{Pr(ocupação)}$$

$$\bar{S}_R = \frac{\bar{S}^2}{2\bar{S}} = \frac{\mathbb{E}(S^2)}{2\mathbb{E}(S)}$$

$$\bar{S}_R^{M/M/1} = \bar{S}, \quad \bar{S}_R^{M/D/1} = \frac{\bar{S}}{2}$$

$$\bar{W}_{M/D/1} = \frac{I \bar{S}}{2(1-I)} = \frac{1}{2} \bar{W}_{M/M/1}$$

Ocupação e vazão:

$$\pi_0 = 1 - \rho = 1 - U = 1 - I$$

$$\lambda = \mu I + 0 \cdot (1 - I)$$

$$\text{vazão fim a fim} = \min\left(R_c, R_s, \frac{R}{10}\right)$$

AULA 9 | 09/09/2026 – quarta-feira

Camada de Aplicação: HTTP, Desempenho e Conexões

Cobertura: Resolução de exercícios (Lei de Little), características do protocolo HTTP, modelos de conexão TCP (triângulo de *handshake*, objetos com linha grossa), análise de tempo (RTT) e evolução das versões do HTTP com *interleaving*.

9.1 Nota sobre a Lei de Little (Lista de Exercícios)

A partir da discussão do exercício P16 em sala, reforçamos uma premissa fundamental da teoria de filas:

Cuidado: Para aplicar a Lei de Little ($\bar{N} = \lambda \bar{T}$), o sistema precisa **necessariamente estar em equilíbrio** ($I < 1$). A questão discutida estava mal formulada porque violava esse princípio. Possíveis consertos matemáticos para tornar o sistema viável envolvem diminuir a taxa de chegada (λ), aumentar a taxa de serviço (μ) ou fixar $\bar{N}$ e $\bar{T}$ ajustando a entrada.

9.2 O Protocolo HTTP

O HTTP (*Hypertext Transfer Protocol*) é o protocolo base da Web, operando na camada de aplicação.

Protocolo Stateless: O HTTP é um protocolo sem estado. O conteúdo da resposta não depende do histórico de requisições anteriores. Para manter sessões (como logins), a web utiliza **cookies**.

9.3 Modelos de Conexão HTTP

O desempenho do HTTP depende de como ele utiliza as conexões da camada de transporte (TCP). Para iniciar qualquer requisição HTTP, primeiro é necessário estabelecer a conexão TCP através de um *Three-way Handshake*. Isso consome 1 RTT (*Round-Trip Time*) inicial apenas para sincronizar (SYN e SYN/ACK) antes mesmo do GET ser enviado.

A tabela abaixo unifica e resume as quatro abordagens formadas pela combinação da persistência e do paralelismo, oferecendo uma visão global:

	Sem Paralelismo	Com Paralelismo
Não Persistente	Fecha conexão após cada objeto; requisições e <i>handshakes</i> estritamente sequenciais.	Múltiplas conexões TCP (com seus respectivos <i>handshakes</i>) abertas simultaneamente.
Persistente	Uma única conexão TCP mantida aberta; requisições sequenciais na mesma via.	Reaproveita conexões TCP abertas e abre novas conexões em paralelo quando necessário.

Abaixo, detalhamos cada modelo com suas vantagens, desvantagens, diagrama de espaço-tempo e análise numérica do tempo envolvido. Nos diagramas, as setas cinzas formam o **triângulo do handshake TCP**, e as setas **mais grossas representam a transferência do objeto**.

9.3.1 1. HTTP Não Persistente (Sem Paralelismo)

Neste modelo, uma nova conexão TCP é aberta para solicitar um objeto e imediatamente fechada após a sua recepção. Os objetos são baixados um por vez.

- **Vantagens:** Consome menos recursos ociosos do servidor. Como a porta TCP é liberada rapidamente após o uso, é um modelo mais robusto contra ataques de negação de serviço que exploram conexões presas.
- **Desvantagens:** Pior desempenho de tempo. Paga-se a latência de um *handshake* TCP (1 RTT) para **cada** nova requisição de objeto na página, dobrando o tempo necessário para objetos pequenos.

Análise de Tempo: Para baixar o arquivo HTML base e n objetos referenciados (desprezando o tempo de transmissão dos objetos pequenos), gasta-se 2 RTT por arquivo. Tempo total:

$$\text{Tempo Total} \approx 2 \text{ RTT} + 2n \text{ RTT} = 2(n + 1) \text{ RTT}$$




Figure 8: Não Persistente Sem Paralelismo: O "triângulo" do TCP é formado antes de cada GET.

9.3.2 2. HTTP Não Persistente (Com Paralelismo)

O cliente abre *múltiplas* conexões TCP simultâneas para baixar os objetos paralelos (ex: imagens) ao mesmo tempo.

- **Vantagens:** O tempo de carregamento da página cai drasticamente, pois os RTTs dos objetos subsequentes são sobrepostos no tempo.
- **Desvantagens:** Exige um consumo severo de recursos. O servidor precisa alocar inúmeros *sockets*, *buffers* e processar vários *handshakes* simultaneamente para um único cliente, sobrecarregando o SO.

Análise de Tempo: Gasta-se 2 RTT para o HTML base e, assumindo paralelismo perfeito para os n objetos, mais 2 RTT simultâneos. Tempo total:

$$\text{Tempo Total} \approx 2 \text{ RTT (HTML)} + 2 \text{ RTT (Objetos)} = 4 \text{ RTT}$$




Figure 9: Não Persistente Com Paralelismo: Múltiplas conexões formam seus próprios triângulos e baixam dados ao mesmo tempo.

9.3.3 3. HTTP Persistente (Sem Paralelismo)

Apenas um *handshake* TCP é feito. A mesma conexão é mantida aberta. O cliente envia a requisição, aguarda receber o objeto inteiro, e então usa a mesma via para a próxima requisição.

- **Vantagens:** Evita a sobrecarga de abrir novas conexões (economiza 1 RTT de *handshake* por objeto subsequente) e poupa CPU/memória do servidor.
- **Desvantagens:** Mantém a conexão ociosa ocupando recursos do servidor no longo prazo. Continua sofrendo atrasos caso a resposta de um arquivo seja lenta, travando o envio do GET seguinte.

Análise de Tempo: 2 RTT para o HTML base (inclui TCP setup) e 1 RTT para cada um dos n objetos adicionais. Tempo total:

$$\text{Tempo Total} \approx 2 \text{ RTT} + n \text{ RTT} = (n + 2) \text{ RTT}$$




Figure 10: Persistente Sem Paralelismo: Apenas um *handshake* TCP inicial (triângulo superior).

9.3.4 4. HTTP Persistente (Com Paralelismo)

Para baixar múltiplos objetos ao mesmo tempo na web moderna, o cliente **reaproveita a conexão persistente já existente** para um dos objetos, mas **abre uma nova conexão TCP em paralelo** para solicitar o outro simultaneamente.

- **Vantagens:** Excelente desempenho. Poupa o RTT de abertura para os objetos que reaproveitam as conexões já abertas, enquanto mantém o paralelismo para acelerar o carregamento global da página.
- **Desvantagens:** Ainda consome múltiplos recursos do servidor (vários *sockets* abertos por cliente) e sofre com os recursos alocados enquanto as conexões são mantidas ociosas.

Análise de Tempo: O HTML custa 2 RTT. A 'Img1' reaproveita a conexão (1 RTT), enquanto a 'Img2' exige nova conexão (2 RTT). Sendo paralelas, o tempo final da etapa é o maior entre eles:

$$\text{Tempo Total} \approx 2 \text{ RTT (HTML)} + \max(1 \text{ RTT}, 2 \text{ RTT}) = 4 \text{ RTT}$$




Figure 11: Persistente Com Paralelismo: A Conexão 1 é reaproveitada para a Img1 poupando tempo, enquanto uma Nova Conexão 2 é aberta para baixar a Img2 simultaneamente.

9.4 Evolução do HTTP e a técnica de Interleaving

Para mitigar problemas clássicos de travamento de rede (onde a lentidão de um arquivo trava a transmissão dos menores, e.g., Head-of-Line Blocking), os protocolos evoluíram:

- **HTTP/1 (Básico):** Opera sobre **TCP**. As respostas do servidor são enviadas inteiras, de forma *FIFO* (First-In, First-Out). **Não possui** suporte nativo a *interleaving*.
- **HTTP/2:** Opera sobre **TCP**. Introduce o **interleaving** de forma nativa na mesma conexão, permitindo que as respostas venham em ordem mais estratégica.
- **HTTP/3:** Abandona o TCP em favor do **UDP**. Construído com o protocolo **QUIC** e com foco forte em **segurança**, reduz radicalmente a latência da conexão inicial (podendo zerar o RTT inicial).

9.4.1 O conceito de Interleaving

O **interleaving** permite que o servidor quebre os arquivos e envie suas partes **intercaladas** através da mesma conexão, não exigindo que um arquivo enorme termine de ser enviado antes de começar o próximo.

A ilusão de rapidez: O *interleaving* manda as partes intercaladas (um pouco de HTML, um pouco de Imagem, etc.) para fazer parecer ao usuário que a página está carregando mais rápido, já que o navegador consegue renderizar trechos dos elementos simultaneamente, ao invés de exibir uma página travada.




Figure 12: Diagrama esquemático do *interleaving* (HTTP/2). Note que o *handshake* TCP (triângulo cinza no topo) ocorre apenas uma vez, antes da transmissão fatiada.

9.5 Questões de revisão

1. Por que a fila $D/D/1$ pode ser estável com $I = 1$, enquanto a $M/M/1$ não pode?
2. O que caracteriza cada posição na notação $A/B/m$? Compare $D/D/1$, $M/D/1$ e $M/M/1$.
3. Por que a espera se escreve como $\bar{W} = \bar{N}_q \bar{S} + \bar{N}_s \bar{S}_R$ e não como $(\bar{N}_q + \bar{N}_s) \bar{S}$ em geral?
4. Por que o segundo momento aparece na expressão de $\bar{S}_R$?
5. Mostre que $\bar{S}_R = \bar{S}$ para serviço exponencial e $\bar{S}_R = \bar{S}/2$ para serviço determinístico.
6. Qual é a interpretação de $\bar{S}_R = \bar{S}$ em termos da propriedade *memoryless*?
7. Dois enlaces têm o mesmo $\bar{S}$ e a mesma taxa de chegada, mas variabilidades diferentes nos tempos de serviço. Qual tem maior espera? Por quê?
8. Obtenha $\bar{W}_{M/D/1}$ a partir da expressão geral e da Lei de Little.
9. Interprete $\pi_0 = 1 - I$. O que significa $\pi_0 = 0,2$?
10. Deduza $\lambda = \mu I$ condicionando a vazão nos estados ocupado e ocioso.
11. Em um caminho com $R_c = 5$ Mbit/s, $R_s = 100$ Mbit/s e um enlace compartilhado de $R = 20$ Mbit/s dividido por 10 conexões, qual é a vazão de cada conexão? Qual é o gargalo?
12. Como um cache próximo ao cliente altera a intensidade de tráfego no enlace de acesso?
13. Qual é a função do campo TTL e como o traceroute a utiliza?
14. Por que os três *probes* de um mesmo salto do traceroute costumam apresentar tempos diferentes?
15. Quais são as quatro formas de comunicação entre processos? Qual delas funciona entre máquinas distintas e por quê?
16. O que é um socket, quem o implementa e onde ele reside?
17. Qual é a diferença de papel entre o endereço IP e o número de porta?
18. Em que sentido o TCP é *heavyweight* e o UDP é *lightweight*? Sobre qual deles o QUIC opera?

AULA 10 | 11/09/2026 – sexta-feira**Cookies, cache Web, HTTP/2, correio eletrônico e DNS**

Cobertura: Capítulo 2, Slides 43 a 104.

10.1 Cookies e privacidade

O HTTP é um protocolo sem estado: cada requisição é tratada de forma independente, e o servidor não guarda memória das requisições anteriores. Isso simplifica o projeto do servidor, mas impede funcionalidades que dependem de continuidade, como um carrinho de compras ou uma sessão autenticada.

Os *cookies* resolvem isso reintroduzindo estado por fora do protocolo. São quatro componentes:

1. uma linha de cabeçalho na mensagem de resposta HTTP (**Set-cookie**);
2. uma linha de cabeçalho na mensagem de requisição HTTP (**Cookie**);
3. um arquivo mantido no computador do usuário e gerenciado pelo navegador;
4. um banco de dados no site.

O funcionamento é direto. Na primeira visita, o site gera um número de identificação, cria uma entrada no seu banco de dados indexada por esse número e o devolve no cabeçalho **Set-cookie**. O navegador armazena o número. Em toda requisição subsequente àquele site, o navegador envia o mesmo número no cabeçalho **Cookie**, e o servidor consegue associar aquela requisição a todas as anteriores.

Os usos legítimos são vários: autorização, carrinho de compras, recomendações, estado de sessão.

10.1.1 A questão da privacidade

O mesmo mecanismo permite rastreamento. O ponto central é que os objetos de uma página não precisam vir do mesmo servidor que a página. Quando uma página inclui um recurso hospedado por terceiros, o navegador faz uma requisição a esse terceiro e envia a ele o cookie correspondente.

Se o mesmo terceiro estiver presente em muitos sites diferentes, ele recebe uma requisição sempre que o usuário visita qualquer um deles, e todas essas requisições carregam o mesmo identificador. Com isso, é possível reconstruir o histórico de navegação do usuário através de sites não relacionados entre si, e associá-lo a um perfil.

Note que o site visitado não precisa informar nada ao terceiro: a simples inclusão do recurso já produz a requisição. O usuário também não é consultado, porque o envio do cookie é automático.


As contramedidas usuais são o bloqueio de cookies de terceiros pelo navegador, a limitação do tempo de vida dos cookies e o uso de modos de navegação que descartam o armazenamento ao fim da sessão.

10.2 Cache Web

Um cache Web, também chamado servidor *proxy*, é um elemento de rede que atende requisições HTTP em nome do servidor de origem. O navegador é configurado para dirigir todas as requisições ao cache.

O fluxo é o seguinte: o navegador abre uma conexão TCP com o cache e envia a requisição. Se o cache tiver uma cópia do objeto, ele a devolve imediatamente. Se não tiver, abre uma conexão TCP com o servidor de origem, requisita o objeto, guarda uma cópia local e devolve outra ao navegador.

Um cache é simultaneamente servidor e cliente: servidor em relação aos navegadores que atende, cliente em relação aos servidores de origem que consulta.



Há duas motivações. A primeira é reduzir o tempo de resposta percebido pelo cliente, já que o cache está próximo e ligado por um enlace rápido. A segunda, menos óbvia e mais importante, é reduzir o tráfego no enlace de acesso da instituição, o que evita a necessidade de ampliar esse enlace.

10.2.1 Exemplo numérico

Considere uma rede institucional com as seguintes características:

- tamanho médio do objeto: $L = 100$ kbits;
- taxa média de requisições: $a = 15$ requisições/s;
- enlace de acesso: $R = 1,54$ Mbit/s;
- atraso médio entre o roteador de acesso e os servidores de origem: 2 s;
- LAN institucional de alta velocidade, com atraso desprezível.

A taxa média de dados entregue aos navegadores é

$$La = 100\,000 \times 15 = 1,50 \text{ Mbit/s.}$$

10.2.1.1 Situação inicial

A intensidade de tráfego no enlace de acesso é

$$I = \frac{La}{R} = \frac{1,50}{1,54} \approx 0,974.$$

O número médio de objetos no enlace é

$$\bar{N} = \frac{I}{1 - I} \approx \frac{0,974}{0,026} \approx 37,5,$$

e o tempo médio no enlace é

$$\bar{T} = \frac{\bar{N}}{a} \approx \frac{37,5}{15} \approx 2,5 \text{ s.}$$

O atraso total fica em torno de 4,5 s: dois segundos na Internet pública e dois e meio na fila do enlace de acesso. O problema é a proximidade de I a 1: nessa região, pequenas variações na carga produzem variações enormes no atraso.

10.2.1.2 Primeira solução: ampliar o enlace

Elevando o enlace de acesso para $R = 154$ Mbit/s,

$$I = \frac{1,50}{154} \approx 0,0097,$$

o que torna o atraso de fila desprezível, da ordem de fração de milissegundo. O atraso total cai para aproximadamente 2,01 s, dominado pela travessia da Internet pública.

A solução funciona, mas é cara: multiplica por cem a capacidade contratada do enlace.

10.2.1.3 Segunda solução: instalar um cache

Suponha uma taxa de acerto de 0,4. Isso significa que 40% das requisições são atendidas localmente, em torno de 10 ms, e apenas 60% atravessam o enlace de acesso.

O tráfego no enlace passa a ser

$$0,6 \times 1,50 = 0,90 \text{ Mbit/s},$$

e a intensidade de tráfego cai para

$$I = \frac{0,90}{1,54} \approx 0,584.$$

Agora

$$\bar{N} = \frac{0,584}{0,416} \approx 1,41, \quad \bar{T} = \frac{1,41}{15} \approx 0,094 \text{ s}.$$

O atraso médio total é a média ponderada dos dois caminhos:

$$\bar{T}_{\text{total}} = 0,4 \times (0,01) + 0,6 \times (2 + 0,094) \tag{44}$$

$$\approx 0,004 + 1,256 \tag{45}$$

$$\approx 1,26 \text{ s}. \tag{46}$$

O resultado é melhor do que o da primeira solução, a um custo muito menor. Esse é o argumento central em favor dos caches: eles atacam a intensidade de tráfego no gargalo, e não a capacidade do gargalo.

10.2.2 GET condicional

O cache introduz um problema novo: a cópia armazenada pode estar desatualizada. O mecanismo que resolve isso é o GET condicional.

Ao guardar um objeto, o cache registra também a data da última modificação informada pelo servidor. Em uma requisição posterior, o cache inclui o cabeçalho

`If-modified-since: <data>.`

Se o objeto não mudou desde aquela data, o servidor responde com o código 304 `Not Modified` e um corpo vazio, o que economiza a transferência completa. Se mudou, responde normalmente com o objeto atualizado.

10.3 HTTP/2 e o bloqueio de cabeça de fila

No HTTP/1.1 com conexão persistente, o cliente pode enviar várias requisições seguidas, mas o servidor devolve os objetos na ordem em que foram pedidos, um após o outro, sobre a mesma conexão TCP.

Isso cria o bloqueio de cabeça de fila, ou *head-of-line blocking*: um objeto grande à frente atrasa todos os objetos pequenos atrás dele.

10.3.1 Exemplo

Um cliente requisita um objeto grande, como um arquivo de vídeo, e três objetos pequenos. Suponha que o objeto grande leve 10 unidades de tempo para ser transmitido e cada objeto pequeno leve 1.

Se o objeto grande for entregue primeiro, os instantes de conclusão são

10, 11, 12, 13,

com média

$$\frac{10 + 11 + 12 + 13}{4} = 11,5.$$


Se os objetos pequenos forem entregues primeiro, os instantes passam a ser

1, 2, 3, 13,

com média

$$\frac{1 + 2 + 3 + 13}{4} = 4,75.$$

O objeto grande termina no mesmo instante nos dois casos, mas o tempo médio de conclusão cai para menos da metade. Nenhuma capacidade foi adicionada: apenas mudou a ordem de atendimento.



10.3.2 A solução do HTTP/2

O HTTP/2 divide cada objeto em quadros de tamanho reduzido e intercala os quadros de objetos diferentes na conexão. Com isso, os objetos progridem em paralelo e um objeto grande deixa de monopolizar a conexão. O cliente pode ainda indicar prioridades entre os objetos.

Resta uma limitação: como tudo ainda trafega sobre uma única conexão TCP, a perda de um segmento bloqueia a entrega de todos os fluxos até a retransmissão. O HTTP/3 ataca esse ponto residual ao operar sobre QUIC, que roda sobre UDP e mantém os fluxos independentes.

10.4 Correio eletrônico

O sistema de correio eletrônico tem três componentes principais:

- agentes de usuário;
- servidores de correio;
- o protocolo SMTP, *simple mail transfer protocol*.


10.4.1 Agente de usuário

O agente de usuário é o programa de leitura e composição de mensagens. Ele permite compor, editar e ler mensagens, e as mensagens enviadas e recebidas ficam armazenadas no servidor, não no agente.

10.4.2 Servidor de correio

Cada servidor mantém, para cada usuário, uma caixa postal com as mensagens recebidas, e mantém também uma fila de mensagens de saída aguardando envio.

Se a entrega a um servidor remoto falhar, a mensagem permanece na fila e novas tentativas são feitas periodicamente.



10.4.3 SMTP

O SMTP usa TCP na porta 25 e transfere a mensagem diretamente do servidor de origem para o servidor de destino, sem servidores intermediários.

A transferência tem três fases: apresentação, transferência das mensagens e encerramento. A conexão é persistente, de modo que várias mensagens podem ser enviadas na mesma conexão.

Uma distinção importante: o SMTP é um protocolo de empurrar, pois quem inicia a conexão é quem tem a mensagem para entregar. Já o acesso à própria caixa postal é feito por protocolos de puxar, como IMAP ou uma interface Web.

10.5 DNS

10.5.1 O problema

Pessoas são identificadas de várias formas: nome, número de documento, passaporte. Hospedeiros e roteadores da Internet também têm dois identificadores:


- o endereço IP, de 32 bits, usado para endereçar datagramas;
- o nome, como `cs.umass.edu`, usado por pessoas.

O primeiro é conveniente para as máquinas, o segundo para os usuários. O DNS, *domain name system*, é o serviço que faz o mapeamento entre eles.

Além da tradução de nomes, o DNS oferece apelidos de hospedeiro, apelidos de servidor de correio e distribuição de carga, esta última associando vários endereços IP a um mesmo nome.

10.5.2 Base de dados distribuída e hierárquica

Um único servidor centralizado seria inviável: teria um ponto único de falha, concentraria todo o volume de tráfego, ficaria distante da maioria dos clientes e seria impossível de manter. Por isso o DNS é organizado como uma hierarquia de servidores.




- **Servidores raiz:** conhecem os servidores responsáveis por cada domínio de topo;
- **Servidores de domínio de topo (TLD):** responsáveis por `.com`, `.org`, `.edu`, e pelos domínios de país;
- **Servidores com autoridade:** guardam os registros oficiais das organizações, mantidos por elas próprias ou por um provedor.

Há ainda um servidor que não pertence à hierarquia mas é o primeiro a ser consultado: o servidor local, configurado pelo provedor de acesso ou pela instituição. O endereço `8.8.8.8` é um exemplo de servidor local público de uso geral.


10.5.3 Consulta iterativa e consulta recursiva

Suponha que um cliente queira o endereço IP de `amazon.com`. Em primeira aproximação, ele consulta um servidor raiz para descobrir o servidor `.com`, e em seguida consulta o servidor `.com` para descobrir o servidor de `amazon.com`. O que muda entre os dois modos é quem carrega o trabalho de percorrer essa cadeia.

Na consulta iterativa, cada servidor contactado responde com a referência do próximo servidor a consultar, e quem percorre a cadeia é o servidor local.



Na consulta recursiva, o servidor contactado assume a responsabilidade de obter a resposta completa e devolvê-la pronta a quem perguntou. A cadeia é percorrida servidor a servidor, e cada um responde apenas ao anterior.



A diferença prática está em onde fica a carga. A consulta recursiva transfere o trabalho para os servidores de nível mais alto, que atenderiam um volume proibitivo de requisições. Por isso, na prática, a consulta do cliente ao seu servidor local costuma ser recursiva, e dali para cima a cadeia costuma ser iterativa.

10.5.4 Cache DNS

Assim que um servidor aprende um mapeamento, ele o guarda localmente e o reutiliza nas consultas seguintes, descartando-o após um prazo de validade.

O efeito é grande: os registros dos servidores de domínio de topo costumam estar em cache nos servidores locais, o que faz com que os servidores raiz raramente sejam consultados de fato. O custo é que uma mudança de endereço só se propaga completamente depois que os registros antigos expiram.

10.5.5 Registros

A base de dados é formada por registros de recurso, cada um com nome, valor, tipo e prazo de validade. Os tipos principais são:

- **A:** o nome é um nome de hospedeiro e o valor é o endereço IP;
- **NS:** o nome é um domínio e o valor é o servidor com autoridade sobre ele;
- **CNAME:** o valor é o nome canônico correspondente a um apelido;
- **MX:** o valor é o nome do servidor de correio associado ao domínio.

10.6 Redes de distribuição de conteúdo

Um cache institucional reduz o tráfego de uma instituição. A generalização desse princípio em escala global é a rede de distribuição de conteúdo, ou CDN.

Uma empresa de CDN instala grupos de servidores geograficamente distribuídos e replica neles o conteúdo dos provedores. Quando um cliente requisita um objeto, ele é direcionado ao grupo mais próximo ou mais adequado, normalmente por meio do próprio DNS: a consulta ao nome do provedor retorna o endereço de um servidor da CDN em vez do endereço do servidor de origem.

O resultado é que a maior parte do tráfego passa a ser local, reduzindo simultaneamente o atraso percebido e a carga nos enlaces de longa distância.

10.7 Síntese

$$I = \frac{La}{R}, \quad \bar{N} = \frac{I}{1 - I}, \quad \bar{T} = \frac{\bar{N}}{a}$$

Com cache de taxa de acerto p , o tráfego no enlace de acesso passa a ser $(1 - p)La$, e o atraso médio total é

$$\bar{T}_{\text{total}} = p\bar{T}_{\text{cache}} + (1 - p)(\bar{T}_{\text{Internet}} + \bar{T}_{\text{acesso}}).$$

Mecanismo	Função
Cookie	estado em um protocolo sem estado
GET condicional	validar a cópia em cache
HTTP/2	intercalar quadros, mitigar HOL
SMTP (porta 25)	entregar mensagem entre servidores
IMAP, Web	acessar a própria caixa postal
DNS	traduzir nome em endereço IP
CDN	aproximar o conteúdo do cliente

10.8 Questões de revisão

1. Por que o HTTP é descrito como um protocolo sem estado, e quais são os quatro componentes que permitem contornar isso?
2. Como um terceiro presente em vários sites consegue reconstruir o histórico de navegação de um usuário?
3. Em que sentido um cache Web é, ao mesmo tempo, cliente e servidor?
4. Quais são as duas motivações para instalar um cache Web? Qual delas justifica o investimento do ponto de vista da instituição?
5. Com $L = 100$ kbits, $a = 15$ requisições/s e $R = 1,54$ Mbit/s, calcule I , $\bar{N}$ e $\bar{T}$.
6. Repita o cálculo anterior com $R = 154$ Mbit/s. Por que essa solução é considerada cara?
7. Com uma taxa de acerto de 0,4, recalcule a intensidade de tráfego no enlace de acesso e o atraso médio total.

8. Por que o cache é mais eficaz do que a ampliação do enlace, mesmo reduzindo o tráfego em apenas 40%?
9. O que é o GET condicional e qual código de resposta ele pode produzir?
10. Explique o bloqueio de cabeça de fila no HTTP/1.1.
11. Com um objeto de 10 unidades de tempo e três de 1 unidade, compare o tempo médio de conclusão nas duas ordens de atendimento. Por que o objeto grande termina no mesmo instante nos dois casos?
12. Como o HTTP/2 mitiga o problema, e qual limitação permanece?
13. Quais são os três componentes principais do correio eletrônico?
14. Por que o SMTP é classificado como protocolo de empurrar, enquanto o acesso à caixa postal usa protocolos de puxar?
15. Por que um único servidor DNS centralizado seria inviável?
16. Diferencie consulta iterativa de consulta recursiva. Qual é usada entre o cliente e o servidor local, e por quê?
17. Por que os servidores raiz são consultados com pouca frequência na prática?
18. Qual é a desvantagem do cache DNS quando um endereço muda?
19. Para que serve cada um dos tipos de registro A, NS, CNAME e MX?
20. Como uma CDN utiliza o DNS para direcionar o cliente?