

Notas de Aula – Redes de Computadores

2026

Estas notas organizam o conteúdo por encontro e combinam o planejamento da disciplina com os registros do quadro. O objetivo é oferecer um roteiro de revisão; os slides e o livro-texto continuam sendo as referências principais.

Aula	Data	Tema	Cobertura
1	12/08	Curso e Internet	Organização, avaliação, Internet e protocolos
2	14/08	Borda e acesso	Hosts, AP/BS, redes de acesso e comutação
3	19/08	Núcleo e medição	Atrasos, núcleo da rede e <i>packet pair</i>
4	21/08	Bloqueio	Multiplexação estatística, binomial e Poisson
5	26/08	Bloqueio e filas	Caravanas de carros e início de filas
6	28/08	Filas	M/M/1
7	2/09	Revisão	Teste ao final da aula
8	4/09	Atrasos e medições	Divisão em camadas, segurança
9	9/09	HTTP	Camada de aplicação

AULA 1 | 12/08/2026 – quarta-feira**Apresentação do curso e uma primeira visão da Internet**

Cobertura: introdução ao curso e início do Capítulo 1.

1.1 Organização da disciplina

- Professor: Daniel Sadoc Menasché; contato registrado no quadro: `sadoc@ic.ufrj.br`.
- Classroom: avisos, materiais e atividades.
- Planilha da turma: presenças, agenda e trabalhos em grupo.
- A avaliação combina provas, exercícios/minitests, trabalho em grupo e eventuais bônus.

Se MP é a média das duas maiores notas entre $P1$, $P2$ e $P3$, MEX é a nota dos exercícios/minitests e NT é a nota do trabalho em grupo, então

$$MF = 0,70 MP + 0,15 MEX + 0,15 NT + \text{bônus}.$$

1.2 Roteiro do Capítulo 1

- 1.1 – O que é a Internet?
- 1.2 – A borda da rede (*network edge*).
- 1.3 – O núcleo da rede (*network core*).
- 1.4 – Desempenho: atraso, perda e vazão.
- 1.5 – Pilha de protocolos e modelos de serviço.

1.3 O que é a Internet?**1.3.1 Visão física**

A Internet é uma rede de redes que interliga bilhões de dispositivos. Os dispositivos nas extremidades são chamados **hosts** ou **sistemas finais**; eles se comunicam por enlaces e por equipamentos de comutação, como roteadores e switches.

1.3.2 Visão lógica ou de serviço

A Internet também é uma infraestrutura que oferece serviços de comunicação a aplicações distribuídas. As aplicações usam interfaces de programação (APIs) e protocolos para trocar dados sem precisar conhecer todos os detalhes internos da rede.

Ideia-chave. A visão física responde “quais elementos compõem a rede?”; a visão de serviço responde “o que a rede oferece às aplicações?”.

1.4 Protocolos

Um protocolo é um conjunto de regras que governa a comunicação entre entidades. Ele estabelece:

- a **sintaxe**: formato e ordem dos campos de uma mensagem;
- a **semântica**: significado dos campos e das mensagens, que caracteriza as ações, ou seja, o que fazer ao transmitir ou receber cada mensagem.

1.5 Primeira ponte com estatística

Um parâmetro, como a média populacional μ , é desconhecido. A partir de observações $D_1, D_2, \dots, D_n$, calculamos uma estatística para estimá-lo. A média amostral é

$$\hat{\mu} = \frac{D_1 + D_2 + \dots + D_n}{n}.$$

Essa linguagem reaparece ao estimar atraso médio, vazão disponível, perda e capacidade de um caminho.

Para revisar

1. Dê um exemplo da Internet sob a visão física e outro sob a visão de serviço.
2. Explique a diferença entre sintaxe, semântica e ação em um protocolo.
3. Por que uma média obtida de poucas medições é um estimador, e não necessariamente o valor real do parâmetro?

AULA 2 | 14/08/2026 – sexta-feira**Borda da rede, redes de acesso e compartilhamento de recursos**

Cobertura: slides até o 21 (inclusive), com ênfase em redes de acesso e comutação.

2.1 Borda da rede

Na borda estão os hosts ou sistemas finais: computadores, telefones, servidores, sensores e outros dispositivos que executam aplicações. A **rede de acesso** conecta um sistema final ao primeiro roteador da rede do provedor.

2.2 Acesso sem fio: AP e estação-base

- No Wi-Fi, o host se associa a um ponto de acesso (AP), tipicamente seguindo a família IEEE 802.11.
- Em uma rede celular, o host se comunica com uma estação-base (BS), por exemplo em uma rede 5G.
- Nos dois casos existe um trecho de rádio, mas a arquitetura, o alcance, a mobilidade e a gestão dos recursos são diferentes.

Um meio é **guiado** quando o sinal percorre cabo de cobre ou fibra, e **não guiado** quando se propaga pelo ar.

2.3 Tecnologias de acesso residencial

- **HFC:** combina fibra na rede do provedor com cabo coaxial no trecho de distribuição; usuários vizinhos podem compartilhar capacidade.
- **DSL:** usa o par de cobre da linha telefônica até a central; o acesso é dedicado nesse trecho físico.
- **Rede doméstica:** normalmente combina modem/ONT, roteador, Ethernet e Wi-Fi.

2.4 Comutação de circuitos e de pacotes

Na comutação de circuitos, recursos são reservados antes da transmissão. Na comutação de pacotes, os dados são divididos em pacotes que compartilham enlaces e buffers.

Aspecto	Circuitos	Pacotes
Recursos	Reservados para a conexão	Compartilhados sob demanda
Uso	Previsível após admissão	Estatístico e variável
Ociosidade	Recursos podem ficar ociosos	Capacidade aproveitada por outros fluxos
Sobrecarga	Nova conexão pode ser bloqueada	Podem surgir fila, atraso e perda

Recursos reservados podem ser separados por frequência (FDM), tempo (TDM) ou códigos (CDMA).

Para revisar

1. Identifique o AP e o roteador de borda em uma rede doméstica.
2. Em que sentido a capacidade de uma rede HFC pode ser compartilhada?
3. Compare a chegada de um novo usuário a um circuito sem capacidade e a um enlace de pacotes congestionado.

AULA 3 | 19/08/2026 – quarta-feira**Atrasos, núcleo da rede e técnica de *packet pair***

Cobertura planejada: slides até o 35 (exclusive) e técnica de *packet pair*.

3.1 Componentes do atraso

Para um pacote de L bits transmitido por um enlace de taxa R bits/s, o atraso de transmissão é

$$d_{\text{trans}} = \frac{L}{R}.$$

Para um enlace de comprimento d e velocidade de propagação s , o atraso de propagação é

$$d_{\text{prop}} = \frac{d}{s}.$$

O primeiro depende do tamanho do pacote e da taxa do enlace; o segundo depende da distância e do meio físico.

3.2 Núcleo da rede

- **Encaminhamento:** mover um pacote da interface de entrada para a interface de saída apropriada.
- **Roteamento:** calcular ou aprender os caminhos usados nas decisões de encaminhamento.
- Em *store-and-forward*, o roteador recebe o pacote antes de transmiti-lo no enlace seguinte.
- Se os pacotes chegam mais depressa do que podem sair, surgem fila, atraso de enfileiramento e, com buffer finito, perda.

3.3 Técnica de *packet pair*

Dois pacotes de mesmo tamanho L são enviados muito próximos. O gargalo de taxa R_b tende a impor uma dispersão Δ entre eles:

$$\Delta \approx \frac{L}{R_b} \quad \implies \quad \hat{R}_b \approx \frac{L}{\Delta}.$$

Tráfego concorrente, filas, escalonamento e resolução do relógio introduzem erro. A técnica estima principalmente a capacidade do gargalo; capacidade e largura de banda disponível não são sinônimos.

3.3.1 Comparação entre *store-and-forward* e *cut-through*

Considere N pacotes de tamanho L atravessando H enlaces idênticos, cada um com taxa R . Ignorando filas e processamento, na comutação *store-and-forward* temos

$$T_{\text{SF}} = (N + H - 1) \frac{L}{R} + \sum_{i=1}^H d_{\text{prop},i}.$$

O termo $H - 1$ aparece porque o primeiro pacote deve ser completamente recebido em cada roteador antes de ser retransmitido.




Figure 1: Comutação *store-and-forward*. O roteador somente começa a transmitir um pacote depois de recebê-lo completamente.

3.3.1.1 Comutação *cut-through*

Na comutação *cut-through*, o roteador pode começar a encaminhar um pacote assim que recebe cabeçalho suficiente para determinar a interface de saída.

No caso ideal, com enlaces de mesma taxa e tempo de processamento desprezível,

$$T_{CT} = N \frac{L}{R} + \sum_{i=1}^H d_{prop,i}.$$

O tempo de transmissão L/R é multiplicado pelo número de pacotes N , mas não pelo número de enlaces H . Os roteadores encaminham os bits como um pipeline contínuo.




Figure 2: Comutação *cut-through*. No caso ideal, o atraso de transmissão é multiplicado pelo número de pacotes, mas não pelo número de enlaces.

3.3.2 Técnica de *packet pair*

Considere dois pacotes de tamanho L enviados consecutivamente por um caminho com dois enlaces. Sejam R_1 e R_2 as capacidades dos enlaces.

A dispersão entre os pacotes depois do primeiro enlace é

$$\Delta_{\text{in}} = \frac{L}{R_1}.$$

A relação entre R_1 e R_2 determina se o segundo pacote precisará esperar no roteador.

3.3.2.1 Primeiro enlace mais rápido: $R_1 > R_2$

Neste caso,

$$\frac{L}{R_1} < \frac{L}{R_2}.$$

O pacote 2 chega ao roteador antes que a transmissão do pacote 1 pelo segundo enlace tenha terminado. Portanto, o pacote 2 espera na fila do roteador.

O atraso de fila do segundo pacote é

$$W_{q,2} = \frac{L}{R_2} - \frac{L}{R_1}.$$

Na saída, a dispersão passa a ser

$$\Delta_{\text{out}} = \frac{L}{R_2}.$$




Figure 3: *Packet pair* quando a capacidade do primeiro enlace é maior. O enlace 2 aumenta a dispersão entre os pacotes.

3.3.2.2 Primeiro enlace mais lento: $R_1 < R_2$

Agora,

$$\frac{L}{R_1} > \frac{L}{R_2}.$$

O segundo enlace termina de transmitir o pacote 1 antes da chegada completa do pacote 2. Portanto, não há espera no roteador.

A dispersão observada na saída permanece

$$\Delta_{\text{out}} = \frac{L}{R_1}.$$

Se os dois pacotes ficam prontos simultaneamente na origem, o pacote 2 precisa esperar a transmissão do pacote 1 pelo primeiro enlace:

$$W_{q,2}^{(\text{origem})} = \frac{L}{R_1}.$$

Essa é uma espera na origem, e não uma fila produzida no roteador intermediário.




Figure 4: *Packet pair* quando a capacidade do primeiro enlace é menor. O segundo enlace fica temporariamente ocioso entre os pacotes.

3.3.2.3 Interpretação dos dois casos

Os dois exemplos podem ser resumidos por

$$\Delta_{\text{out}} = \max \left\{ \frac{L}{R_1}, \frac{L}{R_2} \right\} = \frac{L}{\min\{R_1, R_2\}}.$$

Portanto,

$$\hat{R}_{\text{gargalo}} = \frac{L}{\Delta_{\text{out}}}.$$

No caso ideal, a dispersão observada entre os dois pacotes revela a capacidade do enlace mais lento. Na prática, tráfego concorrente pode introduzir atrasos adicionais de fila e alterar a dispersão observada.

Para revisar

1. Diferencie atraso de transmissão e atraso de propagação.
2. Por que o gargalo aumenta a separação entre pacotes consecutivos?
3. Por que é prudente repetir a medição e usar estatísticas robustas?

Atrasos, *packet pair* e tamanho ótimo de pacote

Notas adicionais – aula de 19 de agosto de 2026

3.4 Atraso de transmissão e atraso de propagação

Considere um pacote com L bits e um enlace com taxa R bits/s. O **atraso de transmissão** (ou de serialização) é o tempo necessário para colocar todos os bits do pacote no enlace:

$$d_{\text{trans}} = \frac{L}{R}.$$

Se o enlace possui distância d e o sinal se propaga no meio com velocidade s , o **atraso de propagação** é

$$d_{\text{prop}} = \frac{d}{s}.$$

Diferença essencial. L/R depende do tamanho do pacote e da taxa do enlace. d/s depende da distância e do meio físico. Um enlace pode ter alta taxa e grande atraso de propagação, como ocorre em enlaces via satélite.

Para um caminho com H enlaces, o atraso fim a fim de um pacote pode ser representado por

$$d_{\text{fim-a-fim}} = \sum_{i=1}^H \left(d_{\text{proc},i} + d_{\text{fila},i} + \frac{L}{R_i} + \frac{d_i}{s_i} \right).$$

Neste texto, H é o número de **enlaces** percorridos. Se “ H hops” for usado para contar apenas os roteadores intermediários, o caminho terá $H + 1$ enlaces e as fórmulas devem ser ajustadas.




Figure 5: As quatro fontes do atraso nodal, na ordem em que o pacote as encontra. A CPU do roteador verifica o cabeçalho e determina a porta de saída. O pacote é então colocado no *buffer* correspondente. Quando chega à frente da fila, o módulo de transmissão da placa de rede serializa seus L bits à taxa R , produzindo o atraso de transmissão L/R . Finalmente, os bits se propagam pelo meio físico, produzindo o atraso de propagação d/s .

3.5 Técnicas de *packet pair*

A técnica de *packet pair* envia dois pacotes de sondagem de mesmo tamanho L muito próximos. Em um gargalo de taxa R_b , os pacotes precisam ser serializados. Na situação ideal, a dispersão observada na saída do gargalo é

$$\Delta_{\text{out}} \approx \frac{L}{R_b},$$

de modo que

$$\hat{R}_b \approx \frac{L}{\Delta_{\text{out}}}.$$

O atraso de propagação comum aos dois pacotes muda o instante absoluto de chegada, mas tende a se cancelar quando se considera apenas a diferença entre os instantes de chegada. Por isso a dispersão pode revelar a taxa de serialização do gargalo.

Na prática, há várias fontes de erro:

- tráfego concorrente pode entrar entre os pacotes e aumentar a dispersão;
- filas e políticas de escalonamento podem comprimir ou expandir o par;
- caminhos diferentes, offloading e resolução limitada do relógio afetam a medição;
- um único par é frágil, razão pela qual se usam repetições, filtros e trens de pacotes.

Capacidade versus largura de banda disponível. O *packet pair* clássico procura principalmente a capacidade do gargalo. A capacidade livre depende do tráfego concorrente e exige hipóteses ou técnicas adicionais.

3.6 Fragmentação de uma mensagem em pacotes

Considere uma mensagem com L' bytes úteis que atravessa H enlaces idênticos. Nesta seção, para manter as fórmulas em bytes, R representa a taxa em **bytes/s**. Se a taxa do enlace for dada em bits/s, basta usar $R/8$ como taxa em bytes/s, ou multiplicar os numeradores por 8. A mensagem é dividida em N pacotes. Cada pacote contém ℓ bytes úteis e um cabeçalho de h bytes. Inicialmente, suponha que L' é múltiplo de ℓ , de modo que

$$N = \frac{L'}{\ell}.$$

As hipóteses do modelo são:

- comutação *store-and-forward*;
- todos os enlaces têm a mesma taxa R ;
- não há perdas, retransmissões, filas nem atraso de processamento;
- os pacotes são transmitidos em pipeline;
- o atraso de propagação será acrescentado separadamente.

O primeiro pacote leva

$$H \frac{\ell + h}{R}$$

para ser serializado nos H enlaces. Depois que o pipeline é preenchido, cada um dos $N - 1$ pacotes restantes chega separado pelo intervalo $(\ell + h)/R$. Logo,

$$T_{\text{tx}}(\ell) = (H + (N - 1)) \frac{\ell + h}{R} \quad (1)$$

$$= \frac{(H + N - 1)(\ell + h)}{R}. \quad (2)$$

Substituindo $N = L'/\ell$,

$$T_{\text{tx}}(\ell) = \frac{1}{R} \left(H - 1 + \frac{L'}{\ell} \right) (\ell + h) \quad (3)$$

$$= \frac{1}{R} \left(L' + (H - 1)\ell + \frac{L'h}{\ell} + (H - 1)h \right). \quad (4)$$

Se cada enlace também possui atraso de propagação d/s , o atraso total, sob as mesmas hipóteses, torna-se

$$T_{\text{total}}(\ell) = T_{\text{tx}}(\ell) + H \frac{d}{s}.$$

O termo de propagação não altera o tamanho ótimo de pacote neste modelo, pois não depende de ℓ .

3.7 Tamanho útil ótimo do pacote

Os termos constantes de (4) não afetam a minimização. Assim, devemos minimizar

$$f(\ell) = (H - 1)\ell + \frac{L'h}{\ell}.$$

Derivando,

$$f'(\ell) = (H - 1) - \frac{L'h}{\ell^2}.$$

Igualando a zero,

$$(H - 1) = \frac{L'h}{\ell^2},$$

e, portanto,

$$\ell^* = \sqrt{\frac{L'h}{H - 1}}.$$

A segunda derivada é

$$f''(\ell) = \frac{2L'h}{\ell^3} > 0,$$

logo o ponto estacionário é um mínimo para $H > 1$, $h > 0$ e $L' > 0$.

O número contínuo de pacotes correspondente é

$$N^* = \frac{L'}{\ell^*} = \sqrt{\frac{L'(H - 1)}{h}}.$$

Na prática, N deve ser inteiro, o último pacote pode ser menor, e ℓ é limitado pela MTU. Devem-se comparar os inteiros próximos de N^* e respeitar os limites do sistema.

3.8 A mesma derivação em função de N

Como $\ell = L'/N$, a Equação (2) também pode ser escrita como

$$T_{\text{tx}}(N) = \frac{(H + N - 1)(L'/N + h)}{R} \quad (5)$$

$$= \frac{1}{R} \left(L' + (H - 1)h + Nh + \frac{(H - 1)L'}{N} \right). \quad (6)$$

Derivando a parte não constante,

$$\frac{d}{dN} \left(Nh + \frac{(H - 1)L'}{N} \right) = h - \frac{(H - 1)L'}{N^2}.$$

Igualando a zero, obtemos novamente

$$N^* = \sqrt{\frac{(H - 1)L'}{h}}.$$

3.9 Quando a fórmula degenera para $L(N + H - 1)/R$?

Se desprezarmos o cabeçalho, isto é, se $h = 0$, e chamarmos de L o tamanho de cada pacote, então $\ell = L$ e a mensagem total satisfaz

$$L' = NL.$$

Substituindo essas três condições na Equação (4),

$$T_{\text{tx}} = \frac{L' + L(H - 1)}{R} \quad (7)$$

$$= \frac{LN + L(H - 1)}{R} \quad (8)$$

$$= \boxed{\frac{L(N + H - 1)}{R}}. \quad (9)$$

Portanto, a identificação está correta sob as seguintes condições:

$$h = 0, \quad \ell = L, \quad L' = NL,$$

além das hipóteses de enlaces iguais, *store-and-forward*, ausência de filas e pipeline perfeito.

Quando $h = 0$, o modelo ideal favorece pacotes cada vez menores: reduzir ℓ melhora o pipeline sem custo adicional. O cabeçalho, o processamento por pacote, a MTU e outros custos reais impedem esse limite irreal e produzem um compromisso entre fragmentação e overhead.

3.10 Resumo das expressões

Grandeza	Expressão
Atraso de transmissão de um pacote	L/R
Atraso de propagação de um enlace	d/s
Dispersão ideal de <i>packet pair</i>	$\Delta \approx L/R_b$
Estimativa do gargalo	$\hat{R}_b \approx L/\Delta$
Mensagem fragmentada	$(H + N - 1)(\ell + h)/R$
Tamanho útil ótimo	$\ell^* = \sqrt{L'h/(H - 1)}$
Número contínuo ótimo de pacotes	$N^* = \sqrt{L'(H - 1)/h}$
Caso sem cabeçalho	$L(N + H - 1)/R$

AULA 4 | 21/08/2026 – sexta-feira

Multiplexação estatística e probabilidade de bloqueio

Cobertura: slide 35 e desenvolvimento, no quadro, do modelo probabilístico de usuários ativos.

4.1 Problema de dimensionamento

Considere m usuários que compartilham um recurso capaz de atender simultaneamente r usuários. Cada usuário está ativo com probabilidade p . Se A é o número de usuários ativos, então, sob independência e probabilidades iguais,

$$A \sim \text{Binomial}(m, p), \quad \Pr(A = a) = \binom{m}{a} p^a (1 - p)^{m-a}.$$

Além disso,

$$\mathbb{E}[A] = mp.$$

A média é a carga esperada, não um limite máximo para A .

4.2 Probabilidade de sobrecarga

Há demanda acima da capacidade quando $A > r$:

$$\Pr(A > r) = \sum_{a=r+1}^m \Pr(A = a) = 1 - \sum_{a=0}^r \Pr(A = a).$$

Um projeto probabilístico escolhe r de modo que

$$\Pr(A > r) \leq \varepsilon,$$

onde ε é a tolerância de bloqueio, perda ou sobrecarga.

Cuidado. Escolher apenas $r = mp$ geralmente não produz uma probabilidade pequena de sobrecarga. É preciso considerar a variabilidade e a cauda da distribuição.

4.3 Aproximação de Poisson

Quando m é grande, p é pequeno e $\lambda = mp$ permanece moderado,

$$\Pr(A = a) \approx e^{-\lambda} \frac{\lambda^a}{a!}.$$

4.4 Fila e garantias

Na comutação de pacotes, o uso pode ser imediato e a garantia costuma ser probabilística. Na comutação de circuitos, a reserva permite garantia ao usuário aceito, mas uma nova chamada pode ser recusada se todos os circuitos estiverem ocupados.

Síntese. A multiplexação estatística aumenta a eficiência porque nem todos os usuários ficam ativos ao mesmo tempo; o preço é um risco controlado de fila, perda ou bloqueio.

Exercício guiado

Uma rede possui $m = 100$ usuários, cada um ativo com probabilidade $p = 0,10$. Assim, $\mathbb{E}[A] = 10$. Para uma capacidade r :

1. calcule $\Pr(A > r)$ usando a cauda binomial;
2. compare com a aproximação de Poisson de parâmetro $\lambda = 10$;
3. encontre o menor r que atende a uma meta ε ;
4. explique por que $r = 10$ não equivale a uma garantia de baixa sobrecarga.

Da binomial ao tempo de descongestionamento

Complemento da aula de 21 de agosto de 2026

4.5 A mesma binomial em dois sistemas diferentes

Considere m usuários. Em uma escala de tempo adequada, defina

$$I_i = \begin{cases} 1, & \text{se o usuário } i \text{ está ativo;} \\ 0, & \text{caso contrário.} \end{cases}$$

Se os usuários são independentes e $\Pr(I_i = 1) = p$, então

$$A = \sum_{i=1}^m I_i \sim \text{Binomial}(m, p).$$

A distribuição matemática é a mesma em comutação de pacotes e de circuitos. O que muda é a definição de “ativo”, a escala de observação e a pergunta feita ao modelo.

	Comutação de pacotes	Comutação de circuitos
Escala de tempo	Slot curto, intervalo de escalonamento ou instante de medição da carga.	Duração de uma chamada/conexão ou instante de admissão de uma nova chamada.
Evento $I_i = 1$	O usuário transmite pacotes ou demanda taxa no slot observado.	O usuário mantém uma chamada/conexão que ocupa um circuito.
Variável A	Número de fontes simultaneamente ativas.	Número de chamadas oferecidas ou circuitos potencialmente ocupados.
Pergunta típica	Qual é $\Pr(A > r)$, isto é, a chance de a demanda superar a capacidade e produzir fila ou perda?	Qual é a chance de uma nova chamada não encontrar circuito disponível? Ou, antes do controle de admissão, qual é $\Pr(A > r)$ para a demanda oferecida?
Interpretação da garantia	Probabilística: busca-se manter fila, atraso ou perda abaixo de uma meta.	Determinística para chamadas aceitas; probabilística para o bloqueio na admissão.

Pergunta e modelo devem combinar. Com admissão rígida e apenas r circuitos, o número de circuitos efetivamente ocupados nunca excede r . Nesse caso, $\Pr(A > r)$ deve referir-se à *demanda oferecida*, antes da recusa, ou ser substituída diretamente pela probabilidade de bloqueio vista por uma chegada. A binomial é apropriada quando há uma população finita de fontes independentes; o modelo clássico de Erlang usa hipóteses temporais diferentes.

4.6 Da binomial à Poisson: derivação heurística

Considere

$$A_m \sim \text{Binomial}(m, p_m), \quad p_m = \frac{\lambda}{m}.$$

Assim, o número médio de usuários ativos permanece fixo:

$$\mathbb{E}[A_m] = mp_m = \lambda.$$

Para um valor fixo a ,

$$\Pr(A_m = a) = \binom{m}{a} \left(\frac{\lambda}{m}\right)^a \left(1 - \frac{\lambda}{m}\right)^{m-a} \quad (10)$$

$$= \frac{m(m-1) \cdots (m-a+1)}{a!} \frac{\lambda^a}{m^a} \left(1 - \frac{\lambda}{m}\right)^m \left(1 - \frac{\lambda}{m}\right)^{-a} \quad (11)$$

$$= \frac{\lambda^a}{a!} \underbrace{\prod_{j=0}^{a-1} \left(1 - \frac{j}{m}\right)}_{\rightarrow 1} \underbrace{\left(1 - \frac{\lambda}{m}\right)^m}_{\rightarrow e^{-\lambda}} \underbrace{\left(1 - \frac{\lambda}{m}\right)^{-a}}_{\rightarrow 1}. \quad (12)$$

Quando $m \rightarrow \infty$, $p_m \rightarrow 0$ e $mp_m = \lambda$, obtemos

$$\boxed{\Pr(A_m = a) \rightarrow e^{-\lambda} \frac{\lambda^a}{a!}}$$

e escrevemos, aproximadamente,

$$A_m \approx \text{Poisson}(\lambda).$$

Interpretação. A aproximação de Poisson é natural quando existem muitas fontes, cada fonte fica ativa com probabilidade pequena, e a carga média total $\lambda = mp$ permanece moderada.

4.7 Do estado da rede ao tempo de recuperação

Até aqui, A descreve uma fotografia da rede em um slot. Agora queremos uma variável aleatória temporal: quantos slots serão necessários para que o sistema volte a ficar des congestionado?

Para cada slot futuro $t = 1, 2, \dots$, seja A_t o número de usuários ativos. Defina

$$q = \Pr(A_t \leq r), \quad 1 - q = \Pr(A_t > r).$$

No modelo binomial,

$$q = \sum_{a=0}^r \binom{m}{a} p^a (1-p)^{m-a}.$$

Defina a nova variável aleatória

$$\boxed{S = \min\{s \geq 1 : A_s \leq r\}},$$

isto é, S é o número de slots futuros até observarmos o primeiro slot descongestionado.

Se os slots são independentes e têm a mesma probabilidade q de sucesso,

$$S \sim \text{Geom}(q),$$

com suporte $\{1, 2, 3, \dots\}$. Sua PMF é

$$\Pr(S = s) = (1 - q)^{s-1}q, \quad s = 1, 2, \dots,$$


e sua função de distribuição acumulada (CDF) é

$$F_S(s) = \Pr(S \leq s) = 1 - (1 - q)^s, \quad s = 1, 2, \dots$$

Hipótese forte. Se usuários permanecem ativos por vários slots, os valores A_t são correlacionados e S não é necessariamente geométrica. A geométrica é o modelo básico obtido sob independência entre slots.

4.8 Duas CDFs para o tempo de descongestionamento

O gráfico compara dois sistemas. No Sistema A, um slot está descongestionado com probabilidade $q_A = 0,50$; no Sistema B, essa probabilidade é apenas $q_B = 0,20$.



Pergunta aos alunos. Qual sistema você preferiria? Para um mesmo valor de s , qual curva oferece maior probabilidade de já ter saído do congestionamento?

Leitura do gráfico. O Sistema A é preferível: sua CDF sobe mais cedo. A curva do Sistema B está mais à direita e é pior, pois atribui maior probabilidade a tempos longos de recuperação. Em termos de ordem estocástica, S_A é estocasticamente menor que S_B (o que pode confundir com o fato de a CDF do sistema S_A estar acima da CDF do sistema S_B).

4.9 Como caracterizar uma variável aleatória

Uma variável aleatória pode ser descrita de várias maneiras equivalentes ou complementares:

- pela **CDF**, $F_S(s) = \Pr(S \leq s)$, que sempre caracteriza a distribuição;
- pela **PMF**, $p_S(s) = \Pr(S = s)$, quando a variável é discreta;
- por uma **transformada**, como a função geradora de probabilidades ou a função geradora de momentos;
- por **todos os momentos**, quando a distribuição é determinada por seus momentos.

Para a geométrica com suporte começando em 1, a função geradora de probabilidades é

$$G_S(z) = \mathbb{E}[z^S] = \sum_{s=1}^{\infty} z^s (1-q)^{s-1} q = \frac{qz}{1 - (1-q)z}.$$

4.10 Média da geométrica pela falta de memória

A geométrica possui a propriedade de falta de memória:

$$\Pr(S > m + n \mid S > m) = \Pr(S > n).$$

Depois de um slot congestionado, a situação probabilística para os slots futuros é igual à situação inicial.

Seja

$$\mu = \mathbb{E}[S].$$

No primeiro slot, ocorrem duas possibilidades:

- com probabilidade q , o sistema descongestiona imediatamente e $S = 1$;
- com probabilidade $1 - q$, gastamos um slot congestionado e, pela falta de memória, o tempo médio restante volta a ser μ .

Portanto,

$$\mu = q \cdot 1 + (1 - q)(1 + \mu) \tag{13}$$

$$= 1 + (1 - q)\mu. \tag{14}$$

Reorganizando,

$$q\mu = 1,$$

e concluímos que

$$\boxed{\mathbb{E}[S] = \frac{1}{q}}.$$

Nos dois sistemas do gráfico,

$$\mathbb{E}[S_A] = \frac{1}{0,50} = 2 \text{ slots}, \quad \mathbb{E}[S_B] = \frac{1}{0,20} = 5 \text{ slots}.$$

Isso confirma numericamente a leitura visual: a curva mais à direita é a pior.

Fechamento da aula. A binomial descreve quantos usuários estão ativos em uma fotografia da rede; a Poisson oferece uma aproximação para muitas fontes raramente ativas; e a geométrica descreve, sob independência temporal, quanto tempo esperamos até o sistema voltar a ficar descongestionado.

Referências de acompanhamento

- J. F. Kurose e K. W. Ross, *Computer Networking: A Top-Down Approach*, Capítulo 1.
- Slides oficiais dos autores: https://gaia.cs.umass.edu/kurose_ross/ppt.php.
- Agenda e materiais da disciplina disponíveis nos canais informados em aula.

AULA 5 | 26/08/2026 – quarta-feira

Do pipeline à teoria de filas

Cobertura: slides 36 até slide 52 sobre teoria de filas.

Roteiro da aula. Primeiro retomamos o envio de vários pacotes por um caminho com múltiplos enlaces. Depois comparamos *store-and-forward* e *cut-through*. Finalmente, introduzimos um modelo de fila para relacionar taxa de chegada, capacidade, utilização, número de pacotes e atraso.

5.1 Retomada: pacotes em pipeline

Considere N pacotes de mesmo tamanho L bits atravessando H enlaces. Todos os enlaces têm taxa R bits/s e os nós usam *store-and-forward*. Por enquanto, ignore filas, perdas, processamento e propagação.

O tempo de transmissão de um pacote em um enlace é

$$\tau = \frac{L}{R}.$$

O primeiro pacote precisa ser completamente transmitido nos H enlaces e chega após $H\tau$. A partir daí, graças ao pipeline, chega um novo pacote a cada intervalo τ . Portanto,

$$T_{N,H} = (H + N - 1) \frac{L}{R}.$$

O termo $N + H - 1$ pode ser visualizado como H intervalos para o primeiro pacote e $N - 1$ intervalos para esvaziar o restante do pipeline.

Se cada enlace também possui atraso de propagação d_i/s_i , ele é somado uma vez por enlace:

$$T_{N,H} = (H + N - 1) \frac{L}{R} + \sum_{i=1}^H \frac{d_i}{s_i}.$$

Observe que a propagação não é multiplicada por N : os pacotes também se propagam em pipeline.

Verificação. Se $N = 1$, obtemos HL/R . Se $H = 1$, obtemos NL/R . Por que esses dois casos-limite fazem sentido?

5.2 Comutação e o momento de encaminhar

O nó intermediário pode decidir quando começar a transmitir o pacote pelo próximo enlace.

	<i>Store-and-forward</i>	<i>Cut-through</i>
Quando encaminha?	Depois de receber o pacote completo.	Assim que recebe cabeçalho suficiente para determinar a saída.
Memória no nó	Armazena o pacote inteiro.	Pode usar um buffer menor, embora ainda possa haver filas.
Erro no final do pacote	Pode ser detectado antes do encaminhamento.	O nó pode já ter propagado parte de um quadro corrompido.
Atraso ideal	Cada enlace acrescenta aproximadamente L/R .	A serialização pode se sobrepor entre enlaces; após o início, o pacote pode atravessar os nós quase como um fluxo de bits.

Não confundir conceitos. *Packet switching* versus *circuit switching* descreve como os recursos são compartilhados. *Store-and-forward* versus *cut-through* descreve quando um nó começa a encaminhar os bits. São duas classificações diferentes.

Em uma rede de pacotes, o encaminhamento é feito pacote a pacote com uma tabela de encaminhamento. Em uma rede de circuitos, há antes uma fase de estabelecimento do circuito e os recursos podem ser reservados durante a conexão. A análise probabilística continua útil nos dois casos, mas em escalas distintas: slots ou rajadas para pacotes; duração de chamadas para circuitos.

5.3 A analogia da caravana

A “caravana”, traduzida na edição nacional de Kurose & Ross como “comboio de carros”, ilustra de forma intuitiva a diferença física e matemática entre o **atraso de transmissão** e o **atraso de propagação**.

Nesta versão da analogia, consideramos um único pacote suficientemente longo para mostrar claramente a diferença entre os regimes *store-and-forward* e *cut-through*.

5.3.1 Os elementos da analogia

Imagine uma rodovia com três cabines de pedágio, separadas por trechos de 100 km:

- **Carros individuais** → os **bits**;
- **O comboio de 15 carros** → um **pacote** de dados;
- **As cabines de pedágio** → os **roteadores ou comutadores**;
- **O tempo de atendimento de um carro** → o tempo necessário para transmitir um bit;
- **Os trechos de rodovia** → os **enlaces** de comunicação;
- **A velocidade dos carros** → a velocidade de propagação do sinal no meio físico.

Adotaremos os seguintes parâmetros:

- distância entre dois pedágios: 100 km;
- velocidade dos carros: 1.000 km/h;
- tempo de atendimento: 1 minuto por carro;
- tamanho do comboio: 15 carros.

5.3.2 Um mesmo pacote nos dois regimes


A Figura 6 representa o sistema no instante $t = 14$ minutos.

No regime *store-and-forward*, o pedágio 2 ainda não recebeu o comboio completo e, portanto, não pode liberar nenhum carro para o trecho seguinte.

No regime *cut-through*, cada pedágio libera os carros à medida que eles chegam. Nesse mesmo instante, o carro 15 está no pedágio 1, o carro 8 está no pedágio 2 e o carro 1 está no pedágio 3.

(a) Store-and-forward no instante $t = 14$ min


um único pacote: o último carro ainda está no pedágio 1, o pedágio 2 aguarda enquanto os demais propagam ou aguardam no pedágio 2 o pacote completo



No instante $t = 14$, o carro 15 está no pedágio 1, os carros 9–14 ainda propagam e os carros 1–8 já estão armazenados no pedágio 2. O trecho posterior permanece vazio.

(b) Cut-through no instante $t = 14$ min

um único pacote ocupa simultaneamente os três pedágios e os dois trechos entre eles



No mesmo instante, o carro 15 está no pedágio 1, o carro 8 está no pedágio 2 e o carro 1 está no pedágio 3. Todos pertencem ao mesmo pacote.

← 100 km → ← 100 km →
 velocidade: 1.000 km/h | distância entre pedágios: 100 km
 serviço: 1 min por carro | pacote: 15 carros | $d_{\text{trans}} = 15$ min

Figure 6: Um único pacote de 15 carros observado no instante $t = 14$ minutos. Em (a), no regime *store-and-forward*, o carro 15 está sendo atendido pelo pedágio 1, os carros 9–14 ainda estão em propagação e os carros 1–8 já chegaram ao pedágio 2, onde permanecem armazenados verticalmente. O pedágio 2 não pode liberar nenhum carro antes de receber o pacote completo e, por isso, o trecho posterior permanece vazio. Em (b), no regime *cut-through*, os carros 15, 8 e 1 estão sendo atendidos simultaneamente pelos pedágios 1, 2 e 3, respectivamente, enquanto os demais carros propagam pelos enlaces.

5.3.3 Cálculo dos atrasos básicos

Atraso de transmissão. Cada pedágio atende um carro por minuto. Portanto, sua taxa de serviço é

$$R_{\text{pedágio}} = 1 \text{ carro/min.}$$

Como o pacote contém 15 carros, o tempo necessário para transmitir o pacote completo é

$$d_{\text{trans}} = \frac{15 \text{ carros}}{1 \text{ carro/min}} = 15 \text{ minutos.} \quad (15)$$

Na analogia com redes, os 15 carros representam os bits do pacote e a taxa de um carro por minuto representa a taxa de transmissão do enlace.

Atraso de propagação. Os carros deslocam-se a 1.000 km/h e os pedágios estão separados por 100 km. Logo,

$$d_{\text{prop}} = \frac{100 \text{ km}}{1.000 \text{ km/h}} \quad (16)$$

$$= 0,1 \text{ h} \quad (17)$$

$$= 6 \text{ minutos.} \quad (18)$$

Observe que o atraso de propagação depende da distância e da velocidade, mas não depende do número de carros.

Tempo para o pacote chegar completamente ao pedágio seguinte. No regime *store-and-forward*, o último carro deixa o primeiro pedágio após 15 minutos e ainda precisa percorrer 100 km.

Consequentemente, o instante em que o pacote está completamente disponível no pedágio seguinte é

$$d_{\text{trans}} + d_{\text{prop}} = 15 + 6 = 21 \text{ minutos.} \quad (19)$$

5.3.4 Funcionamento no regime *store-and-forward*

No regime *store-and-forward*, cada pedágio precisa receber o pacote completo antes de começar a encaminhá-lo:

1. O pedágio 1 atende os 15 carros, um de cada vez.
2. O último carro deixa o pedágio 1 em $t = 15$ minutos.
3. Depois de percorrer 100 km, o último carro chega ao pedágio 2 em

$$t = 15 + 6 = 21 \text{ minutos.}$$

4. Somente em $t = 21$ minutos o pedágio 2 pode começar a atender o primeiro carro.
5. O mesmo procedimento se repete no pedágio 3.

Ideia central: o pedágio seguinte pode receber alguns carros antes dos demais, mas não pode encaminhar nenhum deles antes de receber o comboio completo. Isso corresponde a um roteador *store-and-forward*, que somente inicia a transmissão depois de receber o pacote inteiro.

5.3.5 O instante $t = 14$ minutos

O instante $t = 14$ minutos permite visualizar claramente a diferença entre os dois regimes.

No pedágio 1, cada carro i termina seu atendimento no instante

$$t = i \text{ minutos.}$$

Como o tempo de propagação é de seis minutos, o carro i chega ao pedágio 2 no instante

$$t = i + 6.$$

Assim, no instante $t = 14$:

- o carro 15 está sendo atendido pelo pedágio 1;
- o carro 8, que deixou o pedágio 1 em $t = 8$, chega ao pedágio 2;
- o carro 1 já chegou ao pedágio 2 desde $t = 7$.

No regime *store-and-forward*, o pedágio 2 precisa esperar até $t = 21$ minutos, quando chega o carro 15. Portanto, em $t = 14$ nenhum carro foi encaminhado para além do pedágio 2.

5.3.6 Funcionamento no regime *cut-through*

No regime *cut-through*, o pedágio não espera pela chegada do pacote completo. Cada carro é atendido assim que chega.

O carro 1 segue a seguinte trajetória:

1. é atendido pelo pedágio 1 entre $t = 0$ e $t = 1$;
2. percorre o primeiro trecho entre $t = 1$ e $t = 7$;
3. é atendido pelo pedágio 2 entre $t = 7$ e $t = 8$;
4. percorre o segundo trecho entre $t = 8$ e $t = 14$;
5. chega ao pedágio 3 em $t = 14$.

O carro 8 deixa o pedágio 1 em $t = 8$ e chega ao pedágio 2 em $t = 14$.

O carro 15 começa a ser atendido pelo pedágio 1 em $t = 14$.

Portanto, no instante $t = 14$ minutos,

pedágio 1:	carro 15,
pedágio 2:	carro 8,
pedágio 3:	carro 1.

Os três pedágios estão simultaneamente ocupados por carros pertencentes ao mesmo pacote.

Pipeline: o *cut-through* permite que diferentes partes do mesmo pacote sejam processadas simultaneamente em diferentes estágios. O pacote não precisa estar completamente armazenado em um roteador para que sua parte inicial avance.

5.3.7 Atraso fim a fim nos dois regimes

Considere um caminho com $H = 3$ pedágios, seguido por três trechos de propagação. Cada trecho apresenta atraso de propagação de seis minutos.

5.3.7.1 *Store-and-forward*

Em cada estágio, é necessário:

- atender os 15 carros: 15 minutos;
- percorrer o trecho seguinte: 6 minutos.

Portanto,

$$T_{\text{SF}} = H (d_{\text{trans}} + d_{\text{prop}}) \quad (20)$$

$$= 3(15 + 6) \quad (21)$$

$$= \boxed{63 \text{ minutos}}. \quad (22)$$

5.3.7.2 *Cut-through*

No regime *cut-through*, os carros formam um pipeline através dos três pedágios.

Com $C = 15$ carros, $H = 3$ pedágios e tempo de serviço por carro $t_c = 1$ minuto, o tempo de serviço do pipeline é

$$(C + H - 1)t_c.$$

Somando os três atrasos de propagação,

$$T_{\text{CT}} = (C + H - 1)t_c + H d_{\text{prop}} \quad (23)$$

$$= (15 + 3 - 1)(1) + 3(6) \quad (24)$$

$$= 17 + 18 \quad (25)$$

$$= \boxed{35 \text{ minutos}}. \quad (26)$$

A diferença fundamental é que, no regime *store-and-forward*, o tempo de transmissão do pacote completo é pago em cada estágio:

$$3(15) = 45 \text{ minutos}.$$

No regime *cut-through*, o tempo dominante de transmissão é pago uma única vez:

$$15 \text{ minutos},$$

acrescido apenas do pequeno custo de preenchimento dos dois estágios adicionais:

$$(H - 1)t_c = 2 \text{ minutos.}$$

5.3.8 *Store-and-forward* versus *cut-through*

Os dois regimes diferem no momento em que o equipamento decide encaminhar o pacote:

- ***Store-and-forward***: o comutador recebe o pacote inteiro, verifica o campo de detecção de erros e somente então inicia a transmissão. Em um caminho com H enlaces idênticos, o atraso de transmissão do pacote é aproximadamente

$$H \frac{L}{R}.$$

- ***Cut-through***: o comutador começa a encaminhar assim que lê cabeçalho suficiente para identificar a porta de saída. No modelo ideal, o atraso associado ao tamanho completo do pacote é aproximadamente

$$\frac{L}{R},$$

e não HL/R . Existe apenas um pequeno custo adicional para o preenchimento do pipeline.

O preço do *cut-through*. Como o quadro é encaminhado antes de terminar de chegar, o comutador pode não conseguir verificar previamente todo o campo de detecção de erros. Quadros corrompidos ou truncados podem ser propagados adiante.

Além disso, o ganho diminui se a porta de saída estiver ocupada ou se sua taxa for menor do que a taxa de entrada. Nesses casos, o equipamento precisa armazenar parte ou todo o quadro. Por isso, o *cut-through* e sua variante *fragment-free*, que examina os primeiros 64 bytes, aparecem principalmente em *switches* Ethernet e em redes de datacenter sensíveis à latência. Os roteadores da Internet operam predominantemente em regime *store-and-forward*.

5.4 Da transmissão determinística à fila

Até agora supusemos que o pacote encontra cada enlace livre. Na prática, vários pacotes disputam uma mesma saída. Modele uma interface por um servidor com uma fila: Use a seguinte notação:




Figure 7: Modelo de fila para um enlace de comunicação. Os pacotes chegam à taxa média λ , esperam na fila quando o enlace está ocupado e são transmitidos pelo servidor à taxa média μ .

- λ : taxa média de chegada, em pacotes/s;
- L : tamanho médio dos pacotes, em bits;
- R : taxa do enlace, em bits/s;
- $1/\mu = L/R$: tempo médio de serviço de um pacote;
- $\mu = R/L$: taxa média de serviço, em pacotes/s.

A intensidade de tráfego ou carga oferecida é

$$\rho = \frac{\lambda}{\mu} = \frac{\lambda L}{R}.$$

Quando o sistema é estável e não há perda de trabalho, ρ também é a fração de tempo em que o enlace permanece ocupado.

Uma justificativa por conservação de taxa é simples. Se o enlace está ocupado durante a fração p_{ocup} do tempo, sua taxa média de saída é

$$0 \cdot (1 - p_{\text{ocup}}) + \mu p_{\text{ocup}}.$$


Em regime estacionário, a taxa média de saída deve igualar a taxa de entrada:

$$\lambda = \mu p_{\text{ocup}} \implies p_{\text{ocup}} = \frac{\lambda}{\mu} = \rho.$$

Condição de estabilidade. Em uma fila com buffer ilimitado, precisamos de $\rho < 1$, isto é, $\lambda < \mu$. Se $\rho > 1$ por tempo prolongado, chega trabalho mais rapidamente do que o enlace consegue atendê-lo e a fila cresce sem limite. Em um buffer finito, o efeito aparece como perdas.

5.5 Utilização alta não significa atraso pequeno

Uma utilização próxima de 100% parece eficiente, mas deixa pouca folga para absorver as flutuações aleatórias das chegadas e dos tamanhos dos pacotes.



O formato acima é qualitativo: o crescimento exato depende do modelo de chegadas, do tamanho dos pacotes, do escalonamento e do tamanho do buffer. A mensagem essencial é que o atraso cresce rapidamente quando ρ se aproxima de 1.

Caso particular $M/M/1$. Somente se as chegadas forem Poisson, os tempos de serviço forem exponenciais, houver um único servidor e buffer ilimitado, vale

$$\mathbb{E}[T] = \frac{1}{\mu - \lambda}, \quad \mathbb{E}[W_q] = \frac{\rho}{\mu - \lambda}.$$

Essas fórmulas não são consequências apenas de conhecer λ e μ .

5.6 Lei de Little

Considere todos os pacotes presentes no sistema: os que esperam na fila e o que está sendo transmitido. Defina

- $\bar{N}$: número médio de pacotes no sistema;
- $\bar{T}$: tempo médio de um pacote no sistema;
- λ : taxa média efetiva de entrada no sistema.

A Lei de Little estabelece que

$$\boxed{\bar{N} = \lambda \bar{T}}.$$

A intuição é uma contagem de “pacote-segundos”. Em um intervalo longo de duração t , a área sob a curva $N(u)$ é aproximadamente $t\bar{N}$. A mesma área é a soma dos tempos que aproximadamente λt pacotes passaram no sistema, isto é, $(\lambda t)\bar{T}$. Igualando as duas contagens,

$$t\bar{N} = (\lambda t)\bar{T} \implies \bar{N} = \lambda \bar{T}.$$

A lei também pode ser aplicada apenas à fila:

$$\bar{N}_q = \lambda \bar{W}_q,$$

onde $\bar{N}_q$ exclui o pacote em serviço e $\bar{W}_q$ conta apenas o tempo de espera. É importante combinar corretamente a região contada e o tempo correspondente.

Exemplo. Um enlace recebe em média 200 pacotes/s e cada pacote passa em média 15 ms no sistema. Quantos pacotes há, em média, na fila mais o servidor?

$$\bar{N} = 200 \times 0,015 = 3 \text{ pacotes.}$$

5.7 Síntese e questões de revisão

Ao final da aula, deve ser possível explicar:

1. por que N pacotes em H enlaces requerem $N + H - 1$ intervalos de transmissão no modelo ideal;
2. a diferença entre *store-and-forward* e *cut-through*;
3. por que $\mu = R/L$ e $\rho = \lambda L/R$;
4. por que o atraso pode crescer fortemente antes de a utilização atingir 100%;
5. como usar $\bar{N} = \lambda \bar{T}$ sem misturar sistema e fila.

Para pensar.

1. Um enlace de 10 Mbit/s recebe 800 pacotes/s de tamanho médio 1,000 bytes. Qual é ρ ? O sistema pode ser estável?
2. Se $\bar{N} = 12$ pacotes e $\lambda = 600$ pacotes/s, qual é o tempo médio no sistema?
3. Dois enlaces têm a mesma utilização média. Eles necessariamente têm o mesmo atraso médio? Que outras características podem ser relevantes?

AULA 6 | 28/08/2026 – sexta-feira**Teoria de filas****Cobertura:** Slide 52.**6.1 Lei de Little e intensidade de tráfego**

Nesta aula, introduzimos um modelo simples para estudar o desempenho de um enlace. O objetivo é relacionar:

- a taxa de chegada de pacotes;
- a capacidade de transmissão do enlace;
- a utilização do enlace;
- o número médio de pacotes;
- o tempo médio de espera;
- o tempo médio total no sistema.

Inicialmente, apresentaremos relações que valem para uma classe ampla de sistemas. Posteriormente, adotaremos as hipóteses específicas do modelo $M/M/1$ para obter fórmulas explícitas para o atraso.

6.1.1 Fila de espera, servidor e sistema

Em um instante t , definimos:

- $N_q(t)$: número de pacotes esperando na fila;
- $N_s(t)$: número de pacotes no servidor, isto é, sendo transmitidos;
- $N(t)$: número total de pacotes no sistema.


Consequentemente,

$$N(t) = N_q(t) + N_s(t).$$

Em um enlace com um único servidor, temos

$$N_s(t) \in \{0, 1\}.$$

O servidor contém um pacote quando o enlace está ocupado e nenhum pacote quando o enlace está ocioso.



É importante distinguir a fila de espera do sistema completo:

$$\boxed{\text{sistema} = \text{fila de espera} + \text{servidor}}.$$

Portanto, “fila de espera” e “sistema” não são sinônimos.

6.1.2 Valores instantâneos e valores médios

As variáveis $N_q(t)$, $N_s(t)$ e $N(t)$ descrevem o sistema em um instante. Ao observarmos o sistema durante um intervalo longo, obtemos os valores médios:

- $\bar{N}_q$: número médio de pacotes na fila de espera;
- $\bar{N}_s$: número médio de pacotes no servidor;
- $\bar{N}$: número médio de pacotes no sistema.

Como a igualdade

$$N(t) = N_q(t) + N_s(t)$$

vale em todos os instantes, também temos

$$\boxed{\bar{N} = \bar{N}_q + \bar{N}_s}.$$

Embora o número observado de pacotes seja sempre inteiro, seu valor médio pode ser fracionário. Por exemplo, $\bar{N}_s = 0,8$ significa que o servidor está ocupado durante 80% do tempo e vazio durante os outros 20%.

6.1.3 Tempos no sistema

Definimos:

- W : tempo médio que um pacote passa esperando na fila;
- S : tempo médio de serviço;
- T : tempo médio total que um pacote passa no sistema.

Consequentemente,

$$\boxed{T = W + S}.$$

Considere um enlace com taxa R bits/s e pacotes com tamanho médio L bits. O tempo médio de serviço é

$$S = \frac{L}{R}.$$

A taxa média de serviço, medida em pacotes por segundo, é

$$\boxed{\mu = \frac{1}{S} = \frac{R}{L}}.$$

Por exemplo, se

$$R = 10\,000\,000 \text{ bits/s}$$

e

$$L = 8\,000 \text{ bits},$$

então

$$\mu = \frac{10\,000\,000}{8\,000} = 1\,250 \text{ pacotes/s.}$$

6.1.4 Lei de Little

Seja a a taxa média efetiva de chegada de pacotes, medida em pacotes por segundo.

A Lei de Little afirma que

$$\boxed{\text{número médio} = \text{taxa média de chegada} \times \text{tempo médio}}.$$

Podemos aplicá-la separadamente à fila de espera, ao servidor e ao sistema completo:

$$\overline{N}_q = aW, \tag{27}$$

$$\overline{N}_s = aS, \tag{28}$$

$$\overline{N} = aT. \tag{29}$$

A região usada para contar os pacotes deve ser a mesma região usada para medir o tempo. Por exemplo:

- $\overline{N}_q$ é associado apenas ao tempo de espera W ;
- $\overline{N}_s$ é associado apenas ao tempo de serviço S ;
- $\overline{N}$ é associado ao tempo total $T = W + S$.

6.1.4.1 Intuição para a Lei de Little

Considere um intervalo longo de duração t . Nesse intervalo, chegam aproximadamente

$$at$$

pacotes.

Se cada pacote passa, em média, T segundos no sistema, esses pacotes acumulam aproximadamente

$$(at)T$$

pacote-segundos.

Por outro lado, se há, em média, $\overline{N}$ pacotes no sistema, a área sob a curva que representa o número de pacotes presentes é aproximadamente

$$\overline{N}t.$$

As duas expressões contam a mesma quantidade. Logo,

$$\overline{N}t = (at)T.$$

Cancelando t , obtemos

$$\overline{N} = aT.$$

6.1.4.2 Exemplo

Um enlace recebe, em média,

$$a = 200 \text{ pacotes/s.}$$

Cada pacote passa, em média,

$$T = 15 \text{ ms} = 0,015 \text{ s}$$

no sistema. Pela Lei de Little,

$$\overline{N} = aT = 200 \times 0,015 = 3.$$

Portanto, há, em média, três pacotes no sistema, contando os pacotes na fila e o pacote em transmissão.

6.1.5 Intensidade de tráfego

A intensidade de tráfego é definida por

$$I = \frac{aL}{R}.$$

Como

$$\mu = \frac{R}{L},$$

podemos escrever

$$I = \frac{a}{\mu}.$$

Em teoria de filas, é comum representar a intensidade de tráfego pela letra ρ . Assim,

$$\rho = \frac{a}{\mu} \quad \text{e, nestas notas,} \quad I = \rho.$$

A quantidade I não possui unidade:

$$I = \frac{\text{pacotes/s}}{\text{pacotes/s}}.$$

6.1.6 Intensidade de tráfego e utilização

Seja U a fração do tempo durante a qual o servidor está ocupado.

Quando o servidor está ocupado, ele transmite à taxa $\mu = R/L$ pacotes/s. Quando está vazio, sua taxa de saída é zero. Portanto, a taxa média de saída é

$$U \frac{R}{L} + (1 - U)0.$$

Em equilíbrio, a taxa média de saída deve ser igual à taxa média de entrada:

$$a = U \frac{R}{L}.$$

Isolando U , obtemos

$$U = \frac{aL}{R}.$$

Como $I = aL/R$,

$$\boxed{U = I = \rho}.$$

Assim, a intensidade de tráfego também representa a fração do tempo durante a qual o enlace está ocupado.

6.1.7 Número médio de pacotes no servidor

Como há apenas um servidor,

$$N_s(t) = \begin{cases} 1, & \text{se o servidor estiver ocupado,} \\ 0, & \text{se o servidor estiver vazio.} \end{cases}$$

Consequentemente,

$$\overline{N}_s = 1 \cdot U + 0 \cdot (1 - U) \tag{30}$$

$$= U. \tag{31}$$

Como $U = I$,

$$\boxed{\overline{N}_s = I}.$$

Podemos obter o mesmo resultado diretamente pela Lei de Little:

$$\overline{N}_s = aS = a \frac{L}{R} = I.$$

Por exemplo, se $I = 0,8$, então

$$\overline{N}_s = 0,8.$$

Isso significa que o servidor está ocupado durante 80% do tempo e vazio durante 20% do tempo. Não significa que exista uma fração de pacote no servidor.

6.1.8 Condição de estabilidade

Para que o sistema seja estável, a taxa média de chegada deve ser inferior à taxa média de serviço:

$$a < \mu.$$

Equivalentemente,

$$\boxed{I < 1}.$$

Se $I > 1$, chegam mais pacotes por segundo do que o enlace consegue transmitir.

- Com buffer ilimitado, a fila cresce sem limite.
- Com buffer finito, pacotes acabam sendo descartados.
- Mesmo quando $I < 1$, podem ocorrer filas devido às flutuações aleatórias das chegadas.

Uma utilização média inferior a 1 é necessária para a estabilidade, mas não garante que o atraso seja pequeno.

6.1.9 O que a Lei de Little não determina

A Lei de Little fornece as relações

$$\overline{N}_q = aW, \quad \overline{N}_s = aS, \quad \overline{N} = aT,$$

mas não determina, sozinha, os valores de W , T ou $\overline{N}$.

Para obter fórmulas explícitas para essas quantidades, precisamos especificar um modelo para:

- o processo de chegada;
- a distribuição dos tempos de serviço;
- o número de servidores;
- a política de atendimento;
- o tamanho do buffer.

A seguir, adotaremos o modelo $M/M/1$.

6.2 A fila $M/M/1$

O modelo $M/M/1$ possui as seguintes hipóteses:

- as chegadas formam um processo de Poisson com taxa a ;

- os tempos de serviço são exponenciais com média $1/\mu = L/R$;
- há um único servidor;
- o buffer é ilimitado;
- os pacotes são atendidos por ordem de chegada;
- $a < \mu$.

A hipótese exponencial implica a propriedade de falta de memória:

$$\Pr(S > x + y \mid S > x) = \Pr(S > y).$$

Portanto, quando um pacote chega e encontra outro pacote sendo transmitido, o tempo residual médio dessa transmissão continua sendo

$$\frac{1}{\mu}.$$

6.2.1 Tempo médio na fila

Um pacote que chega encontra, em média:

- $\overline{N}_q$ pacotes esperando;
- um pacote no servidor com probabilidade I .

Como as chegadas são Poisson, uma chegada observa as médias temporais do sistema. Essa propriedade é conhecida como PASTA: *Poisson Arrivals See Time Averages*.

Cada pacote à frente requer, em média, $1/\mu$ segundos de serviço. Assim,

$$W = (\overline{N}_q + I) \frac{1}{\mu}.$$

Pela Lei de Little,

$$\overline{N}_q = aW.$$

Substituindo,

$$W = (aW + I) \frac{1}{\mu}.$$

Multiplicando por μ ,

$$\mu W = aW + I.$$

Portanto,

$$(\mu - a)W = I$$

e

$$W = \frac{I}{\mu - a}.$$

Como

$$I = \frac{a}{\mu},$$

temos

$$\mu - a = \mu(1 - I).$$

Logo,

$$W = \frac{I}{\mu(1 - I)} = \frac{I L/R}{1 - I}.$$

6.2.2 Tempo médio total no sistema

O tempo total no sistema é

$$T = W + \frac{1}{\mu}.$$

Substituindo a expressão de W ,

$$T = \frac{I}{\mu(1 - I)} + \frac{1}{\mu} \quad (32)$$

$$= \frac{I}{\mu(1 - I)} + \frac{1 - I}{\mu(1 - I)} \quad (33)$$

$$= \frac{1}{\mu(1 - I)}. \quad (34)$$

Portanto,

$$T = \frac{1}{\mu(1 - I)} = \frac{1}{\mu - a}.$$

Usando $\mu = R/L$ e $I = aL/R$, também podemos escrever

$$T = \frac{L/R}{1 - aL/R}.$$

6.2.3 Número médio de pacotes

Pela Lei de Little,

$$\bar{N} = aT.$$

Substituindo $T = 1/(\mu - a)$,

$$\bar{N} = \frac{a}{\mu - a}.$$

Dividindo o numerador e o denominador por μ ,

$$\boxed{\bar{N} = \frac{I}{1 - I}}.$$

O número médio de pacotes na fila de espera é

$$\bar{N}_q = aW.$$

Portanto,

$$\bar{N}_q = a \frac{I}{\mu(1 - I)} \quad (35)$$

$$= \frac{I^2}{1 - I}. \quad (36)$$

Assim,

$$\boxed{\bar{N}_q = \frac{I^2}{1 - I}}.$$

Podemos verificar que

$$\bar{N}_q + \bar{N}_s = \frac{I^2}{1 - I} + I \quad (37)$$

$$= \frac{I^2 + I(1 - I)}{1 - I} \quad (38)$$

$$= \frac{I}{1 - I} \quad (39)$$


$$= \bar{N}. \quad (40)$$

6.2.4 Crescimento do número médio de pacotes

A expressão

$$\bar{N} = \frac{I}{1 - I}$$

mostra que o número médio de pacotes cresce rapidamente quando I se aproxima de 1.



Alguns valores ilustrativos são:

I	$\bar{N} = I/(1 - I)$
0,20	0,25
0,50	1
0,80	4
0,90	9
0,95	19

Aumentar a utilização de 80% para 90% mais do que duplica o número médio de pacotes:

$$4 \longrightarrow 9.$$

6.2.5 Exemplo numérico

Considere um enlace com

$$R = 10 \text{ Mbit/s}, \quad L = 1\,000 \text{ bytes}, \quad a = 800 \text{ pacotes/s}.$$

Convertendo o tamanho dos pacotes para bits,

$$L = 8\,000 \text{ bits}.$$

A taxa de serviço é

$$\mu = \frac{10\,000\,000}{8\,000} = 1\,250 \text{ pacotes/s}.$$

A intensidade de tráfego é

$$I = \frac{a}{\mu} = \frac{800}{1\,250} = 0,64.$$

Como $I < 1$, o sistema pode ser estável. No modelo $M/M/1$,

$$\bar{N} = \frac{0,64}{1 - 0,64} \approx 1,78 \text{ pacotes.}$$

O tempo médio total é

$$T = \frac{\bar{N}}{a} = \frac{1,78}{800} \approx 0,00222 \text{ s.}$$

Portanto,

$$\boxed{T \approx 2,22 \text{ ms}}.$$

O tempo médio de serviço é

$$S = \frac{L}{R} = 0,8 \text{ ms.}$$

Logo, o tempo médio na fila é

$$W = T - S \approx 2,22 - 0,8 = 1,42 \text{ ms.}$$

6.2.6 E se todos os pacotes tiverem o mesmo tamanho?

A fórmula

$$\bar{N} = \frac{I}{1 - I}$$

não vale para qualquer sistema com intensidade I . Ela foi obtida usando as hipóteses do modelo $M/M/1$, especialmente a hipótese de tempos de serviço exponenciais.

Se todos os pacotes tiverem exatamente L bits, o tempo de serviço será determinístico. Com chegadas Poisson, o modelo correspondente será $M/D/1$.

Na fila $M/M/1$,

$$W_{M/M/1} = \frac{I}{\mu(1 - I)}.$$

Na fila $M/D/1$,

$$W_{M/D/1} = \frac{I}{2\mu(1 - I)}.$$

Portanto,

$$W_{M/D/1} = \frac{1}{2} W_{M/M/1}.$$

A Lei de Little continua válida nos dois casos. O que muda é o atraso obtido a partir do modelo. A maior variabilidade dos tempos de serviço no modelo $M/M/1$ aumenta o tempo médio de espera.

6.3 Síntese

As principais relações desta aula são:

$$\mu = \frac{R}{L}$$

$$I = \frac{a}{\mu} = \frac{aL}{R}$$

$$\overline{N}_q = aW, \quad \overline{N}_s = aS, \quad \overline{N} = aT$$

$$\overline{N}_s = I$$

Para o modelo $M/M/1$,

$$W = \frac{I}{\mu(1 - I)}$$

$$T = \frac{1}{\mu(1 - I)} = \frac{1}{\mu - a}$$

$$\overline{N}_q = \frac{I^2}{1 - I}, \quad \overline{N} = \frac{I}{1 - I}.$$

6.4 Questões de revisão

1. Qual é a diferença entre fila de espera, servidor e sistema?
2. O que significa afirmar que $\overline{N}_s = 0,75$?
3. Por que a intensidade de tráfego também representa a utilização do servidor?
4. Por que $I < 1$ é uma condição necessária para a estabilidade?
5. A Lei de Little depende de chegadas Poisson ou de tempos de serviço exponenciais?
6. A fórmula

$$\overline{N} = \frac{I}{1 - I}$$

vale para qualquer fila? Quais hipóteses foram usadas para obtê-la?

7. Dois sistemas com a mesma intensidade de tráfego necessariamente apresentam o mesmo atraso médio?
8. Um enlace de 20 Mbit/s recebe 1 000 pacotes/s, com tamanho médio de 1 500 bytes. Calcule μ e I .
9. Em um sistema, há em média oito pacotes e a taxa de chegada é 400 pacotes/s. Use a Lei de Little para determinar o tempo médio no sistema.
10. Em uma fila $M/M/1$, o que acontece com W , T e $\overline{N}$ quando I se aproxima de 1?

AULA 7 | 02/09/2026 – quarta-feira**Modelos probabilísticos, revisão de filas e camadas de protocolo****Cobertura:** Revisão do Slide 52**7.1 Observações sobre o teste**

A aula começou com comentários sobre o teste. Quatro pontos foram destacados.

7.1.1 Modelagem de situações de incerteza

O primeiro ponto é reconhecer qual distribuição descreve cada situação. Cada uma responde a uma pergunta diferente.

- $Z \sim \text{Ber}(p)$: situações de sucesso ou fracasso, isto é, um único experimento com dois resultados possíveis;
- $X \sim \text{Bin}(n, p)$: situações em que se deseja contar a quantidade de sucessos em n tentativas independentes;
- $Y \sim \text{Geo}(p)$: situações em que se deseja contar a quantidade de tentativas até o primeiro sucesso;
- $W \sim \text{Poi}(\lambda)$: situações em que se deseja contar o número de ocorrências em um dado intervalo de tempo.

A variável binomial é construída a partir de variáveis de Bernoulli:

$$X = \sum_{i=1}^n Z_i.$$

A variável geométrica também é construída a partir das mesmas variáveis, mas registrando a posição do primeiro sucesso:

$$Y = \arg \min_i \{Z_i : Z_i = 1\}.$$


Na variável de Poisson, o parâmetro é o produto da taxa pelo intervalo de interesse:

$$\boxed{\lambda = \tilde{\lambda} T},$$

em que $\tilde{\lambda}$ é a taxa de ocorrências por unidade de tempo e T é a duração do intervalo observado.

7.1.1.1 Relações entre as distribuições

As distribuições não são independentes umas das outras. Há uma conexão entre todas elas:



Dois limites foram destacados em aula:

- quando $n \rightarrow \infty$, a soma $X = \sum_i Z_i$ se aproxima de uma Gaussiana;
- quando $n \rightarrow \infty$ com $np = \lambda$ fixo, a binomial se aproxima de uma Poisson. Em sala, comentou-se que valores de n a partir de aproximadamente 10 já produzem uma aproximação razoável.

Uma diferença estrutural importante é o suporte de cada variável:

- o suporte da binomial é finito, $X \in \{0, 1, 2, \dots, n\}$;
- o suporte da geométrica é infinito, $Y \in \{1, 2, 3, \dots\}$;
- o suporte da Poisson é infinito, $W \in \{0, 1, 2, \dots\}$.

Por esse motivo, muitas vezes é mais conveniente trabalhar com a Poisson do que com a binomial: a expressão da Poisson depende de um único parâmetro.

Exemplo de escolha do parâmetro. Se escolhermos $\lambda = 7$ em uma janela de 5 minutos, isso significa que, na média, chegam 7 clientes a cada 5 minutos. O parâmetro da Poisson é sempre um número médio de ocorrências, não uma probabilidade.

7.1.2 PMF aplicada em um ponto

A função massa de probabilidade (PMF) quantifica a probabilidade de uma realização específica da variável aleatória.

Para a binomial,

$$\Pr(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k \in \{0, 1, \dots, n\}.$$

O coeficiente $\binom{n}{k}$ é a combinação de n elementos tomados k a k ; ele conta de quantas maneiras os k sucessos podem se distribuir entre as n tentativas.

Para a geométrica,

$$\Pr(Y = k) = (1 - p)^{k-1} p, \quad k \in \{1, 2, 3, \dots\}.$$

Observe que a geométrica começa em 1: é preciso ao menos uma tentativa para haver um primeiro sucesso.

Para a Poisson,

$$\Pr(W = w) = \frac{e^{-\lambda T} (\lambda T)^w}{w!}, \quad w \in \{0, 1, 2, \dots\}.$$

7.1.3 Notação da CDF

A função de distribuição acumulada (CDF) é definida por

$$F_X(k) = \Pr(X \leq k).$$

A CDF acumula a PMF até o ponto k , inclusive. A distinção entre $\leq$ e $<$ é essencial em variáveis discretas.

7.1.4 Cálculo de $\Pr(X \geq k)$

Seja $X \sim \text{Bin}(n, p)$. Há duas formas de calcular $\Pr(X \geq k)$.

(a) **Soma direta de PMFs.**

$$\Pr(X \geq k) = \sum_{i=k}^n \binom{n}{i} p^i (1-p)^{n-i}.$$

(b) **Complementar da CDF aplicada em um ponto.**

$$\Pr(X \geq k) = 1 - \Pr(X \leq k-1) = 1 - F_X(k-1).$$

A estratégia é acumular até um valor e depois complementar. O cuidado está no índice: o complementar de $X \geq k$ é $X \leq k-1$, e não $X \leq k$.

Exemplo discutido em sala. Arremessos de bola de basquete em uma cesta, com

$$n = 10 \text{ (jogou 10 vezes)}, \quad p = \text{probabilidade de acertar uma tentativa}.$$

Cada arremesso é uma variável de Bernoulli, e o total de acertos é binomial.

7.2 Revisão da aula passada

A segunda parte da aula retomou o modelo de filas visto na Aula 6.

7.2.1 Nota sobre notação


O quadro desta aula usa λ para a taxa média de chegada e barras sobre os tempos médios. A correspondência com a notação da Aula 6 é:

$$\lambda = a, \quad \overline{W} = W, \quad \overline{S} = S, \quad \overline{T} = T.$$

Nesta aula, adotamos a notação do quadro.

7.2.2 Os três elementos

O sistema estudado tem três elementos: a taxa de chegada, a fila e o servidor.



O tempo de serviço médio é

$$\bar{S} = \frac{1}{\mu} = \frac{\bar{L}}{R},$$


em que $\bar{L}$ é o tamanho médio do pacote e R é a taxa do enlace.

A intensidade de tráfego é a probabilidade de o servidor estar ocupado:

$$I = \Pr(\text{ocupado}) < 1.$$

7.2.3 Fluxo de Poisson, variável de Poisson e variável exponencial

Um ponto central da revisão é que “Poisson” aparece em dois papéis diferentes: como fluxo de chegadas e como variável aleatória discreta. Ligada a esse fluxo há ainda uma variável contínua, a exponencial.



A variável de Poisson responde à pergunta: qual a probabilidade de haver w chegadas em um intervalo T qualquer?

$$\Pr(W = w) = \frac{e^{-\lambda T} (\lambda T)^w}{w!}.$$

A variável exponencial responde à pergunta complementar. Definindo

$$V \triangleq \text{tempo até a próxima chegada},$$

o evento $V > T$ significa que nenhuma chegada ocorreu no intervalo T . Logo,

$$\Pr(V > T) = \Pr(W = 0) = e^{-\lambda T}.$$

Essa é a ponte entre as duas descrições: contar chegadas em um intervalo (discreto) e medir o tempo entre chegadas (contínuo) são duas leituras do mesmo fluxo.

7.2.4 Chegadas de Poisson e o estado do sistema

Como as chegadas são de Poisson, um pacote que chega enxerga o sistema no seu estado médio de longo prazo. Ele não chega em um instante privilegiado. Essa é a propriedade PASTA, *Poisson Arrivals See Time Averages*, apresentada na Aula 6.

7.2.5 A conta do tempo médio de espera

Um pacote que chega precisa esperar que todo o trabalho pendente à sua frente seja executado. Esse trabalho pendente é composto por:

- os $\bar{N}_q$ pacotes que estão na fila;
- o pacote que está no servidor, presente em média $\bar{N}_s = I$.

Cada um deles consome, em média, $\bar{S}$ segundos. Portanto,

$$\bar{W} = (\bar{N}_q + \bar{N}_s) \bar{S}.$$

Duas hipóteses sustentam essa expressão:

1. **PASTA:** a chegada observa as médias temporais do sistema;
2. **falta de memória do serviço:** o pacote que já está sendo transmitido ainda demanda, em média, $\bar{S}$ segundos, e não menos.

Aplicando a Lei de Little, $\bar{N}_q = \lambda \bar{W}$, e usando $\bar{N}_s = I$:

$$\bar{W} = \lambda \bar{W} \bar{S} + I \bar{S}. \quad (41)$$

Como $\lambda \bar{S} = \lambda / \mu = I$,

$$\bar{W} = I \bar{W} + I \bar{S}.$$

Isolando $\bar{W}$,

$$\bar{W}(1 - I) = I \bar{S}$$

e portanto

$$\bar{W} = \frac{I \bar{S}}{1 - I}.$$

7.2.6 Número médio de pacotes

Pela Lei de Little aplicada à fila de espera,

$$\bar{N}_q = \lambda \bar{W} = \lambda \frac{I \bar{S}}{1 - I} = \frac{I^2}{1 - I},$$

pois $\lambda \bar{S} = I$. Assim,

$$\overline{N}_q = \frac{I^2}{1 - I}.$$


Somando o pacote em serviço,

$$\overline{N} = \overline{N}_q + \overline{N}_s = \frac{I^2}{1 - I} + I = \frac{I}{1 - I}.$$

Portanto,

$$\overline{N} = \frac{I}{1 - I}.$$

O gráfico de $\overline{N}$ contra I , revisto em aula, cresce sem limite quando $I \rightarrow 1$:



7.2.7 Condição de equilíbrio

Foi retomada a observação do Kurose: o sistema só está em equilíbrio se a taxa de chegada for menor do que a capacidade de serviço. Essa é uma condição *necessária* para o sistema estar em equilíbrio, e corresponde a $I < 1$.


Além disso, se $\overline{S}$ aumenta, então $\overline{W}$ e $\overline{T}$ aumentam. Serviços mais lentos elevam a intensidade de tráfego e, com ela, o atraso.

7.3 Decomposição do atraso

O tempo total $\bar{T}$ percebido por um pacote se decompõe em parcelas distintas:

- $d_{\text{fila}} = \bar{W}$: espera na fila;
- $d_{\text{transm}} = \bar{S}$: tempo de transmissão, isto é, de serviço;
- d_{prop} : tempo de propagação no enlace.

O diagrama espaço-tempo torna a distinção visível. O eixo vertical representa o tempo, e as duas linhas verticais representam o transmissor e o receptor.




A altura do retângulo de cada pacote é o tempo de transmissão; a inclinação da reta é o tempo de propagação. A fila aparece como o intervalo entre a chegada do pacote e o início da sua transmissão.

7.4 Efeito da variabilidade: $M/D/1$ e $M/M/1$

Na fila $M/D/1$, o tempo de serviço é determinístico: todos os pacotes têm o mesmo tamanho, então todos os retângulos de transmissão têm a mesma altura e as retas de propagação são paralelas.

Na fila $M/M/1$, o tempo de serviço é exponencial: o tamanho do pacote é uma variável aleatória, então os retângulos têm alturas diferentes.



A comparação quantitativa foi vista na Aula 6:

$$\bar{W}_{M/D/1} = \frac{1}{2} \bar{W}_{M/M/1}.$$

A conclusão é que a variabilidade dos tempos de serviço, e não apenas a média, determina o atraso. Dois sistemas com a mesma intensidade de tráfego I podem ter atrasos médios diferentes.

7.5 Roteiro do Capítulo 1


- o que é a Internet;
- a borda da rede (*edge*);
- o núcleo da rede (*core*);
- atrasos e perdas;
- modelo em camadas;
- segurança;
- histórico.

O item de segurança veio acompanhado da referência ao livro *Fancy Bear Goes Phishing*, indicado como leitura complementar.

7.6 Camadas de protocolo

7.6.1 A analogia da companhia aérea

O Kurose apresenta a arquitetura em camadas por meio de uma analogia humana: o sistema de uma companhia aérea. Esse sistema envolve emissão de passagens, despacho de bagagem, portão de embarque, pilotos, aviões e controle de tráfego aéreo. Organizar essas funções em camadas permite descrever o sistema por partes.



Cada camada, combinada com as que estão abaixo dela, implementa um serviço:

- na camada da passagem e abaixo dela, realiza-se a transferência balcão-a-balcão do passageiro;
- na camada da bagagem e abaixo dela, realiza-se a transferência despacho-a-recuperação do passageiro e de suas malas;
- na camada do portão, realiza-se a transferência portão-a-portão;
- na camada de decolagem/aterriçagem, realiza-se a transferência pista-a-pista.

Cada camada provê seu serviço de duas maneiras: executando ações próprias e utilizando os serviços da camada imediatamente inferior.

Assim como as funções da companhia aérea estão distribuídas entre vários aeroportos, um protocolo de camada n está distribuído entre sistemas finais, comutadores de pacote e demais componentes da rede.

7.6.2 Vantagens e desvantagens

A principal vantagem é a modularidade: a divisão em camadas permite discutir uma parcela bem definida de um sistema grande e facilita a atualização de componentes.

- uma camada pode duplicar a funcionalidade de uma camada inferior. Por exemplo, várias pilhas oferecem recuperação de erros por enlace e também fim a fim, o que gera trabalho desnecessário;
- uma camada pode precisar de informação que só existe em outra camada, o que infringe o objetivo de separação entre elas.

O conjunto dos protocolos das várias camadas é denominado *pilha de protocolos*. A pilha da Internet tem cinco camadas: física, de enlace, de rede, de transporte e de aplicação. O livro é organizado nessa ordem, de cima para baixo, o que caracteriza a abordagem *top-down*.

7.7 Síntese

Distribuições e suas relações:

$$X = \sum_{i=1}^n Z_i, \quad Y = \arg \min_i \{Z_i : Z_i = 1\}, \quad \lambda = \tilde{\lambda} T$$

$$\Pr(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$\Pr(Y = k) = (1-p)^{k-1} p$$

$$\Pr(W = w) = \frac{e^{-\lambda T} (\lambda T)^w}{w!}$$

$$F_X(k) = \Pr(X \leq k), \quad \Pr(X \geq k) = 1 - F_X(k-1)$$

Fluxo de Poisson e tempo entre chegadas:

$$\Pr(V > T) = \Pr(W = 0) = e^{-\lambda T}$$

Filas:

$$\bar{S} = \frac{1}{\mu} = \frac{\bar{L}}{R}, \quad I = \Pr(\text{ocupado}) < 1$$

$$\bar{W} = (\bar{N}_q + \bar{N}_s) \bar{S} = \frac{I \bar{S}}{1 - I}$$

$$\overline{N}_q = \frac{I^2}{1-I}, \quad \overline{N} = \frac{I}{1-I}$$

Atraso:

$$\overline{T} = d_{\text{fila}} + d_{\text{transm}} + d_{\text{prop}}$$

7.8 Questões de revisão

1. Qual pergunta cada uma das distribuições responde: Bernoulli, binomial, geométrica e Poisson?
2. Por que a geométrica tem suporte $\{1, 2, 3, \dots\}$ e não $\{0, 1, 2, \dots\}$?
3. Sob quais condições a binomial se aproxima de uma Poisson? E de uma Gaussiana?
4. Em $\lambda = \tilde{\lambda}T$, o que representa cada fator? O que significa afirmar que $\lambda = 7$?
5. Escreva $\Pr(X \geq 3)$ para $X \sim \text{Bin}(10, p)$ das duas formas vistas em aula. Por que o complementar usa $\Pr(X \leq 2)$?
6. Qual é a diferença entre o fluxo de Poisson, a variável de Poisson e a variável exponencial?
7. Deduza $\Pr(V > T) = e^{-\lambda T}$ a partir da PMF de Poisson.
8. Quais são as duas hipóteses usadas para escrever $\overline{W} = (\overline{N}_q + \overline{N}_s)\overline{S}$?
9. Partindo dessa expressão e da Lei de Little, obtenha $\overline{W} = I\overline{S}/(1-I)$.
10. Quais parcelas compõem $\overline{T}$? Qual delas não depende da intensidade de tráfego?
11. Por que $M/D/1$ apresenta metade da espera de $M/M/1$, mesmo com a mesma intensidade de tráfego?
12. Na analogia da companhia aérea, qual serviço é prestado pela camada do portão e abaixo dela?
13. Quais são as cinco camadas da pilha de protocolos da Internet?

AULA 8 | 04/09/2026 – sexta-feira**Tempo residual de serviço, vazão e comunicação entre processos**

Cobertura: Fim do Capítulo 1 e início do Capítulo 2.

8.1 Estabilidade e ocupação do servidor

Há uma distinção que precisa ficar clara: um sistema pode estar com o servidor permanentemente ocupado sem que isso implique instabilidade.

Na fila $M/M/1$, a condição de estabilidade é

$$I < 1,$$

e o sistema é instável caso contrário. Isso decorre das flutuações aleatórias: com chegadas de Poisson e serviço exponencial, mesmo com I próximo de 1 ocorrem rajadas que fazem a fila crescer, e é preciso folga para que ela se esvazie.

8.1.1 Existe sistema estável com $I = 1$?

Sim. Considere a fila $D/D/1$:

- chegadas determinísticas;
- tempos de serviço determinísticos;
- um único servidor.

Se um pacote chega exatamente a cada $1/\lambda$ segundos e cada pacote leva exatamente $\bar{S} = 1/\mu$ segundos para ser transmitido, com $\lambda = \mu$, então cada pacote encontra o servidor livre no instante exato em que chega. O servidor fica ocupado 100% do tempo, ou seja, $I = 1$, e mesmo assim a fila nunca cresce: não há espera.

A conclusão é que a condição $I < 1$ é necessária apenas quando existe aleatoriedade. O que gera fila não é a utilização alta em si, mas a variabilidade em torno dela.

8.2 Tempo residual de serviço

Um pacote que chega e encontra o servidor ocupado não espera um tempo de serviço completo pelo pacote em transmissão: espera apenas o que falta dele. Essa quantidade é o tempo residual de serviço, denotado $\bar{S}_R$.

8.2.1 A expressão geral da espera

A espera se decompõe em duas parcelas:

$$\boxed{\bar{W} = \bar{N}_q \bar{S} + \bar{N}_s \bar{S}_R}.$$


O primeiro termo considera os pacotes que estão inteiramente na fila: cada um deles ainda será transmitido por completo, consumindo $\bar{S}$ segundos. O segundo termo trata do pacote que já está no servidor, e por isso usa o tempo residual e não o tempo completo.

O peso do segundo termo é a probabilidade de haver alguém em serviço:

$$\boxed{\bar{N}_s = I = U = \Pr(\text{ocupação})}.$$

8.2.2 Cálculo do tempo residual

Considere o eixo do tempo dividido pelas transmissões sucessivas, cada uma com duração L/R . Um pacote que chega cai em um ponto qualquer de um desses intervalos, e o que ele espera é a distância desse ponto até o fim do intervalo.



Como as chegadas não escolhem o instante em que ocorrem, intervalos longos têm mais chance de receber uma chegada do que intervalos curtos, e exatamente na proporção da sua duração. Isso faz o segundo momento aparecer:

$$\boxed{\bar{S}_R = \frac{\bar{S}^2}{2\bar{S}} = \frac{\mathbb{E}(S^2)}{2\mathbb{E}(S)}}.$$

O numerador é o segundo momento do tempo de serviço, isto é, a esperança de S^2 .

8.2.3 Os dois casos particulares

8.2.3.1 Serviço exponencial: $M/M/1$

Para o tempo de serviço exponencial de média $1/\mu$,

$$\mathbb{E}(S) = \frac{1}{\mu}, \quad \mathbb{E}(S^2) = \frac{2}{\mu^2}.$$

Logo,

$$\bar{S}_R = \frac{2/\mu^2}{2/\mu} = \frac{1}{\mu} = \bar{S}.$$

O tempo residual é igual ao tempo de serviço completo. Esse é o significado concreto da propriedade *memoryless*: saber que a transmissão já começou não adianta nada. A espera fica

$$\boxed{\bar{W}_{M/M/1} = \bar{N}_q \bar{S} + \bar{N}_s \bar{S}}.$$

8.2.3.2 Serviço determinístico: $M/D/1$

Para o tempo de serviço constante e igual a $\bar{S}$,

$$\mathbb{E}(S) = \bar{S}, \quad \mathbb{E}(S^2) = \bar{S}^2.$$

Logo,

$$\bar{S}_R = \frac{\bar{S}^2}{2\bar{S}} = \frac{\bar{S}}{2}.$$

Uma chegada em um instante qualquer encontra, em média, metade da transmissão já concluída. A espera fica

$$\boxed{\bar{W}_{M/D/1} = \bar{N}_q \bar{S} + \bar{N}_s \frac{\bar{S}}{2}}.$$

8.2.3.3 Resolvendo o caso determinístico

Aplicando a Lei de Little, $\bar{N}_q = \lambda \bar{W}$, e usando $\bar{N}_s = I$ com $\lambda \bar{S} = I$:

$$\bar{W} = \lambda \bar{W} \bar{S} + I \frac{\bar{S}}{2} \tag{42}$$

$$= I \bar{W} + \frac{I \bar{S}}{2}. \tag{43}$$

Isolando,

$$\bar{W}(1 - I) = \frac{I \bar{S}}{2}$$

e portanto

$$\boxed{\bar{W}_{M/D/1} = \frac{I \bar{S}}{2(1 - I)} = \frac{1}{2} \bar{W}_{M/M/1}}.$$


8.2.4 O papel da variabilidade

A expressão de $\bar{S}_R$ depende do segundo momento, e não apenas da média. Duas filas podem ter o mesmo $\bar{S}$, a mesma taxa de chegada e a mesma intensidade de tráfego, e ainda assim apresentar esperas diferentes. Quanto maior a variabilidade dos tempos de serviço, maior o tempo residual e pior o desempenho.

Vale notar que várias aplicações geram pacotes com tamanho determinístico: a aplicação usa sempre o mesmo tamanho, o que aproxima o comportamento do caso $M/D/1$ e reduz a espera pela metade em relação ao caso exponencial.

8.3 Distribuição do número de pacotes

O sistema pode ser descrito pelos estados $0, 1, 2, 3, \dots$, em que o estado n significa haver n pacotes no sistema. As transições ocorrem para o estado seguinte à taxa λ , quando chega um pacote, e para o estado anterior à taxa μ , quando um pacote termina de ser servido.



A probabilidade de o sistema estar vazio é o complementar da probabilidade de estar ocupado:

$$\pi_0 = 1 - \text{Pr}(\text{ocupado}) = 1 - \rho = 1 - U = 1 - I.$$

8.4 Vazão

8.4.1 Vazão instantânea e vazão média

A vazão instantânea é a taxa com que os bits estão sendo entregues em um dado momento. Enquanto o servidor transmite, ela vale

$$\frac{R}{L} = \mu,$$

e enquanto o servidor está ocioso, ela vale zero.

A vazão média é obtida condicionando nos dois estados possíveis:

$$\text{vazão média} = (\text{vazão} \mid \text{ocupado}) \text{Pr}(\text{ocupado}) + (\text{vazão} \mid \text{ocioso}) \text{Pr}(\text{ocioso}).$$

Substituindo cada termo,


$$\lambda = \mu I + 0 \cdot (1 - I).$$

Essa identidade confirma que $I = \lambda/\mu$: em equilíbrio, o que entra é igual ao que sai, e a única forma de o servidor entregar λ pacotes por segundo transmitindo à taxa μ é ficar ocupado durante a fração I do tempo.

8.4.2 Vazão fim a fim e gargalo

Em um caminho fim a fim, a vazão é limitada pelo enlace mais restritivo. Considere um servidor com taxa de acesso R_s , um cliente com taxa de acesso R_c e um enlace intermediário de taxa R compartilhado por 10 conexões simultâneas. A vazão de cada conexão é

$$\min\left(R_c, R_s, \frac{R}{10}\right).$$



Um cache instalado próximo ao cliente altera essa conta. Uma fração p_{hit} das requisições é atendida localmente, sem atravessar o gargalo; apenas a fração p_{miss} percorre o caminho completo. O tráfego que efetivamente disputa o enlace compartilhado é reduzido pelo fator p_{miss} , o que diminui a intensidade de tráfego naquele enlace e, com ela, o atraso de fila. O cache do navegador é um exemplo desse mecanismo.

8.5 Medição do atraso

8.5.1 TTL

Todo pacote carrega um campo TTL, *time to live*, que é decrementado a cada roteador atravessado. Quando o campo chega a zero, o roteador descarta o pacote e devolve uma mensagem de erro à origem. O objetivo do campo é impedir que pacotes circulem indefinidamente em caso de laço de roteamento.

8.5.2 Traceroute

O traceroute explora esse mecanismo: envia pacotes com valores crescentes de TTL, de modo que cada roteador do caminho seja obrigado a responder na sua vez. Para cada salto são enviados três *probes*, e os três tempos são reportados.

Um valor medido, como 121 ms, é um tempo total: ele engloba o atraso de fila acumulado no caminho, além dos atrasos de transmissão, propagação e processamento. Por isso os três valores de um mesmo salto costumam diferir entre si.


Vale lembrar que $\overline{W}$ é uma média fixa, determinada pelos parâmetros do sistema, enquanto as amostras individuais de espera variam de pacote para pacote.

8.6 Custo da divisão em camadas

A modularidade das camadas tem um preço, e ele aparece em dois lugares.

Primeiro, cada camada mantém sua própria fila, o que significa uma fila por camada ao longo do percurso.

Segundo, cada camada atravessada acrescenta um cabeçalho ao pacote. O cabeçalho mais interno é o que só será examinado pelo destino final; os cabeçalhos externos são lidos e removidos pelos elementos intermediários.



8.7 Segurança

Três propriedades organizam a discussão de segurança, resumidas pela sigla AIC.

Availability (disponibilidade)	Integrity (integridade)	Confidentiality (confidencialidade)
DoS ataque ativo <i>firewall</i>	<i>spoofing</i> ataque ativo assinaturas, <i>hashes</i>	<i>sniffing</i> ataque passivo criptografia

A distinção entre ataque ativo e passivo é relevante: no ataque ativo há modificação ou injeção de tráfego, o que o torna detectável em princípio; no ataque passivo há apenas observação, e por isso a defesa é impedir a leitura, não a interceptação.

Como leitura complementar sobre o tema, foi indicado o livro *Fancy Bear Goes Phishing*.

8.8 Capítulo 2: comunicação entre processos

8.8.1 Formas de comunicação

Uma aplicação de rede não é um programa executando em uma máquina isolada: são processos em máquinas diferentes que trocam informação. Antes de tratar da rede, convém situar as formas gerais de comunicação entre processos (IPC):


- *pipes*;
- sinais;
- mensagens (*sockets*);
- memória compartilhada.

Dessas quatro, a comunicação por mensagens é a que interessa às redes, pois é a única que funciona entre máquinas distintas. A memória compartilhada pertence ao domínio da computação concorrente, dentro de uma mesma máquina.

Vale a distinção: *threads* já compartilham memória por padrão; processos não.

8.8.2 Sockets


O socket é o elemento entre a aplicação e a camada de transporte. Ele é implementado pelo sistema operacional, e é, concretamente, uma região de memória do sistema operacional.



As operações disponíveis sobre um socket são criar, ler e destruir. A aplicação escreve no socket e lê do socket; tudo o que acontece abaixo dele é responsabilidade do sistema operacional e da rede.

8.8.3 Portas

O endereço IP identifica a máquina; a porta identifica qual processo dentro dela deve receber os dados. Um mesmo servidor pode atender simultaneamente à porta 80, para HTTP, e à porta 25, para correio eletrônico.



8.8.4 Transporte: TCP e UDP

Há duas opções de transporte disponíveis para a aplicação:

- TCP: oferece muitos serviços à aplicação, e por isso é *heavyweight*;
- UDP: oferece quase nada, é minimalista e *lightweight*.

A escolha entre eles é uma decisão de projeto da aplicação: quanto do trabalho ela quer delegar ao transporte e quanto quer implementar por conta própria.

O HTTP tradicionalmente usa TCP, mas também pode operar sobre QUIC, que por sua vez roda sobre UDP.

O capítulo se encerra com a programação de uma aplicação usando sockets.

8.9 Síntese

Espera com tempo residual:

$$\bar{W} = \bar{N}_q \bar{S} + \bar{N}_s \bar{S}_R, \quad \bar{N}_s = I = U = \text{Pr(ocupação)}$$

$$\bar{S}_R = \frac{\bar{S}^2}{2\bar{S}} = \frac{\mathbb{E}(S^2)}{2\mathbb{E}(S)}$$

$$\bar{S}_R^{M/M/1} = \bar{S}, \quad \bar{S}_R^{M/D/1} = \frac{\bar{S}}{2}$$

$$\bar{W}_{M/D/1} = \frac{I \bar{S}}{2(1-I)} = \frac{1}{2} \bar{W}_{M/M/1}$$

Ocupação e vazão:

$$\pi_0 = 1 - \rho = 1 - U = 1 - I$$

$$\lambda = \mu I + 0 \cdot (1 - I)$$

$$\text{vazão fim a fim} = \min\left(R_c, R_s, \frac{R}{10}\right)$$

AULA 9 | 09/09/2026 – quarta-feira

Camada de Aplicação: HTTP, Desempenho e Conexões

Cobertura: Resolução de exercícios (Lei de Little), características do protocolo HTTP, modelos de conexão TCP (triângulo de *handshake*, objetos com linha grossa), análise de tempo (RTT) e evolução das versões do HTTP com *interleaving*.

9.1 Nota sobre a Lei de Little (Lista de Exercícios)

A partir da discussão do exercício P16 em sala, reforçamos uma premissa fundamental da teoria de filas:

Cuidado: Para aplicar a Lei de Little ($\bar{N} = \lambda \bar{T}$), o sistema precisa **necessariamente estar em equilíbrio** ($I < 1$). A questão discutida estava mal formulada porque violava esse princípio. Possíveis consertos matemáticos para tornar o sistema viável envolvem diminuir a taxa de chegada (λ), aumentar a taxa de serviço (μ) ou fixar $\bar{N}$ e $\bar{T}$ ajustando a entrada.

9.2 O Protocolo HTTP

O HTTP (*Hypertext Transfer Protocol*) é o protocolo base da Web, operando na camada de aplicação.

Protocolo Stateless: O HTTP é um protocolo sem estado. O conteúdo da resposta não depende do histórico de requisições anteriores. Para manter sessões (como logins), a web utiliza **cookies**.

9.3 Modelos de Conexão HTTP

O desempenho do HTTP depende de como ele utiliza as conexões da camada de transporte (TCP). Para iniciar qualquer requisição HTTP, primeiro é necessário estabelecer a conexão TCP através de um *Three-way Handshake*. Isso consome 1 RTT (*Round-Trip Time*) inicial apenas para sincronizar (SYN e SYN/ACK) antes mesmo do GET ser enviado.

A tabela abaixo unifica e resume as quatro abordagens formadas pela combinação da persistência e do paralelismo, oferecendo uma visão global:

	Sem Paralelismo	Com Paralelismo
Não Persistente	Fecha conexão após cada objeto; requisições e <i>handshakes</i> estritamente sequenciais.	Múltiplas conexões TCP (com seus respectivos <i>handshakes</i>) abertas simultaneamente.
Persistente	Uma única conexão TCP mantida aberta; requisições sequenciais na mesma via.	Reaproveita conexões TCP abertas e abre novas conexões em paralelo quando necessário.

Abaixo, detalhamos cada modelo com suas vantagens, desvantagens, diagrama de espaço-tempo e análise numérica do tempo envolvido. Nos diagramas, as setas cinzas formam o **triângulo do handshake TCP**, e as setas **mais grossas representam a transferência do objeto**.

9.3.1 1. HTTP Não Persistente (Sem Paralelismo)

Neste modelo, uma nova conexão TCP é aberta para solicitar um objeto e imediatamente fechada após a sua recepção. Os objetos são baixados um por vez.

- **Vantagens:** Consome menos recursos ociosos do servidor. Como a porta TCP é liberada rapidamente após o uso, é um modelo mais robusto contra ataques de negação de serviço que exploram conexões presas.
- **Desvantagens:** Pior desempenho de tempo. Paga-se a latência de um *handshake* TCP (1 RTT) para **cada** nova requisição de objeto na página, dobrando o tempo necessário para objetos pequenos.

Análise de Tempo: Para baixar o arquivo HTML base e n objetos referenciados (desprezando o tempo de transmissão dos objetos pequenos), gasta-se 2 RTT por arquivo. Tempo total:

$$\text{Tempo Total} \approx 2 \text{ RTT} + 2n \text{ RTT} = 2(n + 1) \text{ RTT}$$




Figure 8: Não Persistente Sem Paralelismo: O "triângulo" do TCP é formado antes de cada GET.

9.3.2 2. HTTP Não Persistente (Com Paralelismo)

O cliente abre *múltiplas* conexões TCP simultâneas para baixar os objetos paralelos (ex: imagens) ao mesmo tempo.

- **Vantagens:** O tempo de carregamento da página cai drasticamente, pois os RTTs dos objetos subsequentes são sobrepostos no tempo.
- **Desvantagens:** Exige um consumo severo de recursos. O servidor precisa alocar inúmeros *sockets*, *buffers* e processar vários *handshakes* simultaneamente para um único cliente, sobrecarregando o SO.

Análise de Tempo: Gasta-se 2 RTT para o HTML base e, assumindo paralelismo perfeito para os n objetos, mais 2 RTT simultâneos. Tempo total:

$$\text{Tempo Total} \approx 2 \text{ RTT (HTML)} + 2 \text{ RTT (Objetos)} = 4 \text{ RTT}$$




Figure 9: Não Persistente Com Paralelismo: Múltiplas conexões formam seus próprios triângulos e baixam dados ao mesmo tempo.

9.3.3 3. HTTP Persistente (Sem Paralelismo)

Apenas um *handshake* TCP é feito. A mesma conexão é mantida aberta. O cliente envia a requisição, aguarda receber o objeto inteiro, e então usa a mesma via para a próxima requisição.

- **Vantagens:** Evita a sobrecarga de abrir novas conexões (economiza 1 RTT de *handshake* por objeto subsequente) e poupa CPU/memória do servidor.
- **Desvantagens:** Mantém a conexão ociosa ocupando recursos do servidor no longo prazo. Continua sofrendo atrasos caso a resposta de um arquivo seja lenta, travando o envio do GET seguinte.

Análise de Tempo: 2 RTT para o HTML base (inclui TCP setup) e 1 RTT para cada um dos n objetos adicionais. Tempo total:

$$\text{Tempo Total} \approx 2 \text{ RTT} + n \text{ RTT} = (n + 2) \text{ RTT}$$




Figure 10: Persistente Sem Paralelismo: Apenas um *handshake* TCP inicial (triângulo superior).

9.3.4 4. HTTP Persistente (Com Paralelismo)

Para baixar múltiplos objetos ao mesmo tempo na web moderna, o cliente **reaproveita a conexão persistente já existente** para um dos objetos, mas **abre uma nova conexão TCP em paralelo** para solicitar o outro simultaneamente.

- **Vantagens:** Excelente desempenho. Poupa o RTT de abertura para os objetos que reaproveitam as conexões já abertas, enquanto mantém o paralelismo para acelerar o carregamento global da página.
- **Desvantagens:** Ainda consome múltiplos recursos do servidor (vários *sockets* abertos por cliente) e sofre com os recursos alocados enquanto as conexões são mantidas ociosas.

Análise de Tempo: O HTML custa 2 RTT. A 'Img1' reaproveita a conexão (1 RTT), enquanto a 'Img2' exige nova conexão (2 RTT). Sendo paralelas, o tempo final da etapa é o maior entre eles:

$$\text{Tempo Total} \approx 2 \text{ RTT (HTML)} + \max(1 \text{ RTT}, 2 \text{ RTT}) = 4 \text{ RTT}$$




Figure 11: Persistente Com Paralelismo: A Conexão 1 é reaproveitada para a Img1 poupando tempo, enquanto uma Nova Conexão 2 é aberta para baixar a Img2 simultaneamente.

9.4 Evolução do HTTP e a técnica de Interleaving

Para mitigar problemas clássicos de travamento de rede (onde a lentidão de um arquivo trava a transmissão dos menores, e.g., Head-of-Line Blocking), os protocolos evoluíram:

- **HTTP/1 (Básico):** Opera sobre **TCP**. As respostas do servidor são enviadas inteiras, de forma *FIFO* (First-In, First-Out). **Não possui** suporte nativo a *interleaving*.
- **HTTP/2:** Opera sobre **TCP**. Introduce o **interleaving** de forma nativa na mesma conexão, permitindo que as respostas venham em ordem mais estratégica.
- **HTTP/3:** Abandona o TCP em favor do **UDP**. Construído com o protocolo **QUIC** e com foco forte em **segurança**, reduz radicalmente a latência da conexão inicial (podendo zerar o RTT inicial).

9.4.1 O conceito de Interleaving

O **interleaving** permite que o servidor quebre os arquivos e envie suas partes **intercaladas** através da mesma conexão, não exigindo que um arquivo enorme termine de ser enviado antes de começar o próximo.

A ilusão de rapidez: O *interleaving* manda as partes intercaladas (um pouco de HTML, um pouco de Imagem, etc.) para fazer parecer ao usuário que a página está carregando mais rápido, já que o navegador consegue renderizar trechos dos elementos simultaneamente, ao invés de exibir uma página travada.




Figure 12: Diagrama esquemático do *interleaving* (HTTP/2). Note que o *handshake* TCP (triângulo cinza no topo) ocorre apenas uma vez, antes da transmissão fatiada.

9.5 Questões de revisão

1. Por que a fila $D/D/1$ pode ser estável com $I = 1$, enquanto a $M/M/1$ não pode?
2. O que caracteriza cada posição na notação $A/B/m$? Compare $D/D/1$, $M/D/1$ e $M/M/1$.
3. Por que a espera se escreve como $\bar{W} = \bar{N}_q \bar{S} + \bar{N}_s \bar{S}_R$ e não como $(\bar{N}_q + \bar{N}_s) \bar{S}$ em geral?
4. Por que o segundo momento aparece na expressão de $\bar{S}_R$?
5. Mostre que $\bar{S}_R = \bar{S}$ para serviço exponencial e $\bar{S}_R = \bar{S}/2$ para serviço determinístico.
6. Qual é a interpretação de $\bar{S}_R = \bar{S}$ em termos da propriedade *memoryless*?
7. Dois enlaces têm o mesmo $\bar{S}$ e a mesma taxa de chegada, mas variabilidades diferentes nos tempos de serviço. Qual tem maior espera? Por quê?
8. Obtenha $\bar{W}_{M/D/1}$ a partir da expressão geral e da Lei de Little.
9. Interprete $\pi_0 = 1 - I$. O que significa $\pi_0 = 0,2$?
10. Deduza $\lambda = \mu I$ condicionando a vazão nos estados ocupado e ocioso.
11. Em um caminho com $R_c = 5$ Mbit/s, $R_s = 100$ Mbit/s e um enlace compartilhado de $R = 20$ Mbit/s dividido por 10 conexões, qual é a vazão de cada conexão? Qual é o gargalo?
12. Como um cache próximo ao cliente altera a intensidade de tráfego no enlace de acesso?
13. Qual é a função do campo TTL e como o traceroute a utiliza?
14. Por que os três *probes* de um mesmo salto do traceroute costumam apresentar tempos diferentes?
15. Quais são as quatro formas de comunicação entre processos? Qual delas funciona entre máquinas distintas e por quê?
16. O que é um socket, quem o implementa e onde ele reside?
17. Qual é a diferença de papel entre o endereço IP e o número de porta?
18. Em que sentido o TCP é *heavyweight* e o UDP é *lightweight*? Sobre qual deles o QUIC opera?